

多阶段渐进图像恢复

Syed Waqas Zamir * 1 Aditya Arora * 1 Salman Khan 2 Munawar Hayat 3 Fahad Shahbaz Khan 2 Ming-Hsuan Yang 4,5,6 Ling Shao 1,21 人工智能初始研究所 2 Mohamed bin Zayed 人工智能大学 3 莫纳什大学 4 加州大学默塞德 5 延世大学 6 谷歌研究

Abstract

图像恢复任务在恢复图像时需要空间细节和高级上下文信息之间的复杂平衡。在本文中，我们提出了一种新颖的协同设计，可以最佳地平衡这些竞争目标。我们的主要建议是多阶段架构，它逐步学习退化输入的恢复功能，从而将整个恢复过程分解为更易于管理的步骤。具体来说，我们的模型首先使用编码器-解码器架构学习上下文特征，然后将它们与保留本地信息的高分辨率分支相结合。在每个阶段，我们都引入了一种新颖的每像素自适应设计，利用原位监督注意力来重新加权局部特征。这种多阶段架构的一个关键要素是不同阶段之间的信息交换。为此，我们提出了一种双方面的方法，其中信息不仅从早期到后期顺序交换，而且特征处理块之间还存在横向连接以避免任何信息丢失。由此产生的紧密互连的多级架构（称为MPRNet）在图像去雨、去模糊和去噪等一系列任务中的10个数据集上提供了强大的性能提升。源代码和预训练模型可在 <https://github.com/swz30/MPRNet> 上获取。

一、简介

图像恢复是从降级版本中恢复干净图像的任务。退化的典型例子包括噪声、模糊、雨、雾等。这是一个高度不适定的问题，因为存在无限的可行解决方案。为了将解决方案空间限制为有效/自然图像，现有的恢复技术[19,29,39,59,66,67,100]明确使用根据经验观察手工制作的图像先验。然而，设计这样的先验是一项具有挑战性的任务，而且通常不可推广。为了改善这个问题，最近最先进的方法[17,44,57,86,87,93,94,97]采用了卷积神经网络（CNN），它可以




图 1: GoPro 数据集上的图像去模糊 [53]。在下面

不同的参数容量（x轴），我们的多阶段方法比单阶段基线[65]（带有通道注意力[95]）以及最先进的方法（y轴上的PSNR）表现更好。

通过从大规模数据中捕获自然图像统计数据，明确地学习更一般的先验。基于 CNN 的方法相对于其他方法的性能增益主要归因于其模型设计。已经开发了许多用于图像恢复的网络模块和功能单元，包括递归残差学习 [4, 95]、扩张卷积 [4, 81]、注意力机制 [17, 86, 96]、密集连接 [73, 75, 97]、编码器-解码器[7, 13, 43, 65]和生成模型[44, 62, 90, 92]。然而，几乎所有这些针对低级视觉问题的模型都是基于单阶段设计。相比之下，在姿态估计 [14, 46, 54]、场景解析 [15] 和动作分割 [20, 26, 等高级视觉问题中，多阶段网络比单阶段网络更有效。45]。最近，很少有努力将多阶段设计引入图像去模糊[70,71,88]和图像去雨[47,63]。我们分析这些方法来识别阻碍其性能的架构瓶颈。首先，现有的多级技术要么采用编码器-解码器架构[71, 88]，它在编码广泛的上下文信息方面有效，但在保留空间图像细节方面不可靠，或者使用单尺度管道[63]，它提供空间精确但语义-

* 同等贡献

输出的可靠性明显较低。然而，我们表明，有效的图像恢复需要在多级架构中结合两种设计选择。其次，我们表明，天真地将一个阶段的输出传递到下一阶段会产生次优结果[53]。第三，与[88]不同的是，在每个阶段提供地面实况监督对于逐步恢复非常重要。最后，在多阶段处理过程中，需要一种将中间特征从早期阶段传播到后期阶段的机制，以保留编码器-解码器分支的上下文特征。我们提出了一种多阶段渐进式图像恢复架构，称为MPRNet，具有几个关键组件。1)。早期阶段采用编码器-解码器来学习多尺度上下文信息，而最后阶段则对原始图像分辨率进行操作以保留精细的空间细节。2)。每两个阶段之间插入一个监督注意力模块（SAM），以实现渐进式学习。在地面实况图像的指导下，该模块利用前一阶段的预测来计算注意力图，这些注意力图又用于细化前一阶段的特征，然后再传递到下一阶段。3)。添加了跨阶段特征融合（CSFF）机制，有助于将多尺度上下文特征从早期阶段传播到后期。此外，该方法简化了阶段之间的信息流，这有效地稳定了多阶段网络优化。这项工作的主要贡献是：

- 一种新颖的多阶段方法，能够生成上下文丰富且空间准确的输出。由于其多阶段性质，我们的框架将具有挑战性的图像恢复任务分解为子任务，以逐步恢复退化的图像。

- 有效的监督注意力模块，在进一步传播特征之前，在每个阶段充分利用恢复的图像来细化输入特征。

- 跨阶段聚合多尺度特征的策略。

- 我们通过在十个合成和真实世界数据集上设置新的最先进技术，用于各种恢复任务（包括图像去雨、去模糊和去噪），同时保持较低的复杂性，从而证明了MPRNet的有效性（见图1）。此外，我们还提供详细的消融、定性结果和泛化测试。

2.相关工作

近年来，见证了从高端数码单反相机到智能手机相机的范式转变。然而，使用智能手机摄像头捕捉高质量图像具有挑战性。由于相机的限制和/或不利的环境条件，图像中经常出现图像质量下降。早期的恢复方法基于全变分[10, 67]、稀疏编码[3, 51, 52]、自相似性[8, 16]、梯度先验[68, 80]等。最近，

基于CNN的恢复方法已经取得了最先进的结果[57, 70, 86, 93, 97]。就架构设计而言，这些方法可大致分为单阶段和多阶段。

单阶段方法。目前，大多数图像恢复方法都基于单阶段设计，并且架构组件通常基于为高级视觉任务开发的组件。例如，残差学习[30]已被用于执行图像去噪[2, 72, 93]、图像去模糊[42, 43]和图像去雨[37]。类似地，为了提取多尺度信息，通常使用编码器-解码器[65]和扩张卷积[83]模型[4, 28, 43]。其他单阶段方法[5, 89, 97]包含密集连接[34]。

多阶段方法。这些方法[24, 47, 53, 63, 70, 71, 88, 99]旨在通过在每个阶段采用轻量级子网络以渐进的方式恢复干净的图像。这种设计是有效的，因为它将具有挑战性的图像恢复任务分解为更小、更容易的子任务。然而，常见的做法是对每个阶段使用相同的子网络，这可能会产生次优结果，如我们的实验（第4节）所示。

注意力。在图像分类[31, 32, 79]、分割[21, 35]和检测[74, 79]等高级任务中取得成功的推动下，注意力模块已被用于低级视觉任务[38]。例子比比皆是，包括图像去雨[37, 47]、去模糊[61, 70]、超分辨率[17, 95]和去噪[4, 86]的方法。主要思想是捕获沿空间维度[98]、通道维度[32]或两者[79]的远程相互依赖性。

3. 多阶段渐进修复

所提出的图像恢复框架如图1所示。2、分三个阶段逐步恢复图像。前两个阶段基于编码器-解码器子网络，由于接受域较大，该子网络可以学习广泛的上下文信息。由于图像恢复是位置敏感的任务（需要从输入到输出的像素到像素对应），因此最后阶段采用对原始输入图像分辨率进行操作的子网络（无需任何下采样操作），从而预-在最终输出图像中提供所需的精细纹理。我们不是简单地级联多个阶段，而是在每两个阶段之间加入一个监督注意力模块。在地面实况图像的监督下，我们的模块在将前一阶段的特征图传递到下一阶段之前重新缩放它们。此外，我们引入了一种跨阶段特征融合机制，其中早期子网络的中间多尺度上下文特征有助于巩固后面子网络的中间特征。虽然MPRNet堆叠了多个阶段，但每个阶段都有

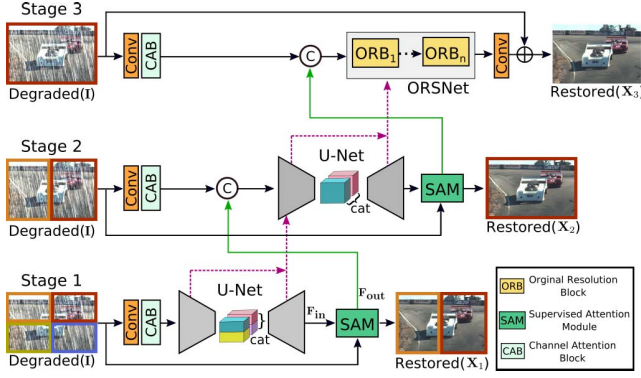


图 2: 建议的渐进式 IM 多级架构

年龄恢复。早期阶段采用编码器解码器来提取多尺度上下文特征，而最后阶段以原始图像分辨率运行以生成空间精确的输出。每两个阶段之间添加一个监督注意力模块，该模块学习细化一个阶段的特征，然后再将其传递到下一阶段。粉色虚线箭头代表跨阶段特征融合机制。

对输入图像的访问。与最近的恢复方法[70, 88]类似，我们在输入图像上采用多补丁层次结构，并将图像分割成不重叠的补丁：四个用于阶段 1，两个用于阶段 2，原始图像用于阶段 1。最后阶段，如图2所示。在任何给定阶段 S ，所提出的模型不是直接预测恢复的图像 X_S ，而是预测残差图像 R_S ，将退化的输入图像 I 添加到其中以获得： $X_S = I + R_S$ 。我们使用以下损失函数端到端优化 MPRNet：

$$\mathcal{L} = \sum_{S=1}^3 [\mathcal{L}_{char}(\mathbf{X}_S, \mathbf{Y}) + \lambda \mathcal{L}_{edge}(\mathbf{X}_S, \mathbf{Y})], \quad (1)$$

其中 \mathbf{Y} 代表真实图像， \mathcal{L}_{char} 是 Charbonnier 损失 [12]：

$$\mathcal{L}_{char} = \sqrt{\|\mathbf{X}_S - \mathbf{Y}\|^2 + \varepsilon^2}, \quad (2)$$

对于所有实验，常数 ε 根据经验设置为 10^{-3} 。另外， \mathcal{L}_{edge} 是边缘损失，定义为：

$$\mathcal{L}_{edge} = \sqrt{\|\Delta(\mathbf{X}_S) - \Delta(\mathbf{Y})\|^2 + \varepsilon^2}, \quad (3)$$

其中 Δ 表示拉普拉斯算子。方程中的参数 λ 。
(1) 控制两个损失项的相对重要性，如[37]中设置为 0.05。接下来，我们描述我们方法的每个关键要素。

3.1. 互补特征处理

现有的用于图像恢复的单级 CNN 通常使用以下架构设计之一：1)。编码器-解码器，或 2)。单尺度特征管道。这

编码器-解码器网络[7,13,43,65]首先逐渐将输入映射到低分辨率表示，然后逐步应用反向映射来恢复原始分辨率。虽然这些模型有效地编码了多尺度信息，但由于重复使用下采样操作，它们很容易牺牲空间细节。相比之下，在单尺度特征管道上运行的方法在生成具有精细空间细节的图像方面是可靠的[6,18,93,97]。然而，由于感受野有限，它们的输出在语义上不太稳健。这表明上述架构设计选择的固有局限性，这些架构设计选择能够生成空间精确或上下文可靠的输出，但不能同时生成两者。为了利用这两种设计的优点，我们提出了一个多阶段框架，其中早期阶段包含编码器-解码器网络，最后阶段采用在原始输入分辨率上运行的网络。

编码器-解码器子网络。图 3a 显示了我们的编码器-解码器子网络，它基于标准 U-Net [65]，具有以下组件。首先，我们添加通道注意块 (CAB) [95]来提取每个尺度的特征 (CAB 见图 3b)。其次，U-Net 跳跃连接处的特征图也使用 CAB 进行处理。最后，我们没有使用转置卷积来提高解码器中特征的空间分辨率，而是使用双线性上采样和卷积层。这有助于减少输出图像中经常因转置卷积而出现的棋盘伪影[55]。

原始分辨率子网。为了保留从输入图像到输出图像的精细细节，我们在最后阶段引入了原始分辨率子网络 (ORSNet) (见图2)。ORSNet 不采用任何下采样操作并生成空间丰富的高分辨率特征。它由多个原始分辨率块 (ORB) 组成，每个 ORB 还包含 CAB。ORB 的示意图如图3b所示。

3.2. 跨阶段特征融合

在我们的框架中，我们在两个编码器-解码器之间 (见图3c) 以及编码器-解码器和 ORSNet 之间引入 CSFF 模块 (见图3d)。请注意，一个阶段的特征首先使用 1×1 卷积进行细化，然后将它们传播到下一阶段进行聚合。拟议的 CSFF 有几个优点。首先，它使网络不易因编码器-解码器中重复使用上采样和下采样操作而导致信息丢失。其次，一个阶段的多尺度特征有助于丰富下一阶段的特征。第三，网络优化过程变得更加稳定，因为它简化了信息流，从而允许我们在整体架构中添加几个阶段。

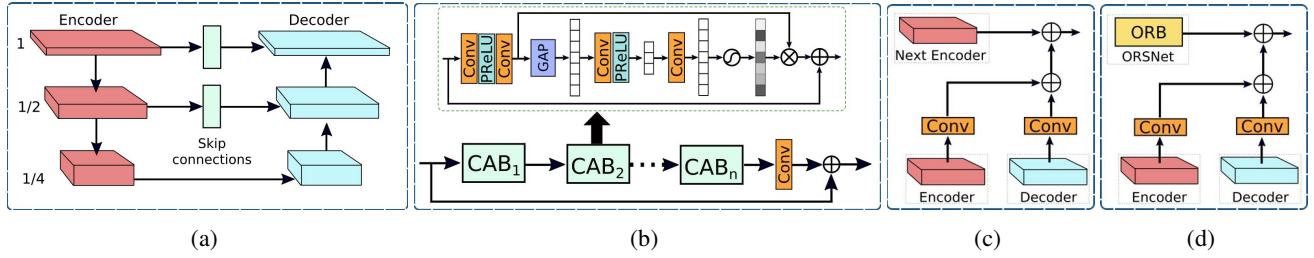


图 3: (a) 编码器-解码器子网络。 (b) ORSNet 子网络中原始解析块 (ORB) 的图示。每个ORB 包含多个通道注意力块。 GAP 代表全局平均池化[49]。 (c) 第 1 阶段和第 2 阶段之间的跨阶段特征融合。 (d) 第 2 阶段和最后阶段之间的 CSFF。




图 4: 监督注意力模块。

3.3.监督注意力模块

最近用于图像恢复的多阶段网络[70,88]直接预测每个阶段的图像，然后将其传递到下一个连续阶段。相反，我们在每两个阶段之间引入一个监督注意力模块，这有助于实现显著的性能增益。SAM的示意图如图4所示，它的贡献有两方面。首先，它提供了对于每个阶段的渐进式图像恢复有用的地面实况监控信号。其次，借助局部监督预测，我们生成注意力图来抑制当前阶段信息量较少的特征，只允许有用的特征传播到下一阶段。如图4所示，SAM将传入的特征 F 早期阶段的 $\varepsilon R \times H \times W \times C$ ，首先通过简单的 1×1 卷积生成残差图像 $R_s \in R \times H \times W \times 3$ ，其中 $H \times W$ 表示空间维度， C 是通道数。将残差图像与劣化的输入图像 I 相加以获得恢复图像 $X_s \in R \times H \times W \times 3$ 。对于这个预测图像 X_s ，我们提供了对真实图像的显式监督。接下来，使用 1×1 卷积和sig-moid激活从图像 X_s 生成每像素注意掩模 $M \in R \times H \times W \times C$ 。然后使用这些掩模重新校准变换后的局部特征 F_{in} （在 1×1 卷积后获得），从而产生添加到身份映射路径中的注意力引导特征。最后，由SAM生成的注意力增强特征表示 F_{out} 被传递到下一阶段进行进一步处理。

4 实验与分析

我们针对多个图像恢复任务评估了我们的方法，包括 (a) 图像去雨、(b) 图像去模糊和 (c) 在 10 个不同数据集上的图像去噪。

4.1.数据集和评估协议

使用 PSNR 和 SSIM [76] 指标进行定量比较。如 [7] 中所述，我们通过将 PSNR 转换为 RMSE ($RMSE \propto \sqrt{10 - PSNR/10}$) 并将 SSIM 转换为 DSSIM ($DSSIM = (1 - SSIM)/2$)。表 1 总结了用于训练和测试的数据集，并在下面进行了描述。

图像去雨。使用与图像去雨的最新最佳方法相同的实验设置[37]，我们在从多个数据集[23,48,81,89,90]收集的13,712个干净的雨图像对上训练我们的模型，如表1所示。经过训练的模型，我们对各种测试集进行评估，包括 Rain100H [81]、Rain100L [81]、Test100 [90]、Test2800 [23] 和 Test1200 [89]。

图像去模糊。与[70,88,43,71]一样，我们使用Go-Pro[53]数据集，其中包含2,103对用于训练的图像对和1,111对用于评估的图像。此外，为了证明通用性，我们采用 GoPro 训练模型并将其直接应用于 HIDE [69] 和 RealBlur [64] 数据集的测试图像。HIDE 数据集是专门为人类感知的运动去模糊而收集的，其测试集包含 2,025 个图像。虽然 GoPro 和 HIDE 数据集是综合生成的，但 RealBlur 数据集的图像对是在现实条件下捕获的。RealBlur 数据集有两个子集：(1) RealBlur-J 由相机 JPEG 输出形成，(2) RealBlur-R 通过对 RAW 图像应用白平衡、去马赛克和去噪操作来离线生成。

图像去噪。为了训练我们的图像去噪任务模型，我们使用 SIDD 数据集 [1] 的 320 张高分辨率图像。对 SIDD 数据集 [1] 中的 1,280 个验证补丁和 DND 基准数据集 [60] 中的 1,000 个补丁进行评估。这些测试补丁是由原始au-从全分辨率图像中提取的

表 1: 各种图像恢复任务的数据集描述。

Tasks	Deraining							Deblurring			Denoising	
Datasets	Rain14000 [23]	Rain1800 [81]	Rain800 [90]	Rain100H [81]	Rain100L [81]	Rain1200 [89]	Rain12 [48]	GoPro [53]	HIDE [69]	RealBlur [64]	SIDD [1]	DND [60]
Train Samples	11200	1800	700	0	0	0	12	2103	0	0	320	0
Test Samples	2800	0	100	100	100	1200	0	1111	2025	1960	40	50
Testset Rename	Test2800	-	Test100	Rain100H	Rain100L	Test1200	-	-	-	-	-	-

表 2: 图像去雨结果。最好成绩和第二好成绩被突出显示并加下划线。对于每种方法，误差相对减少

括号中报告了性能最佳的算法（请参阅第 4.1 节了解误差计算技术）。与之前的最佳方法 MSPFN [37] 相比，我们的 MPRNet 在 PSNR 方面实现了约 20% 的相对改进。

Methods	Test100 [90]		Rain100H [81]		Rain100L [81]		Test2800 [23]		Test1200 [89]		Average	
	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑
DerainNet [22]	22.77	0.810	14.92	0.592	27.03	0.884	24.31	0.861	23.38	0.835	22.48 (69.3%)	0.796 (61.3%)
SEMI [77]	22.35	0.788	16.56	0.486	25.03	0.842	24.43	0.782	26.05	0.822	22.88 (67.8%)	0.744 (69.1%)
DIDMDN [89]	22.56	0.818	17.35	0.524	25.23	0.741	28.13	0.867	29.65	0.901	24.58 (60.9%)	0.770 (65.7%)
UMRL [82]	24.41	0.829	26.01	0.832	29.18	0.923	29.97	0.905	30.55	0.910	28.02 (41.9%)	0.880 (34.2%)
RESCAN [47]	25.00	0.835	26.36	0.786	29.80	0.881	31.29	0.904	30.51	0.882	28.59 (37.9%)	0.857 (44.8%)
PreNet [63]	24.81	0.851	26.77	0.858	<u>32.44</u>	<u>0.950</u>	31.75	0.916	31.36	0.911	29.42 (31.7%)	0.897 (23.3%)
MSPFN [37]	<u>27.50</u>	<u>0.876</u>	<u>28.66</u>	<u>0.860</u>	32.40	0.933	<u>32.82</u>	<u>0.930</u>	32.39	<u>0.916</u>	<u>30.75</u> (20.4%)	<u>0.903</u> (18.6%)
MPRNet (Ours)	30.27	0.897	30.41	0.890	36.40	0.965	33.64	0.938	32.91	0.916	32.73 (0.0%)	0.921 (0.0%)

托斯。SIDD 和 DND 数据集均由真实图像组成。

4.2. 实施细节

我们的 MPRNet 是端到端可训练的，不需要预训练。我们为三个不同的任务训练单独的模型。我们在编码器-解码器的每个尺度上使用 2 个 CAB，对于下采样，我们使用带有 stride2 的 2×2 最大池。在最后阶段，我们使用包含 3 个 ORB 的 ORSNet，每个 ORB 进一步使用 8 个 CAB。根据任务复杂性，我们通过将去雨通道数设置为 40、去噪通道数设置为 80、去模糊通道数设置为 96 来缩放网络宽度。网络在 256×256 个补丁上进行训练，批量大小为 16，进行 4×10^5 次迭代。对于数据增强，随机应用水平和垂直翻转。我们使用 Adam 优化器 [41]，初始学习率为 2×10^{-4} ，使用余弦退火策略 [50] 稳步降低到 1×10^{-6} 。

4.3. 图像去雨结果

对于图像去雨任务，与之前的工作[37]一致，我们使用 Y 通道（在 YCbCr 颜色空间中）计算图像质量分数。表 2 显示，我们的方法通过在所有五个数据集上一致实现更好的 PSNR/SSIM 分数，显著提高了最先进的水平。与最近最好的算法 MSPFN [37] 相比，我们获得了 1.98 dB 的性能增益（所有数据集的平均值），表明误差减少了 20%。某些数据集的改进高达 4 dB，例如 Rain100L [81]。此外，我们的模型的参数比 MSPFN [37] 少 3.7 倍，同时速度快 2.4 倍。图 5 显示了具有挑战性的图像的视觉比较。我们的 MPRNet 可以有效消除雨纹

具有不同的方向和大小，并生成视觉上令人愉悦且忠实于真实情况的图像。相比之下，其他方法会损害结构内容（第一行），引入伪影（第二行），并且不会完全消除雨纹（第三行）。

4.4. 图像去模糊结果

我们在表 3 中报告了在合成 GoPro [53] 和 HIDE [69] 数据集上评估的图像去模糊方法的性能。总体而言，我们的模型相对于其他算法表现良好。与之前表现最好的技术[70]相比，我们的方法在 GoPro[53]数据集上实现了9%的PSNR改进和21%的SSIM改进，并且在HIDE数据集[69]上误差减少了11%和13%。值得注意的是，我们的网络仅在 GoPro 数据集上进行训练，但在 HIDE 数据集上达到了最先进的结果（+0.98 dB），从而展示了其强大的泛化能力。我们在真实的数据集上评估了我们的 MPRNet -最近的 RealBlur [64] 数据集在两个实验设置下的世界图像：1)。将 GoPro 训练的模型直接应用于 Re-alBlur（以测试对真实图像的泛化），以及 2)。对 RealBlur 数据进行训练和测试。表 4 显示了实验结果。对于设置 1，我们的 MPRNet 在 DMPHN 算法 [88] 上在 RealBlur-R 子集上获得了 0.29 dB 的性能增益，在 RealBlur-J 子集上获得了 0.28 dB 的性能增益。在设置 2 中也观察到了类似的趋势，其中我们相对于 SRN [71] 的增益为 RealBlur-R 和 RealBlur-J 上分别为 0.66 dB 和 0.38 dB。图 6 显示了经过评估的一些去模糊图像。总的来说，我们的模型恢复的图像比其他模型恢复的图像更清晰、更接近真实情况。




Figure 5: Image deraining results. Our MPRNet effectively removes rain and generates images that are natural, artifact-free and visually更接近真实情况。

表 3: 去模糊结果。我们的方法仅针对 GoPro 数据集 [53] 并直接应用于 HIDE 数据集 [69]。

Method	GoPro [53]		HIDE [69]	
	PSNR \uparrow	SSIM \uparrow	PSNR \uparrow	SSIM \uparrow
Xu <i>et al.</i> [80]	21.00 (73.9%)	0.741 (84.2%)	-	-
Hyun <i>et al.</i> [36]	23.64 (64.6%)	0.824 (76.7%)	-	-
Whyte <i>et al.</i> [78]	24.60 (60.5%)	0.846 (73.4%)	-	-
Gong <i>et al.</i> [27]	26.40 (51.4%)	0.863 (70.1%)	-	-
DeblurGAN [42]	28.70 (36.6%)	0.858 (71.1%)	24.51 (52.4%)	0.871 (52.7%)
Nah <i>et al.</i> [53]	29.08 (33.8%)	0.914 (52.3%)	25.73 (45.2%)	0.874 (51.6%)
Zhang <i>et al.</i> [91]	29.19 (32.9%)	0.931 (40.6%)	-	-
DeblurGAN-v2 [43]	29.55 (30.1%)	0.934 (37.9%)	26.61 (39.4%)	0.875 (51.2%)
SRN [71]	30.26 (24.1%)	0.934 (37.9%)	28.36 (25.9%)	0.915 (28.2%)
Shen <i>et al.</i> [69]	-	-	28.89 (21.2%)	0.930 (12.9%)
Gao <i>et al.</i> [25]	30.90 (18.3%)	0.935 (36.9%)	29.11 (19.2%)	0.913 (29.9%)
DBGAN [92]	31.10 (16.4%)	0.942 (29.3%)	28.94 (20.8%)	0.915 (28.2%)
MT-RNN [58]	31.15 (16.0%)	0.945 (25.5%)	29.15 (18.8%)	0.918 (25.6%)
DMPHN [88]	31.20 (15.5%)	0.940 (31.7%)	29.09 (19.4%)	0.924 (19.7%)
Suin <i>et al.</i> [70]	31.85 (8.9%)	0.948 (21.2%)	29.98 (10.7%)	0.930 (12.9%)
MPRNet (Ours)	32.66 (0.0%)	0.959 (0.0%)	30.96 (0.0%)	0.939 (0.0%)

4.5. 图像去噪结果

在表 5 中，我们报告了 SIDD [1] 和 DND [60] 数据集上几种图像去噪方法的 PSNR/SSIM 分数。我们的方法比最先进的方法获得了相当大的增益，即在 SIDD 上比 CycleISP [86] 提高了 0.19 dB，在 DND 上比 SADNet [11] 提高了 0.21 dB。请注意，DND 数据集不包含任何训练图像，即完整的公开发布的数据集只是一个测试集。前任-

表 4: RealBlur 数据集 [64] 上的去模糊比较

der 两种不同的设置：1)。将我们的 GoPro 训练模型直接应用于 RealBlur 集（以评估对真实图像的泛化），2)。对 RealBlur 数据进行训练和测试，其中方法用符号 ‡ 表示。其他评估方法的 PSNR/SSIM 分数取自 RealBlur 基准 [64]。

Method	RealBlur-R		RealBlur-J	
	PSNR \uparrow	SSIM \uparrow	PSNR \uparrow	SSIM \uparrow
Hu <i>et al.</i> [33]	33.67 (23.4%)	0.916 (42.9%)	26.41 (23.2%)	0.803 (35.5%)
Nah <i>et al.</i> [53]	32.51 (33.0%)	0.841 (69.8%)	27.87 (9.1%)	0.827 (26.6%)
DeblurGAN [42]	33.79 (22.4%)	0.903 (50.5%)	27.97 (8.1%)	0.834 (23.5%)
Pan <i>et al.</i> [56]	34.01 (20.4%)	0.916 (42.9%)	27.22 (15.7%)	0.790 (39.5%)
Xu <i>et al.</i> [80]	34.46 (16.2%)	0.937 (23.8%)	27.14 (16.4%)	0.830 (25.3%)
DeblurGAN-v2 [43]	35.26 (8.1%)	0.944 (14.3%)	28.70 (0.0%)	0.866 (5.2%)
Zhang <i>et al.</i> [91]	35.48 (5.7%)	0.947 (9.4%)	27.80 (9.8%)	0.847 (17.0%)
SRN [71]	35.66 (3.7%)	0.947 (9.4%)	28.56 (1.6%)	0.867 (4.5%)
DMPHN [88]	35.70 (3.3%)	0.948 (7.7%)	28.42 (3.2%)	0.860 (9.3%)
MPRNet (Ours)	35.99 (0.0%)	0.952 (0.0%)	28.70 (0.0%)	0.873 (0.0%)
‡DeblurGAN-v2 [43]	36.44 (28.1%)	0.935 (56.9%)	29.69 (21.2%)	0.870 (40.0%)
‡SRN [71]	38.65 (7.3%)	0.965 (20.0%)	31.38 (4.3%)	0.909 (14.3%)
‡MPRNet (Ours)	39.31 (0.0%)	0.972 (0.0%)	31.76 (0.0%)	0.922 (0.0%)

使用我们的 SIDD 训练模型在 DND 基准上的实验结果表明，我们的模型可以很好地推广到不同的图像域。图7示出了视觉结果。我们的方法能够消除真实噪声，同时保留结构和纹理图像细节。相比之下，其他方法恢复的图像要么包含过于平滑的内容，要么包含具有斑点纹理的伪影。

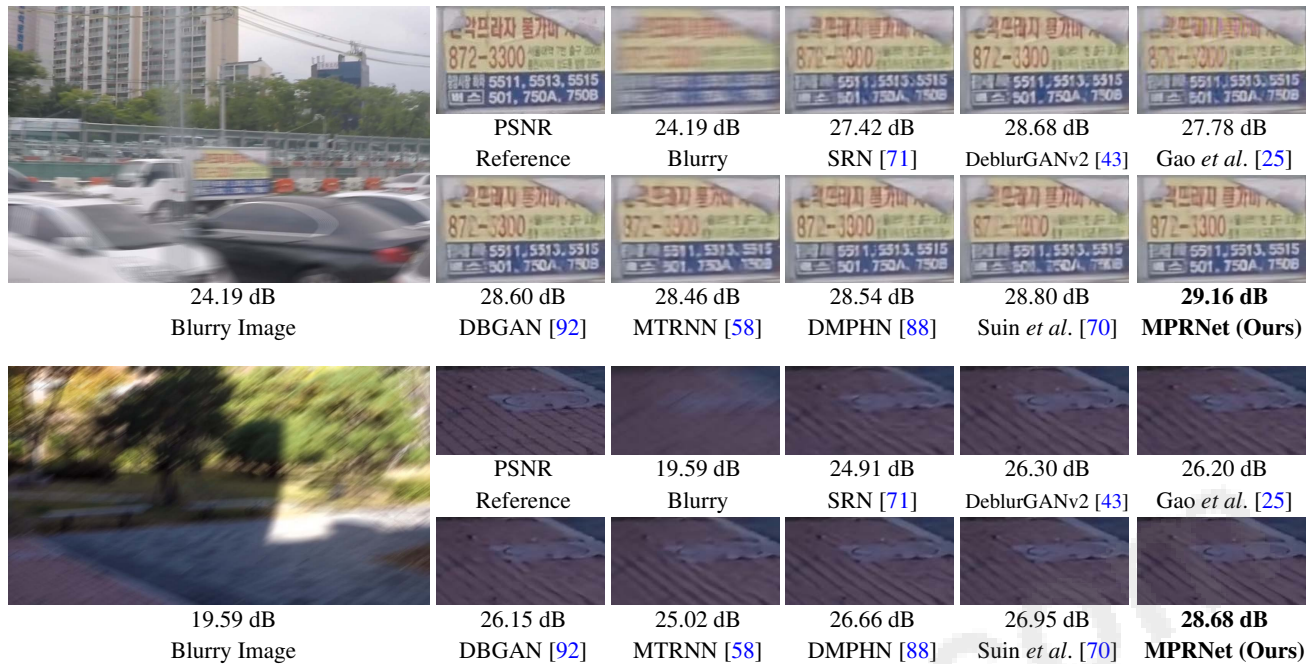


图 6: GoPro 数据集上图像去模糊的视觉比较 [53]。与最先进的方法相比，我们的 MPRNet 恢复更清晰、更忠实于感知的图像。

表 5: SIDD [1] 和 DND [60] 的去噪比较

数据集。* 表示使用额外训练数据的方法。而我们的 MPRNet 仅在 SIDD 图像上进行训练并直接在 DND 上进行测试。

Method	SIDD [1]		DND [60]	
	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑
DnCNN [93]	23.66 (84.2%)	0.583 (89.9%)	32.43 (57.2%)	0.790 (79.1%)
MLP [9]	24.71 (82.2%)	0.641 (88.3%)	34.23 (47.3%)	0.833 (73.7%)
BM3D [16]	25.65 (80.2%)	0.685 (86.7%)	34.51 (45.6%)	0.851 (70.5%)
CBDNet* [28]	30.78 (64.2%)	0.801 (78.9%)	38.06 (18.2%)	0.942 (24.1%)
RIDNet* [4]	38.71 (10.9%)	0.951 (14.3%)	39.26 (6.0%)	0.953 (6.4%)
AINDNet* [40]	38.95 (8.4%)	0.952 (12.5%)	39.37 (4.8%)	0.951 (10.2%)
VDN [84]	39.28 (4.8%)	0.956 (4.6%)	39.38 (4.7%)	0.952 (8.3%)
SADNet* [11]	39.46 (2.8%)	0.957 (2.3%)	39.59 (2.4%)	0.952 (8.3%)
DANet* [85]	39.47 (2.7%)	0.957 (2.3%)	39.58 (2.5%)	0.955 (2.2%)
CycleISP* [86]	39.52 (2.2%)	0.957 (2.3%)	39.56 (2.7%)	0.956 (0.0%)
MPRNet (Ours)	39.71 (0.0%)	0.958 (0.0%)	39.80 (0.0%)	0.954 (4.4%)

4.6.消融研究

在这里，我们提出了消融实验来分析我们的评估的每个组成部分的贡献，该实验是在 GoPro 数据集 [53] 上进行的，使用在大小为 128×128 的图像块上训练 10 5 次迭代的去模糊模型，结果如表 6 所示。随着阶段数量的增加，我们的模型产生了更好的性能，这验证了我们多阶段设计的有效性。子网络的选择。由于我们模型的每个阶段都可以采用不同的子网设计，因此我们测试了不同的选项。我们表明，在早期阶段使用编码器-解码器并在最后阶段使用 ORSNet 会导致 im-

表 6: 对拟议 MPRNet 各个组件的消融研究。

#Stages	Stage Combination	SAM	CSFF	PSNR
1	U-Net (baseline)	-	-	28.94
1	ORSNet (baseline)	-	-	28.91
2	U-Net + U-Net	✗	✗	29.40
2	ORSNet + ORSNet	✗	✗	29.53
2	U-Net + ORSNet	✗	✗	29.70
3	U-Nets + ORSNet	✗	✗	29.86
3	U-Nets + ORSNet	✗	✓	30.07
3	U-Nets + ORSNet	✓	✗	30.31
3	U-Nets + ORSNet	✓	✓	30.49

与所有阶段采用相同设计 (U-Net+U-Net 为 29.4 dB, ORSNet+ORSNet 为 29.53 dB) 相比，SAM 和 CSFF 的性能得到了验证 (29.7 dB)。我们通过从最终模型中删除所提出的监督注意力模块和跨阶段特征融合机制来证明它们的有效性。表 6 显示，当移除 SAM 时，PSNR 从 30.49 dB 大幅下降至 30.07 dB，当我们去除 CSFF 时，PSNR 从 30.49 dB 大幅下降至 30.31 dB。删除这两个组件会使性能大幅下降，从 30.49 dB 降至 29.86 dB。

5. 资源高效的图像恢复

CNN 模型通常表现出准确性和计算效率之间的权衡。为了追求更高的精度，通常会开发更深层次和复杂的模型。尽管大型模型往往比小型模型表现得更好，但计算成本可能会降低




图 7: 图像去噪比较。第一个例子来自 DND [60], 其他例子来自 SIDD [1]。提出的MPRNet更好保留去噪图像中的精细纹理和结构图案。

表 7: MPRNet 在 Go 上的阶段式去模糊性能专业[53]。运行时间是使用 Nvidia Titan Xp GPU 计算的。

Method	DeblurGAN-v2 [43]	SRN [71]	DMPHN [88]	Suin <i>et al.</i> [70]	MPRNet (ours)		
					1-stage	2-stages	3-stages
PSNR	29.55	30.10	31.20	31.85	30.43	31.81	32.66
#Params (M)	60.9	6.8	21.7	23.0	5.6	11.3	20.1
Time (s)	0.21	0.57	1.07	0.34	0.04	0.08	0.18

高得令人望而却步。因此, 开发资源高效的图像恢复模型非常有意义。一种解决方案是每次目标系统发生变化时调整其容量来训练同一网络。然而, 这是乏味的并且常常是不可行的。更理想的方法是拥有一个单一网络, 该网络可以 (a) 对计算高效系统进行早期预测, 以及 (b) 后期预测以获得高精度。多阶段恢复模型自然提供了这样的功能。表 7 报告了我们多阶段方法的阶段结果。我们的 MPRNet 在每个阶段都展现出有竞争力的恢复性能。值得注意的是, 我们的第一阶段模型轻量、快速, 并且比 SRN [71] 和 DeblurGAN-v2 [43] 等其他复杂算法产生更好的结果。同样, 与最近的方法 DM-PHN [88] 相比, 我们的第 2 阶段模型显示 PSNR 增益为 0.51

dB, 同时资源效率更高 (参数减少约 2 倍, 速度提高 13 倍)。

六, 结论

在这项工作中, 我们提出了一种用于图像恢复的多阶段架构, 通过在每个阶段注入监督来逐步改善退化的输入。我们为我们的设计制定了指导原则, 要求在多个阶段进行互补的特征处理以及它们之间灵活的信息交换。为此, 我们提出了上下文丰富且空间准确的阶段, 可以统一编码一组不同的特征。为了确保相互阶段之间的协同作用, 我们提出跨阶段的特征融合以及从早期阶段到后期阶段的注意力引导输出交换。我们的模型在众多基准数据集上取得了显著的性能提升。此外, 我们的模型在模型大小方面是轻量级的, 在运行时方面是高效的, 这对于资源有限的设备来说非常有趣。

致谢。M.-H. Yang 得到了 NSF CAREER Grant 1149783 的部分支持。特别感谢 Kui Jiang 提供的图像去雨结果。

References

- [1] 阿卜杜勒拉赫曼·阿卜杜勒哈迈德、斯蒂芬·林和迈克尔·S布朗。适用于智能手机相机的高质量去噪数据集。CVPR, 2018年。4,5,6,7,8[2] Abdelrahman Abdelhamed、Radu Timofte 和 Michael S Brown。NTIRE 2019 真实图像去噪挑战：方法和结果。CVPRW, 2019年。2[3] Michal Aharon、Michael Elad 和 Alfred Bruckstein。K-SVD：一种用于设计稀疏表示的超完备字典的算法。跨。签名。Proc., 2006年。2[4] 赛义德·安瓦尔和尼克·巴恩斯。具有特征注意力的真实图像去噪。ICCV, 2019。1,2,7,8[5] 赛义德·安瓦尔和尼克·巴恩斯。密集残差拉普拉斯超分辨率。TPAMI, 2020。2[6] Saeed Anwar、Salman Khan 和 Nick Barnes。超分辨率深度之旅：一项调查。ACM 计算调查, 2019年。3[7] Tim Brooks、Ben Mildenhall、Tianfan Xu、Jiawen Chen、Dillon Sharlet 和 Jonathan T Barron。未处理图像以进行学习的原始去噪。CVPR, 2019年。1,3,4[8] Antoni Buades、Bartomeu Coll 和 J-M Morel。一种图像去噪的非局部算法。CVPR, 2005年。2[9] Harold C Burger、Christian J Schuler 和 Stefan Harmeling。图像去噪：普通神经网络可以与 BM3D 竞争吗？CVPR, 2012年。7[10] Tony F Chan 和 Chiu-Kwong Wong。总变分盲解卷积。TIP, 1998。2[11] 常孟, 李奇, 冯华军, 徐志海。用于单图像去噪的空间自适应网络。在 ECCV, 2020年。6, 7, 8[12] Pierre Charbonnier、Laure Blanc-Feraud、Gilles Aubert 和 Michel Barlaud。用于计算成像的两种确定性半二次正则化算法。ICIP, 1994.3[13] 陈晨, 陈启峰, 徐嘉, Vladlen Koltun。学习在黑暗中看东西。CVPR, 2018. 1, 3[14] 陈一伦, 王志成, 彭宇翔, 张志强, 余刚, 孙健。用于多人姿势估计的级联金字塔网络。CVPR, 2018。1[15] Bowen Cheng、Liang-Chieh Chen、Yunchao Wei、Yukun Zhu、Zillong Huang、Jinjun Xiong、Thomas S Huang、Wen-Mei Hwu 和 Honghui Shi。SPGNet：场景解析的语义预测指南。ICCV, 2019年。1[16] Kostadin Dabov、Alessandro Foi、Vladimir Katkovnik 和 Karen Egiazarian。通过稀疏 3-D 变换域协同过滤进行图像去噪。TIP, 2007. 2, 7, 8 [17] 戴涛, 蔡建瑞, 张永兵, 夏树涛, 张雷。用于单图像超分辨率的二阶注意网络。CVPR, 2019. 1, 2[18] Chao Dong, Chen Change Loy, Kaiming He, Xiaoou Tang。使用深度卷积网络的图像超分辨率。TPAMI, 2015. 3[19] 董伟胜, 张雷, 石光明, 吴晓林。通过自适应稀疏域选择和自适应正则化进行图像去模糊和超分辨率。提示, 2011。1
- [20] 亚赞·阿布·法哈和尤尔根·加尔。MS-TCN：用于动作分割的多级时间卷积网络。In CVPR, 2019. 1[21] 付军, 刘静, 田海杰, 李勇, 包勇军, 方志伟, 陆汉清。双注意力网络用于场景分割。CVPR, 2019。2[22] 付雪阳, 黄家斌, 丁星浩, 廖英浩, 约翰·佩斯利。清理天空：用于单图像除雨的深层网络架构。TIP, 2017. 5, 6[23] 付雪阳, 黄家斌, 曾德禄, 黄悦, 丁兴浩, John Paisley。通过深度细节网络从单幅图像中去除雨水。CVPR, 2017. 4, 5[24] 付雪阳, 梁博荣, 黄悦, 丁星浩, John Paisley。用于图像去雨的轻量级金字塔网络。TNNLS, 2019. 2[25] 高红运, 陶鑫, 沉晓勇, 贾佳雅。通过参数选择性共享和嵌套跳过连接进行动态场景去模糊。In CVPR, 2019. 6, 7[26] Pallabi Ghosh, Yi Yao, Larry Davis, and Ajay Divakaran。用于动作分割的堆叠时空图卷积网络。WACV, 2020. 1[27] 龚东, 杨杰, 刘灵巧, 张彦宁, Ian Reid, 沉春华, Anton Van Den Hengel, 石勤峰。从运动模糊到运动流：消除异构运动模糊的深度学习解决方案。2017年 CVPR。6[28] 郭石, 严子飞, 张凯, 左王猛, 张雷。对真实照片进行卷积盲去噪。CVPR, 2019. 2, 7, 8[29] 何凯明, 孙健, 唐晓鸥。使用暗通道先验的单图像去雾。TPAMI, 2010. 1[30] 何凯明, 张翔宇, 任少清, 孙健。图像识别中的深度残差学习。在 CVPR, 2016年。2[31] 胡杰, 沉力, 塞缪尔·阿尔巴尼, 孙刚, Andrea Vedaldi。收集-激发：利用卷积神经网络中的特征上下文。见 NeurIPS, 2018。2[32] 胡杰, 沉力, Samuel Albanie, 孙刚, 吴恩华。挤压和激励网络。IEEE TPAMI, 2019.2[33] Zhe Hu, Sunghyun Cho, Jue Wang, 和 Ming-Hsuan Yang。用光条纹去模糊低光图像。在 CVPR, 2014年。6[34] 高晃, 刘庄, Laurens Van Der Maaten, Kilian Q Weinberger。密集连接的卷积网络。CVPR, 2017。2[35] 黄子龙, 王兴刚, 黄立超, 长黄, 魏云超, 刘文字。CCNet：用于语义分割的交叉交叉注意力。ICCV, 2019。2[36] Tae Hyun Kim、Byeongjoo Ahn 和 Kyoung Mu Lee。动态场景去模糊。ICCV, 2013。6[37] 蒋奎, 王中远, 易鹏, 黄保金, 罗益民, 马佳一, 蒋军军。用于单图像去雨的多尺度渐进融合网络。In CVPR, 2020. 2, 3, 4, 5, 6[38] Salman Khan、Muzammal Naseer、Munawar Hayat、Syed Waqas Zamir、Fahad Shahbaz Khan 和 Mubarak

沙阿。愿景中的变形金刚：一项调查。arXiv: 2101.01169, 2021。2[39] Kwang In Kim 和 Younghee Kwon。使用稀疏回归和自然图像先验的单图像超分辨率。TPAMI, 2010。1[40] Yoonsik Kim, Jae Woong Soh, Gu Yong Park, 和 Nam IkCho。通过自适应实例归一化从合成噪声去噪到真实噪声去噪的迁移学习。CVPR, 2020.7, 8[41] Diederik P Kingma 和 Jimmy Ba。Adam: 一种随机优化方法。arXiv:1412.6980, 2014。5[42] Orest Kupyn, Volodymyr Budzan, Mykola Mykhailych, Dmytro Mishkin 和 Jiří Matas。DeblurGAN: 使用条件对抗网络进行盲运动去模糊。见CVPR, 2018。2, 6[43] Orest Kupyn, Tetiana Martyniuk, Junru Wu, 和 Zhangyang Wang。DeblurGAN-v2: 更快更好的去模糊(数量级)。ICCV, 2019。1,2,3,4,6,7,8[44] Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Ca-ballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang 等人使用生成对抗网络实现逼真的单图像超分辨率。CVPR, 2017。1[45]李世杰, Yazan AbuFarha, 刘云, 程明明, Juergen Gall。MS-TCN++: 用于动作的多阶段时间卷积网络 TPAMI, 2020.1[46] 李文波, 王志成, 尹斌一, 彭其翔, 杜玉英, 肖天子, 于刚, 卢洪涛, 魏一辰, and 孙健.重新思考用于人体姿态估计的多级网络。arXiv:1901.00148, 2019。1[47] 李夏, 吴建龙, 林周辰, 刘红, 查宏斌。用于单图像去雨的循环挤压和激励上下文聚合网络。ECCV, 2018。1, 2,5, 6[48] Yu Li, Robby T Tan, XiaojieGuo, Jiangbo Lu, and Michael S Brown。使用层先验去除雨条纹。In CVPR, 2016。4, 5[49] Wei Liu, Andrew Rabinovich, and Alexander C Berg。ParseNet: 看得更广, 看得更清楚。arXiv: 1506.04579, 2015。4[50] 伊利亚·洛希洛夫和弗兰克·哈特。SGDR: 带有热重启的随机梯度下降。ICLR, 2017。5[51] 罗宇, 徐勇, 吉慧。通过判别性稀疏编码从单个图像中去除雨水。ICCV, 2015 年。2[52] Julien Mairal, Michael Elad 和 Guillermo Sapiro。彩色图像恢复的稀疏表示。TIP, 2007。2[53] Seungjun Nah, Tae Hyun Kim 和 Kyoung Mu Lee。用于动态场景去模糊的深度多尺度卷积神经网络。CVPR, 2017。1, 2, 4, 5, 6, 7, 8[54] Alejandro Newell, Kaiyu Yang, Jia Deng。用于人体姿势估计的堆叠沙漏网络。在 ECCV, 2016 年。1[55] 奥古斯都·奥德纳、文森特·杜穆兰和克里斯·奥拉。反卷积和棋盘伪影。蒸馏, 2016。3

[56] 潘金山, 孙德庆, 汉斯彼得·普菲斯特, 杨明轩。使用暗通道先验进行盲图像去模糊。CVPR, 2016。6[57]潘新刚, 詹晓航, 戴波, 林大华, 陈变洛, 罗平。利用深度生成先验进行多功能图像恢复和操作。In ECCV, 2020。1, 2[58] Dongwon Park, Dong Un Kang, Jisoo Kim, and Se YoungChun。通过增量时间训练进行渐进非均匀单图像去模糊的多时态循环神经网络。ECCV, 2020。6, 7[59] Pietro Perona 和 Jitendra Malik。使用各向异性扩散进行尺度空间和边缘检测。TPAMI, 1990。1[60]托比亚斯·普洛茨和斯特凡·罗斯。用真实照片对去噪算法进行基准测试。CVPR, 2017。4,5,6,7,8[61] Kuldeep Purohit 和 AN Rajagopalan。用于高效运动去模糊的区域自适应密集网络。在 AAAI, 2020 年。2[62] 钱瑞, 谭涛, 杨文瀚, 苏家俊, 刘家英。专注的生成对抗网络, 用于从单个图像中去除雨滴。CVPR, 2018。1[63]任东伟, 左王猛, 胡清华, 朱鹏飞, 孟德宇。渐进式图像去雨网络: 更好、更简单的基线。CVPR, 2019。1, 2, 5, 6[64] Jaesung Rim, Haeyun Lee, Jucheol Won, and SunghyunCho。用于学习和基准去模糊算法的真实模糊数据集。ECCV, 2020 年。4,5,6[65] Olaf Ronneberger, Philipp Fischer 和 Thomas Brox。U-Net: 用于生物医学图像分割的卷积网络。摘自 MICCAI, 2015 年。1,2,3[66] Stefan Roth 和 Michael J Black。专家领域: 学习图像先验的框架。CVPR, 2005 年。1[67] Leonid I Rudin, Stanley Osher 和 Emad Fatemi。基于非线性全变分的噪声消除算法。PhysicaD: 非线性现象, 1992。1, 2 [68] 齐山, 贾亚亚, Aseem Agarwala。对单个图像进行高质量运动去模糊。ToG, 2008。2[69] 沉子一, 王文官, 陆贤凯, 沉建兵, 凌海滨, 徐廷发, 邵凌。人类感知的运动去模糊。ICCV, 2019。4,5,6[70] Maitreya Suin, Kuldeep Purohit 和 A. N. Rajagopalan。用于自适应运动去模糊的空间注意力补丁分层网络。CVPR, 2020。1, 2, 3, 4, 5, 6, 7, 8[71] 陶鑫, 高红云, 沉晓勇, 王珏, 贾吉亚。用于深度图像去模糊的尺度循环网络。In CVPR, 2018。1, 2, 4, 5, 6, 7, 8[72] Chunwei Tian, Lunke Fei, Wenxian Cheng, Yong Xu, Wangmeng Zuo, and Chia-Wen Lin。图像去噪的深度学习: 概述。神经网络, 2020。2[73]童童, 李根, 刘协杰, 高勤泉。使用密集跳跃连接的图像超分辨率。在ICCV, 2017。1[74] 王晓龙, Ross Girshick, Abhinav Gupta, 和 Kaim-ing He。非局部神经网络。CVPR, 2018。2[75] 王新涛, 余柯, 吴世翔, 谷金金, 刘一豪, 董超, 乔宇, 陈变洛。埃斯甘:

增强型超分辨率生成对抗网络。In ECCVW, 2018. 1[76] Zhou Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli. 图像质量评估: 从错误可见性到结构相似性。TIP, 2004. 4[77] 魏伟, 孟德宇, 赵谦, 徐宗本, 吴英。用于图像除雨的半监督迁移学习。CVPR, 2019. 5, 6[78] Oliver Whyte, Josef Sivic, Andrew Zisserman 和 Jean Ponce。对抖动图像进行非均匀去模糊。国际JCV, 2012. 6[79] Sanghyun Woo, Jongchan Park, Joon-Young Lee 和 InSo Kweon。Cbam: 卷积块注意力模块。In ECCV, 2018. 2[80] Li Xu, Shi Cheng Cheng, Jiaya Jia。用于自然图像去模糊的非自然 10 稀疏表示。在 CVPR, 2013 年。2, 6[81] 杨文瀚, 谭涛, 冯嘉实, 刘嘉英, 郭宗明, 严水成。单幅图像的深度学习联合降雨检测和去除。CVPR, 2017.1,4,5[82] Rajeev Yasarla 和 Vishal M Patel。不确定性引导的多尺度残差学习——使用循环旋转CNN进行单图像去雨。CVPR, 2019. 5, 6[83] Fisher Yu 和 Vladlen Koltun。通过扩张卷积进行多尺度上下文聚合。ICLR, 2016. 2[84] 岳宗胜, 勇宏伟, 赵谦, 孟德宇, 张雷。变分去噪网络: 走向盲噪声建模去除。In NeurIPS, 2019. 7,8[85] 岳宗盛, 赵谦, 张磊, 孟德宇。双对抗网络: 走向现实世界的噪声去除和噪声生成。ECCV, 2020. 7, 8[86] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang 和 Ling Shao。CycleISP: 通过改进的数据合成恢复真实图像。CVPR, 2020. 1,2,6,7,8[87] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang 和 Ling Shao。学习丰富的特征以实现真实图像的恢复和增强。ECCV, 2020. 1[88] 张红光, 戴玉超, 李红东, Piotr Koniusz。用于图像去模糊的深堆叠分层多补丁网络。CVPR, 2019. 1, 2, 3, 4, 5, 6, 7, 8[89] He Zhu 和 Vishal M Patel。使用多流密集网络进行密度感知的单图像除雨。2018 年 CVPR。2,4,5,6[90] 张赫, Vishwanath Sindagi, Vishal M Patel。使用条件生成对抗网络进行图像去雨。TCSVT, 2019. 1, 4, 5[91] 张嘉伟, 潘金山, 任志明, 宋一兵, 包林超, 刘伟豪, 杨明轩。使用空间变异循环神经网络进行动态场景去模糊。CVPR, 2018. 1, 6[92] 张凯浩, 罗文瀚, 钟怡然, 马琳, Bjorn Stenger, 刘伟, 李洪东。通过真实模糊来去模糊。CVPR, 2020.1,6,7

[93] 张凯, 佐王猛, 陈云金, 孟德宇, 张雷。超越高斯降噪器: 用于图像降噪的深度CNN残差学习。TIP, 2017. 1, 2, 3, 7[94] 张凯, 左王猛, 谷书航, 张磊。学习深度CNN去噪先验进行图像恢复。In CVPR, 2017. 1[95] 张玉伦, 李鲲鹏, 李凯, 王力辰, 钟必能, 付云。使用非常深的残差通道注意力网络进行图像超分辨率。ECCV, 2018.1,2,3[96] 张玉伦, 李鲲鹏, 李凯, 钟必能, 付云。用于图像恢复的剩余非局部注意力网络。ICLR, 2019. 1[97] 张玉伦, 田亚鹏, 孔宇, 钟必能, 付云。用于图像恢复的残差密集网络。TPAMI, 2020. 1, 2, 3[98] 赵恒双, 张毅, 刘书, 施建平, 陈昌洛, 林大华, 贾佳亚。Psanet: 用于场景解析的逐点空间注意力网络。ECCV, 2018.2[99] 郑宇培, 于欣, 刘淼淼, 张顺利。基于残差多尺度的单幅图像去雨。In BMVC, 2019. 2[100] 宋纯朱, David Mumford。先前的学习和吉布斯反应扩散。TPAMI, 1997. 1