

具有散射效果的屏下摄像头图像修复

宋彬彬¹、陈翔宇^{1,2}、徐书宁¹、周建涛¹ †¹智慧城市物联网国家重点实验室澳门大学计算机与信息科学系²中国科学院深圳先进技术研究院

{yb97426, jtzhou}@umac.mo, {chxy95, rebeccaxu0418}@gmail.com

Abstract

屏下摄像头 (UDC) 为消费者提供全屏视觉体验，不会因凹口或打孔而受到任何阻碍。然而，显示器的半透明特性不可避免地会给 UDC 图像带来严重的退化。在这项工作中，我们通过具体考虑显示器引起的散射效应来解决 UDC 图像恢复问题。我们通过将显示器视为一块均匀的散射介质来明确地建模散射效应。利用散射效应的物理模型，我们改进了图像合成的图像形成管道，以构建具有地面事实的真实 UDC 数据集。为了抑制最终 UDC 图像恢复的散射效应，设计了一个两分支恢复网络。更具体地说，散射分支利用通道自注意力的全局建模功能来估计退化图像的散射效应参数。而图像分支则利用 CNN 的局部表示优势来恢复清晰的场景，并由散射分支隐式引导。对现实世界和合成数据进行了大量的实验，证明了所提出的方法相对于最先进的 UDC 恢复技术的优越性。源代码和数据集可在 <https://github.com/NamecantbeNULL/SRUDC> 获取。

一、简介

作为避免屏幕上凹口和打孔带来的解决方案，屏下摄像头 (UDC) 的采用越来越受欢迎。这样的设计满足了人们对全屏手持设备日益增长的需求，提升了消费者的视觉体验。然而，显示屏的半透明性质覆盖了



图 1. 真实场景图像上的 UDC 图像恢复示例。(a) 退化的 UDC 图像, (b-e) 不考虑散射效应的最先进方法的输出, (f) 我们的结果, 能够消除雾度和对比度失真, 同时恢复精细细节。 (放大以获得更好的视图。)

相机不可避免地会在捕获的 UDC 图像中引入各种类型的退化，例如对比度失真、模糊、模糊、噪声和光源周围的衍射伪影。为了缓解这些问题，近年来快速发展的 UDC 图像恢复方法 [42, 6, 14, 11, 8, 21, 43, 12, 4, 31, 7, 5] 致力于恢复退化图像。这些方法大多数集中于高频分量的退化，例如模糊环、噪声和衍射伪影，而简单地将低频分量的退化建模为像素强度衰减。然而，显示器的散射效应可能会导致诸如 con-

† 通讯作者。

对比度失真和模糊，在以前的UDC恢复方法中一直被忽略。这种疏忽可能会严重限制现有方法在真实场景图像上的恢复性能和泛化。本质上，散射效应是 UDC 成像系统中的常见现象 [26]。当入射光进入显示器时，它会穿过多个堆叠层，例如阴极、基板等，然后到达相机传感器。在此过程中，与这些层内的小粒子的碰撞改变了一些光子的传播方向。因此，入射辐射的总能量被抑制，部分光转化为散射光，从而产生对比度畸变和雾度。由于散射效应导致的这些类型的退化不仅影响捕获的 UDC 图像的视觉质量，而且当 UDC 图像作为输入时，还可能导致高级视觉系统失败。令人惊讶的是，据我们所知，UDC 图像恢复任务中尚未明确解决散射效应。一方面，由于散射效应，现实世界和现有数据合成管道生成的合成 UDC 图像之间存在差距。另一方面，恢复方法需要针对 UDC 图像中散射引起的退化进行特殊设计。这两个原因促使我们考虑散射效应，以更好地恢复捕获的 UDC 图像。在这项工作中，我们通过将相机接收到的辐照度分解为透射分量和散射分量并分别计算来对 UDC 散射效应进行建模。基于提出的 UDC 散射模型，我们增强了现有的图像形成管道 (IFP)，以生成具有配对地面事实的真实 UDC 图像。我们表明，与现有的 IFP 相比，我们的增强方法生成的合成 UDC 图像更接近真实捕获的图像。为了恢复具有散射效应的UDC图像，我们提出了一个由散射分支和图像分支组成的双分支深度网络。散射分支估计退化图像的散射效应参数，而图像分支则在散射分支的引导下恢复清晰的场景。在散射分支中，我们提出转置自注意力块 (TSAB) 来利用通道自注意力 (CSA) 的全局建模能力[37, 32]。在图像分支中，我们使用卷积神经网络 (CNN) 作为骨干来利用其局部表示优势[29, 3]。为了有效地结合来自两个分支的信息，我们设计了一个特征融合模块，它利用来自散射分支的全局信息自适应地调制深层特征。图1展示了在真实场景图像上进行UDC图像恢复的示例。总而言之，我们的贡献如下：

· 我们提出了一种新的 UDC 成像模型，明确考虑了散射效应，这会导致未执行

预期的模糊和对比度失真。然后增强图像形成管道，生成更真实的 UDC 合成图像。· 在提出的具有散射效应的 UDC 成像模型的指导下，我们专门设计了一个双分支深度框架，该框架利用了 CSA 和 CSA 的全局建模能力CNN 的局部表示优势，用于恢复 UDC 图像。· 大量实验表明，在现实世界和合成数据上都有显着的性能提升。与最先进的方法相比，生成图像的视觉质量是显着改善。

2. 相关作品

在本节中，我们首先简要介绍与UDC图像退化过程建模相关的工作。然后回顾了最近开发的UDC图像恢复方法。

2.1. UDC成像建模

许多先前的工作[42,6,11,13,14,23]已经研究了UDC成像的退化。Zhou等人[42]首先用经典卷积模型将UDC成像过程表述为：

$$\mathbf{I} = \gamma(\mathbf{B} * \mathbf{k}) + \mathbf{n}, \quad (1)$$

其中 \mathbf{B} 表示干净的场景图像， \mathbf{I} 表示降级的图像。这里， \mathbf{k} 是点扩散函数 (PSF)， \mathbf{n} 是零均值噪声， γ 是强度缩放因子， $*$ 表示卷积算子。然而，在有限的动态范围内直接使用该模型可以抑制饱和区域周围的衍射伪影。为了更接近真实世界的数据，Feng 等人[6]建议将卷积迁移到具有高动态范围的 RAW 域，并在智能手机中测量 UDC 的实际 PSF 以进行数据合成。权等人[14]进一步考虑由于光的入射角引起的PSF的空间变化。为了模拟低空间频率的复杂形式的退化，Koh等人。[11]利用3D变换来替代单个缩放因子 γ 。尽管上述工作改进了UDC退化模型，但是具有单个 γ 的卷积模型不能产生广泛观察到的由UDC散射引起的对比度失真和模糊这种现象促使我们专门对 UDC 成像中的光散射过程进行建模。

2.2. UDC恢复方法

[42]中提出了基于U-Net的开创性UDC图像恢复方法，作为盲反卷积解决方案。为了处理饱和区域中不同的PSF，Feng等人[6]设计动态跳过连接网络

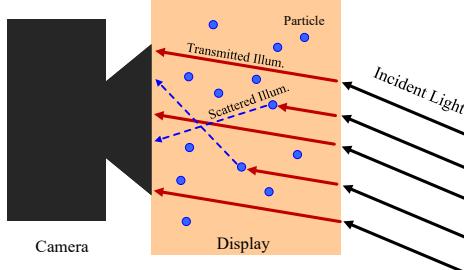


图2 UDC散射模型示意图。相机接收到的辐照度可以分解为透射照明和散射照明。

(DISCNet) 来估计潜在的干净图像。Koh等人[11]提出了一种用于 UDC 图像恢复

(BNUDC) 的分支网络，它同时消除了高频噪声和低频退化。为了节省内存以恢复高分辨率图像，Sundar 等人使用了 Deep Atrous Guided Filter (DAGF) 网络。[31]。罗等人。[21]发现了 HSV 空间中 UDC 和真实图像的不同统计特征。为了在 H 和 S 通道中自适应地拟合估计图像，他们提出了一种级联曲线估计网络来增强 UDC 图像。虽然已经有一些尽管在 UDC 图像恢复方面取得了成功的尝试，但现有方法在很大程度上忽略了散射效应的处理，这可能严重影响真实世界 UDC 图像的恢复性能。

3. 使用 UDC 散射模型增强 IFP

在本节中，我们首先通过将相机接收到的辐照度分解为透射分量和散射分量来模拟 UDC 成像系统中的散射现象（第 3.1 节）。随后，我们提出了一种增强的 UDC 图像形成管道（IFP）方法，利用散射模型来合成 UDC 图像（第 3.2 节）。我们证明，我们提出的方法产生的 UDC 图像，与现有的 UDC IFP 相比，与真实捕获的 UDC 图像具有更高的相似性。

3.1. UDC 散射效应建模

在本研究中，我们假设撞击显示器的入射辐射来自单个光源，以便于在简化的环境中对 UDC 散射效应进行建模。通过利用辐射累积，我们的建模方法可以轻松扩展到具有多个光源的情况。实际上，入射光可以有多种来源，包括太阳光、地面反射光、场景反射光等。此外，当光源距离 UDC 相当远时，可以假设入射光线是平行的。光束[27]。当入射平行光穿过显示器时



图 3. 我们增强的 IFP 和 Feng 等人生成的合成图像的比较。[6]。我们的增强型 IFP 会产生模糊和对比度失真，这也可以在现实世界捕获的 UDC 图像中观察到。PSNR 和 SSIM 是通过使用捕获的 UDC 图像作为参考来计算的。

播放时，一小部分光子与显示器内的微小颗粒碰撞，导致散射现象[26]。未受影响的光子继续穿过显示器，最终以衰减的幅度到达相机传感器。UDC 散射现象的示意图如图 2 所示。在我们的分析中，我们将 UDC 成像系统中的显示器视为一块具有恒定散射系数 β 的均匀散射介质。UDC 散射效应可表示为： $L(x) = L_t(x) + L_s(x)$ (2)

其中 L 表示相机捕获的光强度， L_t 是透射照明分量， L_s 是散射照明分量。这里， x 代表像素位置。受图像去雾[22, 15]和水下图像增强[10, 16]中使用的散射模型的启发，我们可以将 L_t 和 L_s 写成显式形式：

$$\begin{aligned} L_t(x) &= L_b(x) e^{-\beta d(x)}, \\ L_s(x) &= m(1 - e^{-\beta d(x)}), \end{aligned} \quad (3)$$

其中 $d(x)$ 表示光线在显示器内的路径距离， m 是与入射辐射亮度 L_b （也称为干净背景图像的光强度）相关的比例常数。对于具有相同入射角的光线， $d(x)$ 近似于所有像素位置的固定值。正如下面将讨论的，该 UDC 散射模型将用于增强 UDC IFP。

3.2. Enhanced UDC IFP

基于提出的 UDC 散射模型，我们现在增强了现有的 IFP，以生成更真实的 UDC 图像，并具有配对的地面事实，用于训练后续模型

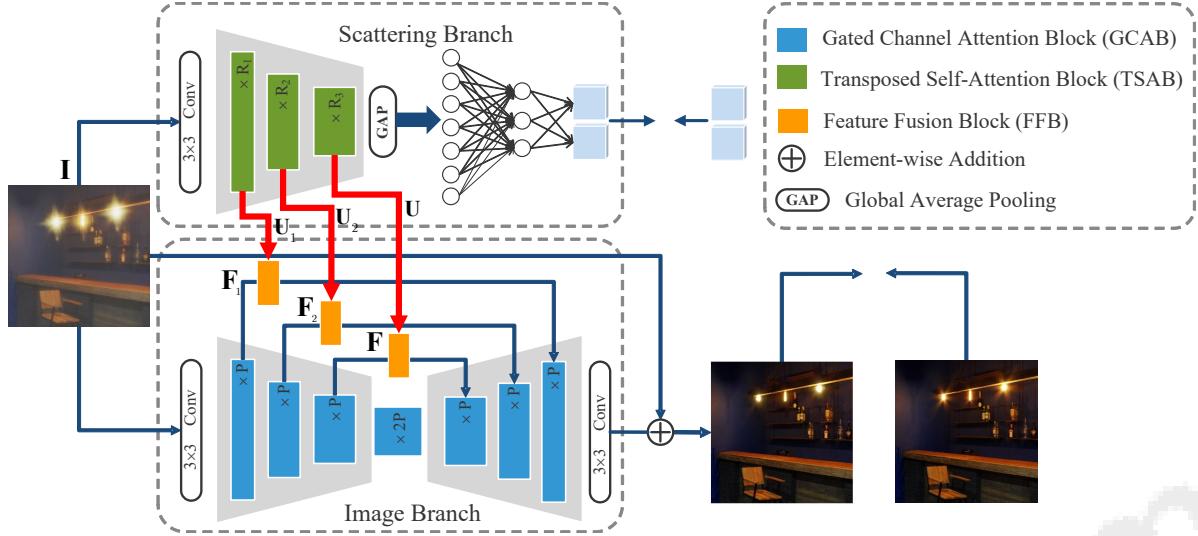


图 4. 我们提出的用于 UDC 图像恢复的 SRUDC 的概述。整个框架由两个分支组成：散射分支和图像分支。散射分支从退化图像中估计散射效果的参数，而图像分支则在散射分支的引导下恢复清晰的场景。

恢复网络。具体来说，我们将与 $\text{PSF } k$ 和零均值噪声 n 相关的衍射模糊集成到 (2) 中。我们的增强型 UDC IFP 可以定义为：

$$I(x) = TC \cdot (\mathbf{L}_t(x) + \mathbf{L}_s(x)) * \mathbf{k} + \mathbf{n}, \quad (4)$$

其中 x 是像素位置， I 是退化的 UDC 图像， $TC(\cdot)$ 表示色调映射和剪切函数。这里引入 $TC(\cdot)$ 的目的是在高动态范围空间产生各向异性衍射模糊后，将图像强度转换到低动态范围空间。将 (3) 代入 (4) 得：

$$I(x) = TC \left\{ [\mathbf{L}_b(x) e^{-\beta d(x)} + m(1 - e^{-\beta d(x)})] * \mathbf{k} + \mathbf{n} \right\}. \quad (5)$$

其中 $\mathbf{L}_b(x)$ 是背景 B 的光强度。 $Asd(x)$ 对于所有 x 近似为一个常数，并且 k 和 m 都假设与 x 无关，上述 UDC 散射模型可以看作是全局的转型。通过引入 $\alpha = e^{-\beta d}$ 并省略 x ，增强型 IFP 可以进一步简化为：

$$I = TC \cdot [\alpha \mathbf{L}_b + m(1 - \alpha)] * \mathbf{k} + \mathbf{n}. \quad (6)$$

对于参数 m ，它是与入射辐射亮度 L_b 相关的比例常数，我们将其设置为灰度 B 的平均值，以保持平均亮度。这样的设置是合理的，因为屏下摄影通常不会影响 HSV 空间中值 (V) 通道的分布 [21]。此外， α 在区间 $[0.6, 0.9]$ 内是一个恒定的经验采样。为了证明我们增强的 IFP 的合理性，我们将其与现有的数据合成方法 [6] 进行了比较

一个小的真实数据集 [21]。如图 3 所示，我们生成的 UDC 图像与真实捕获的图像在视觉上更加相似；还具有显着更高的 PSNR 和 SSIM 值。为了进一步说明增强型 IFP 的优越性，我们对 HSV 颜色空间中的整个合成数据集进行了统计分析。我们发现合成数据集中的色调 (H) 和饱和度 (S) 通道的分布与真实捕获的数据集中的分布相似。统计特性的直方图表示可以在补充材料中找到。

4. 用于 UDC 图像恢复的散射去除网络

为了具体解决 UDC 图像恢复中的散射效应问题，我们提出了一种用于 UDC 图像恢复的散射去除网络 (SRUDC)。基于我们增强的 UDC IFP，我们注意到 α 和 m 的准确估计非常有利于 UDC 图像恢复。为此，我们特意在 SRUDC 中设计了一个散射分支来估计这些参数，以指导图像分支中背景图像的恢复过程。框架概述如图 1 所示。4. 给定退化的 UDC 图像 I ，我们的目标是恢复干净的背景图像 B 。我们的 SRUDC 框架由两个分支组成，即散射分支和图像分支。具体来说，散射分支根据 I 估计 α 和 m (第 4.1 节)，而图像分支在散射分支的指导下恢复 B (第 4.2 节)。为了进一步增强图像分支的特征表示，我们设计了一种新的特征融合块 (FFB)，它有效地结合了来自图像分支的全局信息。

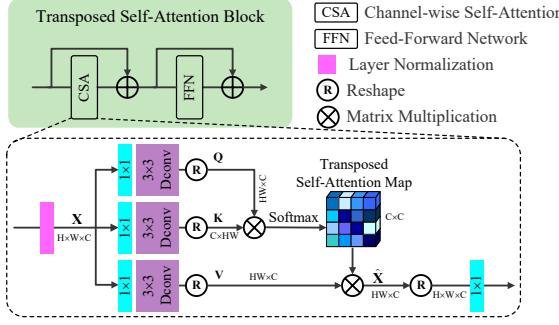


Figure 5. The structure of TSAB.

散射分支（第 4.3 节）。

4.1. 分散分支

散射分支旨在估计 α 和 m ，它们以数字方式表示 UDC 成像系统中的散射效应。回想一下 (6)，这两个系数决定了由于 UDC 散射效应而导致的 cleanimage 的全局变换。因此， α 和 m 的准确估计需要网络保持对空间不变的全局信息进行建模的能力。为此，受到最近成功的通道自注意力 [37,35,41] 的启发，我们开发了转置自注意力块 (TSAB)，它捕获通道维度中的远程依赖性。此外，我们采用全局平均池化 (GAP) 来提取特征的有用全局统计量，然后通过两层多层感知器 (MLP) 计算 α 和 m 的条件向量。详细散射的结构如图 4 的上半部分所示。给定一个退化的 UDC 图像 I ，我们应用 3×3 卷积层来提取浅层特征。然后，提取的特征通过基于多个 TSAB 的三级编码器，生成深层特征集 U_o ($o = 1, 2, 3$)，其中 o 是级别索引。每个级别的 TSAB 的数量表示为 $\{R_1, R_2, R_3\}$ 。我们对特征进行两次降尺度，逐渐减小空间尺寸并增加通道数量。最终，估计的 α 和 m 可以通过以下方式获得：

$$(\hat{\alpha}, \hat{m}) = W_2 \odot g(W_1 \odot GAP(U_3)), \quad (7)$$

其中 $GAP(\cdot)$ 表示全局平均池化层， W_1 和 W_2 是两层 MLP 的参数， $g(\cdot)$ 表示 Sigmoid 函数，表示 Hadamard 积。此外，特征 U_o s 进一步变换以指导重建图像分支中的干净场景。关于 TSAB，它是散射分支中的重要构建块，其架构如图 2 所示。5. 给定输入特征，为了通过通道维度中的长距离依赖关系捕获全局信息并显着减少存储消耗，我们计算特征调制的 CSA

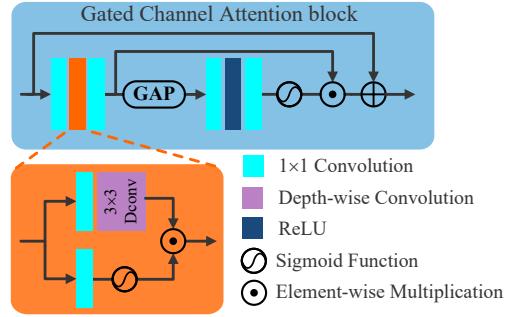


Figure 6. The structure of the proposed GCAB.

残留物。从层归一化张量 $X \in \mathbb{R}^{H \times W \times C}$ 中，我们使用 1×1 卷积和 3×3 深度卷积的组合，然后进行整形以生成 $\{Q, K, V\} \in \mathbb{R}^{HW \times C}$ 。CSA 调制定义为： $X = \text{soft tmax}(QK^T)V$ (8) 其中 X 表示通道方式调制特征。然后将 X 整形为尺寸 $R^{H \times W \times C}$ 以供进一步加工。经过 CSA 调制后，在 TSAB 中加入前馈网络引入非线性激活，进一步增强了 CSA 的能力。

4.2. 图像分支

在散射分支 U_o s 的指导下，提出图像分支来生成估计的背景 B 。我们利用 CNN 作为骨干来利用其局部表示能力。如图 4 底部所示， I 首先通过 3×3 卷积层转换到特征空间。然后，对称 U 形架构在特征空间中重建背景场景。编码器和解码器由三个级别组成，基于我们提出的门控通道注意块 (GCAB) 构建。为了协助恢复过程，编码器的特征表示为 F_e ($e = 1, 2, 3$)，由 U_o 调制，然后通过跳跃连接与解码器特征连接 [25]。为了更好地重建空间变化的 UDC 图像内容，我们设计 GCAB 作为图像分支中编码器和解码器的基本构建块。GCAB 的结构如图 6 所示。GCAB 基于广泛使用的残差通道注意块 [40, 38]。为了增强特征图的空间表示能力，我们引入了门控机制 [1, 30]，它自适应地激活特征图。如图 6 中的橙色块所示，给定输入张量 Y ，门控算子定义为：

$$\text{Gating}(Y) = W_{dw} W_{pw}^1 Y \odot g(W_{pw}^2 Y), \quad (9)$$

其中 W_{1pw} 和 W_{2pw} 分别表示两个 1×1 卷积层的权重矩阵， W_{dw} 是 3×3 深度卷积的参数。通过整合门机制和通道注意力，我们可以

自适应地调制空间和通道维度的特征以恢复 UDC 图像。

4.3. 特征融合块

为了隐式指导图像分支解码器中 B 的估计，我们通过特征融合块（FFB）使用 U_o 中嵌入的散射效应信息重新校准 F_e 。由于 F_e 和 U_o 分别对输入的全局和局部信息进行编码，直接连接或按元素相加可能会导致歧义。为了解决这一挑战，我们设计了 FFB 来自适应调制 F_e 。根据 UDC 散射模型的公式（参见（6）），我们建议在 FFB 中使用仿射变换。受空间特征变换（SFT）[33, 2]的启发，我们计算 U_o 的仿射变换的系数和偏移量。FFB 的设计图解放在了补充中。给定 F_e 和 U_o 且 $e = o$ ，融合权重 $\{v, w\}$ 可以通过两个 1×1 卷积层和 leaky ReLU 函数的组合获得。然后，输出特征 F_o 可以通过以下方式生成： $F_o = v F_e + w$ 。（10）

4.4. 培训目标

我们对估计的 $\{\alpha, m\}$ 和恢复的 B 应用监督。我们的框架以端到端的方式进行训练，目标函数如下：

$$\mathcal{L} = \omega_c \mathcal{L}_c + \omega_i \mathcal{L}_i, \quad (11)$$

其中 \mathcal{L}_c 和 \mathcal{L}_i 分别表示散射分支和图像分支的训练损失。这里，平衡散射和图像分支的相对重要性的权重参数 ω_c 和 ω_i 根据经验设置为 $\omega_c = 0.1$ 和 $\omega_i = 1$ 。对于散射分支，我们使用均方误差（MSE）作为标准，而对于图像分支，训练损失以 L_1 形式定义。具体来说，我们有：

$$\begin{aligned} \mathcal{L}_c &= \mathcal{L}_{MSE}(\hat{\alpha}, \alpha) + \mathcal{L}_{MSE}(\hat{m}, m), \\ \mathcal{L}_i &= \mathcal{L}_{L_1}(\hat{\mathbf{B}}, \mathbf{B}). \end{aligned} \quad (12)$$

5. 实验结果

我们现在描述有关 SRUDC 实施的一些细节。对于散射分支中的 TSAB 数量，我们设置 $\{R_1 = 2, R_2 = 3, R_3 = 4\}$ ，而对于图像分支中的 GCAB 数量，我们设置 $P = 16$ 。所提出的 SRUDC 使用 Pytorch 实现[24] 框架并在四个 NVIDIA V100GPU 上训练了 800 个周期。在训练过程中，图像被随机裁剪成 256×256 的块，小批量大小设置为 64。AdamW 优化器[20]用于更新可学习参数。我们使用余弦退火

表 1. 合成数据集的定量比较。最好的结果以粗体显示，次好的结果加下划线。

Method	PSNR	SSIM	LPIPS	Params (M)	MACs (G)
DISCNet [6]	25.54	0.9246	0.1508	3.442	272.33
DAGF [31]	27.12	0.9230	0.1024	1.117	45.89
DWFormer [43]	28.85	0.9392	0.1366	1.447	131.84
UDCUNet [18]	31.33	0.9759	0.0459	<u>1.406</u>	402.16
BNUDC [11]	34.91	0.9777	<u>0.0331</u>	4.575	317.38
SRUDC-light	<u>35.56</u>	<u>0.9804</u>	0.0365	3.105	<u>106.79</u>
SRUDC-full	36.02	0.9833	0.0322	8.734	240.36

策略[19]调整学习率，初始化为 4×10^{-4} 并逐渐减小到 4×10^{-6} 。

5.1. 训练和测试数据集

所提出的 SRUDC 使用合成数据集进行训练。退化图像 I 通过使用（6）获得。对于（6）中的 PSFk，我们总共收集了 10 个内核，其中包括 9 个使用 ZTE Axon 20 手机 [6] 测量的内核和一个使用透明 OLED [36] 的真实世界内核。使用这些 PSF 内核，我们可以从 2016 个图像补丁生成 20160 个训练图像对，这些图像补丁是从 HDRI Haven 数据集 [9] 中的 HDR 图像中裁剪成 800×800 的大小。关于测试数据集，我们利用合成数据和真实世界数据的组合来评价。与综合训练数据集类似，我们从 HDRI Haven 数据集中选择 360 个裁剪图像块来生成综合测试集。真实测试集由三部分组成，包括 UDC-ZTE [6]（包含中兴 Axon 20 手机拍摄的 30 张高分辨率 UDC 图像）、UDC-UAV [6]（包含从航拍视频中捕获的 162 张图像）以及 UDCIE [21]（包含 12 张）。在野外环境中拍摄的图像。因此，我们总共有 3600 个合成图像和 204 个真实世界测试图像来评估我们的方法和现有竞争对手。

5.2. 定量结果

表 1 报告了合成数据测试的定量结果。我们提供了两个版本的 SRUDC：完整版本和轻量版本，分别表示为 SRUDC-full 和 SRUDC-light。SRUDC-full 和 SRUDC-light 中编码器-解码器的三个级别的特征通道数分别设置为 $\{24, 48, 96\}$ 和 $\{16, 32, 64\}$ 。我们将 SRUDC 的恢复性能与五种最先进的 UDC 图像恢复方法进行了比较，包括 DISCNet [6]、DAGF [31]、DWFormer [43]、UDCUNet [18] 和 BNUDC [11]。为了公平比较，我们还使用建议的默认参数集在训练数据上重新训练这些模型，并选择预训练模型和重新训练模型之间更好的结果进行比较。这对于竞争方法来说无疑是有利的。我们采用 PSNR、SSIM [34] 和 LPIPS [39] 作为评估指标。使用参数数量和乘法累加运算（MAC）来比较模型复杂度。作为

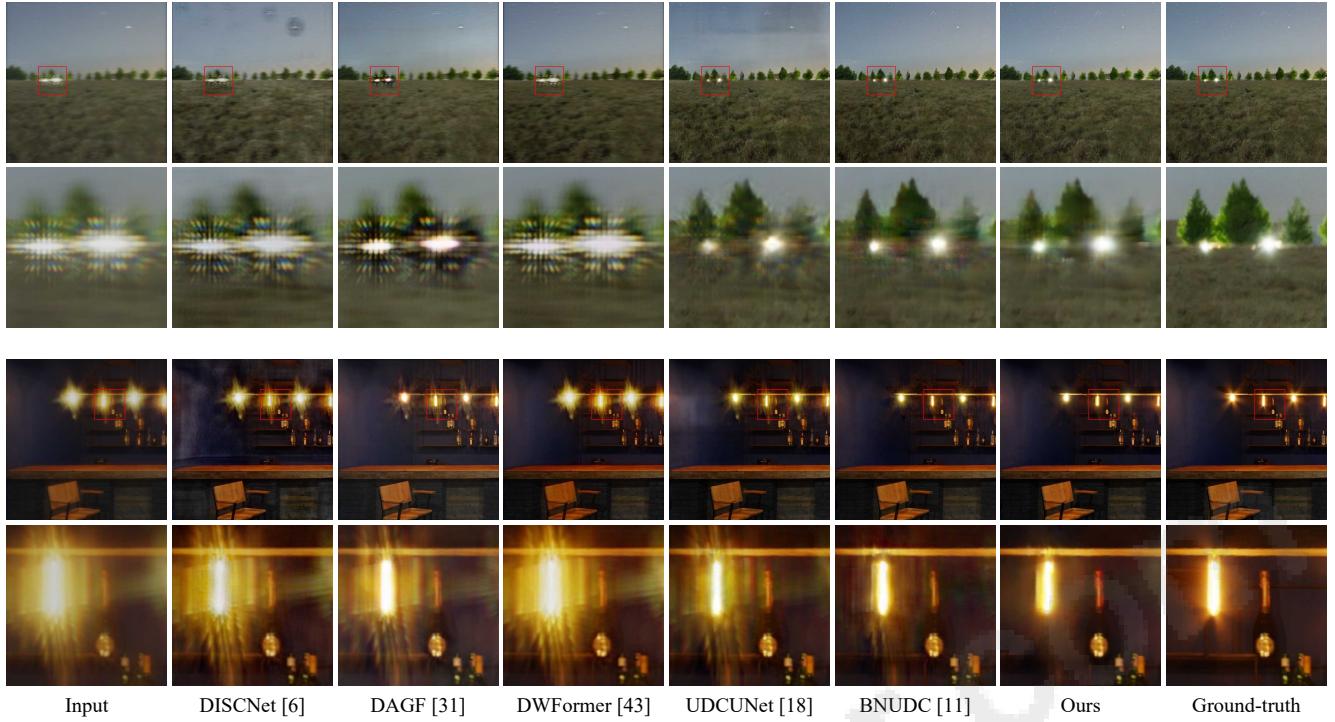


图 7. 合成图像的视觉比较。我们的方法消除了散布在整个图像上的散射引起的雾度和对比度失真。同时，光源周围的衍射伪影被极大地抑制。

如表 1 所示，SRUDC-full 大大优于第二好的方法 BNUDC，即 PSNR 中 1.11dB，SSIM 中 0.0056，LPIPS 中 0.0009。对于模型复杂性，SRUDC-light 通过 106.79G MAC 和与现有 SOTA 方法相当数量的参数实现了第二低的计算开销。同时，SRUDC-light 在 PSNR 方面仍然比 BNUDC 保持了 0.65dB 的性能增益。

5.3. Qualitative Results

现在，我们在合成和真实 UDC 图像上比较我们的方法和竞争方法的定性结果。图 7 显示了两个合成示例的结果。可以看出，我们的方法能够消除散布在整个图像上的散射引起的雾度和对比度失真，并极大地抑制光源周围的衍射伪影。我们还给出了不同方法在真实世界数据集上的视觉比较图 8。正如可以观察到的，我们的 SRUDC 实现了最好的感知质量，特别是在文本区域的重建方面，例如重复的栅栏和建筑结构。此外，SRUDC 与 UDCUnet 一样可以避免颜色偏移。更多定性比较可以在补充文件中找到。

5.4. 消融研究

散射分支：为了证明散射分支的好处，我们构建了以下消融实验。

Table 2. Impact of the scattering branch.

Model	PSNR	SSIM	LPIPS
w/o the supervisions of m and α	35.13	0.9817	0.0347
w/o the entire scattering branch	34.66	0.979	0.0394
w/ CNN scattering branch	35.02	0.9798	0.0336
SRUDC-full	36.02	0.9833	0.0322

我们首先评估 m 和 α 监督的重要性。如表 2 所示，与 SRUDC-full 相比，关闭 m 和 α 的监督会导致性能显着下降 0.89dB。我们进一步尝试通过从 SRUDC 中删除整个散射分支来证明其效果。在这种情况下，SRUDC 退化为 Unet 的变体。从表 2 的第二行可以看出，整个散射分支带来了约 1.36dB PSNR 的显着性能增益。此外，我们将散射分支中的 TSAB 替换为 CNN 结构 GCAB，以显示 CSA 的有效性。可以看出，由于对全局信息进行建模的强大能力，我们提出的 TSAB 可以带来约 1dB PSNR 增益的显着性能改进。图像分支：我们在图像分支中评估所提出的 GCAB 中的组件。我们依次重新移动门控操作和通道注意力并重新训练对应模型。如表 3 所示，消除门控操作和通道注意力分别导致 0.38 dB 和 0.7 dB PSNR 下降。特征融合块：为了显示 FFB 的好处，我们

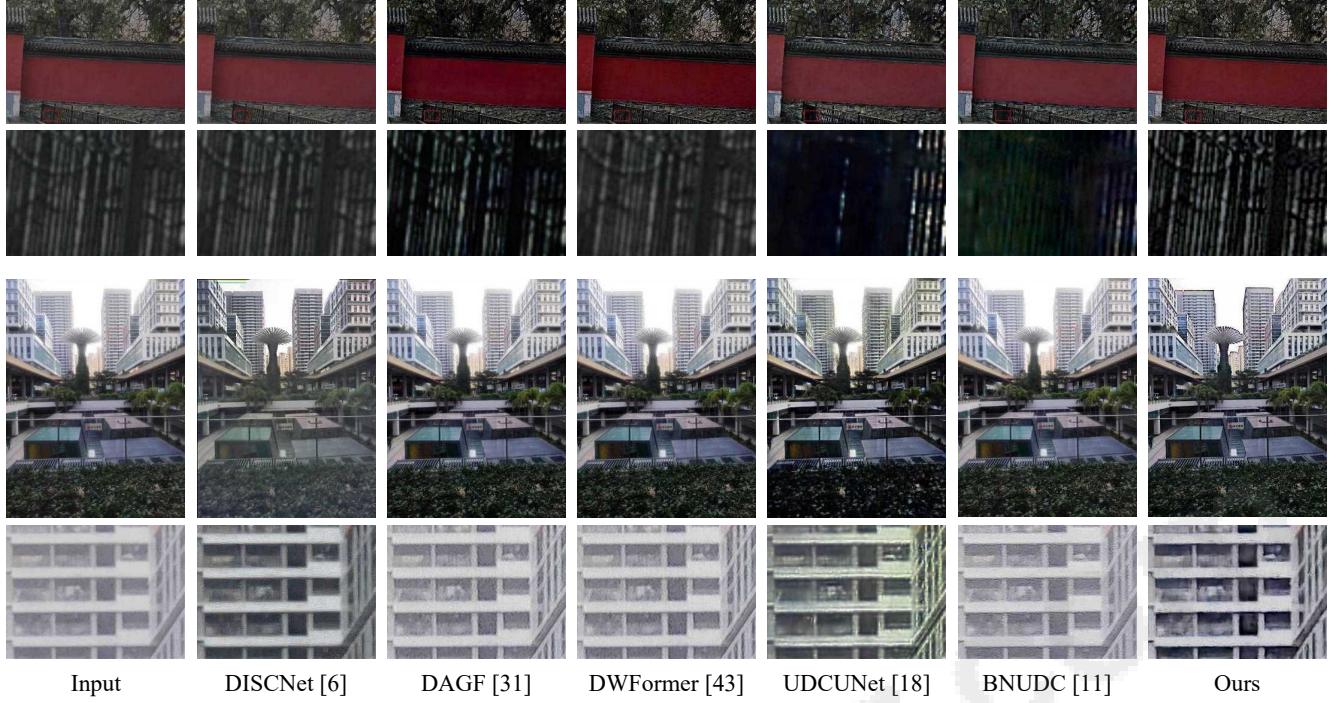


图 8. 真实世界图像的视觉比较。我们的方法为文本区域的重建实现了最佳的感知质量，例如重复的栅栏和建筑结构。

Table 3. Effect of the components in the image branch.

Model	PSNR	SSIM	LPIPS
w/o gating operation	35.64	0.9824	0.0356
w/o channel attention	35.32	0.9806	0.0417
GCAB	36.02	0.9833	0.0322

Table 4. Effect of the feature fusion block.

Model	PSNR	SSIM	LPIPS
Concatenation	35.84	0.9813	0.0325
SKfusion [17]	35.42	0.9824	0.0335
SCAM [28]	33.59	0.9707	0.0479
Our FFB	36.02	0.9833	0.0322

在此模块上构建消融实验。具体来说，我们用串联、SKfusion [17] 和 SCAM [28] 代替 FFB。表 4 中总结的结果验证了 SFT 的优越性，PSNR 增益约为 0.18dB。

5.5. 增强型 IFP 的有效性

为了展示在 UDC 图像恢复中考虑散射效应的重要性，我们比较了最先进的 UDC 恢复方法 BNUDC 的预训练和再训练模型。预训练模型使用现有 IFP、Feget al 生成的数据进行训练。[6]，并且重新训练的模型是使用我们增强的 IFP 合成的数据进行训练的。在真实世界的 UDC 图像上测试的视觉结果如图 9 所示。通过比较，我们的合成数据有效地提高了 BNUDC 恢复结果的视觉质量。



图 9. BNUDC 预训练和再训练与来自不同 IFP 的合成数据的比较。(a) 真实世界输入 UDC 图像。(b) BNUDC 使用 Feng 等人生成的数据进行预训练的结果。[6]。(c) 使用增强型 IFP 的数据重新训练 BNUDC 的结果。我们的合成数据有效地提高了 BNUDC 恢复结果的视觉质量。

六，结论

在本研究中，我们建议在考虑显示器引起的散射效应的情况下解决 UDC 图像恢复问题。使用物理 UDC

散射模型，我们改进了 IFP 以实现真实的 UDC 图像合成。为了恢复干净的背景场景，我们专门设计了一个双分支深度网络，其中散射分支估计退化图像的散射效果参数，而图像分支恢复背景图像。设计的特征融合块利用散射分支的全局信息为 UDC 图像恢复提供指导。我们的模型在合成和真实世界的 UDC 图像上都显着优于最先进的方法。致谢。这项工作得到了澳门科学技术发展基金SKLIOTSC-2021-2023、0072/2020/AMJ和0022/2022/A1的部分支持；部分由澳门大学研究委员会根据 MYRG2020-00101-FST 和 MYRG2022-00152-FST 进行；部分由中国自然科学基金委员会资助，编号：61971476；部分由阿里巴巴集团通过阿里巴巴创新研究计划提供。

References

- [1] 陈良宇, 褚晓杰, 张翔宇, 孙健。图像恢复的简单基线。欧元。会议。计算。视觉, 第 17-33 页, 2022 年。5[2] 陈翔宇, 刘一豪, 张正文, 乔宇, 董超。Hdrunet: 具有去噪和去量化的单图像 hdr 重建。在 IEEE 会议上计算。可见模式识别。Worksh., 第 354-363 页, 2021 年。6[3] 陈翔宇、张正文、任吉米、田林虎、乔宇和董超。从 sdrtv 到 hdrtv 的新旅程。在国际。会议。计算。参见, 第 4500-4509 页, 2021 年。2[4] Florin Conde、Marcos V. 和 Vasluiianu、Sabari Nathan 和 Radu Timofte。移动设备上的实时屏下摄像头图像恢复和 hdr。欧元。会议。计算机可视化。Worksh., 第 747-762 页, 2022 年。
 1[5] 冯瑞成、李崇义、陈怀金、李帅、顾金伟和陈变洛。从非对齐数据生成对齐伪监督，用于屏下摄像头中的图像恢复。在 IEEE 会议上计算。维斯。PatternRecog., 第 5013-5022 页, 2023。
 1[6] 冯瑞成, 李崇义, 陈怀金, 李帅, 陈变洛, 谷金伟。通过动态跳跃连接网络消除屏下摄像头中的衍射图像伪影。在 IEEE 会议上计算。维斯。模式识别, 第 662-671 页, 2021. 1, 2, 3, 4, 6, 8[7] 冯瑞成, 李崇义, 周尚辰, 孙文秀, 朱庆鹏, 蒋军, 杨庆宇, 陈变来, 顾金伟, 朱玉瑞, 等。Mipi 2022 屏下相机图像修复挑战: 方法和结果。欧元。会议。计算。维斯。Worksh., 第 60-77 页, 2022。
 1[8] 高克明, 常孟, 姜昆军, 王亚旭, 徐志海, 冯华军, 李奇, 胡增新, 陈悦婷。现实世界的图像恢复显示屏下成像。Opt.Express, 29(23): 37820-37834, 2021。1[9] HDRI。人类发展指数数据集。https://polyhaven.com/hdris。6
 [10] 朱尔斯·S·贾菲。计算机建模和最佳水下成像系统的设计。IEEE 海洋工程杂志, 15(2):101-111, 1990。3[11] Jaihyun Koh、Jangho Lee 和 Sungroh Yoon。Bnudc: 一个双分支深度神经网络, 用于从屏下摄像头恢复图像。在 IEEE 会议上计算。维斯。PatternRecog., 第 1950-1959 页, 2022. 1, 2, 3, 6[12] Melvin Kuriakose、P S RishiKesh、Densen Puthusser 和 C. V. 吉吉。变换域金字塔扩张卷积网络用于恢复显示下相机图像。欧元。会议。计算。Worksh., 第 364-378 页, 2020 年。1[13] Hyeok-Jun Kwon、Chang-Mo Yang、Min-Cheol Kim、Choon-Woo Kim、Ji-Young Ahn 和 Pu-Reum Kim。模拟通过透明有机发光二极管的透明塑料传输图像的模糊。显示技术杂志, 12(8): 851-858, 2016。2[14] Kinam Kwon、Eunhee Kang、Sangwon Lee、Su-Jin Lee、Hyong-Euk Lee、ByungIn Yoo 和 Jae-Joon Han。智能手机屏下摄像头的可控图像恢复。在 IEEE 会议上计算。维斯。模式识别, 2073-2082 页, 2021. 1, 2[15] 李博一, 任文琪, 付登攀, 陶大成, 冯丹, 曾文俊, 王张扬。对单图像去雾及其他方面进行基准测试。IEEE 传输。图像处理., 28(1):492-505, 2018. 3[16] 李崇义, Saeed Anwar, 侯俊辉, 丛润民, 郭春乐, 任文琪。通过介质传输引导的多色空间嵌入增强水下图像。IEEE 传输。图像处理., 30:4985-5000, 2021.3[17] 李翔, 王文海, 胡晓林, 杨健。选择性内核网络。在 IEEE 会议上计算。维斯。PatternRecog., 第 510-519 页, 2019。8[18] Xina Liu, Jinfan Hu, Xiangyu Chen, Chao Dong。Udc-unet: 通过 u-shaped dynamic 网络恢复屏下摄像头图像。欧元。会议。计算。维斯。Worksh., 第 113-129 页, 2022. 1, 6[19] Ilya Loshchilov 和 Frank Hutter。Sgdr: 带有热重启的随机梯度下降。arXiv preprint arXiv:1608.03983, 2016. 6[20] Ilya Loshchilov 和 Frank Hutter。解耦权重衰减正则化。arXiv 预印本 arXiv:1711.05101, 2017. 6[21] 罗军, 任文琪, 王涛, 李崇义, 曹晓春。通过级联曲线估计增强屏下摄像头图像。IEEE 图像处理汇刊, 31: 4856-4868, 2022. 1, 3, 4, 6[22] Srinivasa G Narasimhan 和 Shree K Nayar。视野和氛围。国际。J. 计算机。Vis., 48(3):233, 2002。3[23] Yongmin Park、Dongwoo Kang、Sungjin Kim、Taeseong Han、JangJin Yoo 和 Moojong Lim。论文 5.3: 透明 oled 显示器视觉质量模拟。见 SID Symposium Digest of Technical Papers, 第 44 卷, 第 156-159 页。Wiley 在线图书馆, 2013 年。2[24] Adam Paszke、Sam Gross、Soumith Chintala、Gregory Chanan、Edward Yang、Zachary DeVito、Zeming Lin、Alban Desmaison、Luca Antiga 和 Adam Lerer。pytorch 中的自动微分。2017 年 6 月

[25] 奥拉夫·罗纳伯格、菲利普·费舍尔和托马斯·布洛克斯。U-net: 用于生物医学图像分割的卷积网络。In Proc. 国际。会议。医学。图像计算。Comput.-Assisted Intervention, 第 234–241 页, 2015. 5[26] Amin Salehi、Xiangyu Fu、Dong-Hun Shin 和 Franky So。oled 光学设计的最新进展。Advanced Function Materials, 29(15):1808803, 2019. 2, 3[27] Heiko H Schuett, Franziska Baier, and Roland W Fleming. 从阴影图案感知光源距离。Journal of Vision, 16(3) :9–9, 2016. 3[28] 宋斌斌, 周建涛, 陈翔宇, 张石乐。原始 RGB 图像对的实景反射去除。IEEE Trans. 电路系统。视频技术, 99(99):1–1, 2023.8[29] 宋彬彬, 周建涛, 吴海伟。用于渐进式单图像反射消除的多级曲率引导网络。IEEE 传输。电路系统。视频技术, 32(10):6515–6529, 2022. 2[30] 宋宇达, 周扬, 钱惠, 杜鑫。重新思考图像去雾网络的性能提升。arXiv preprint arXiv:2209.11448, 2022. 5[31] Varun Sundar、Sumanth Hegde、Divya Kothandaraman 和 Kaushik Mitra。用于屏下摄像头图像恢复的深孔引导滤镜。欧元。会议。计算。Vis.Worksh., 第 379–397 页, 2020. 1, 3, 6[32] 屠正中, 侯赛因·塔勒比, 张涵, 杨峰, 佩曼·米兰法尔, 艾伦·博维克, 李银晓。Maxim: 用于图像处理的多轴mlp。在 IEEE 会议上计算机可视化。模式识别, 第 5769–5780 页, 2022. 2[33] Xintao Wang, Ke Yu, Chao Dong, 和 Chen Change Loy。通过深度空间特征变换在图像超分辨率中恢复真实纹理。IEEE 计算机视觉和模式识别会议论文集, 第 606–615 页, 2018 年。6[34] Zhou Wang, A.C. Bovik, H.R. Sheikh 和 E.P. Simoncelli. 图像质量评估: 从错误可见性到结构相似性。IEEE 传输。图像处理, 13 (4) : 600–612, 2004. 6[35] 颜嘉兴, 赵红, 卜鹏辉, 金宇胜。基于通道注意力的自监督单目深度估计网络。2021 年国际 3D 视觉会议 (3DV), 第 464–473 页, 2021 年。5[36] Anqi Yang 和 Aswin C. Sankaranarayanan。设计面板下摄像头的显示像素布局。IEEE 传输。模式肛门。马赫。Intell., 43(7):2245–2256, 2021. 6[37] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, and Ming-Hsuan Yang. Restormer: 高效变压器分辨率图像恢复。在 IEEE 会议上计算。维斯。模式识别, 第 5728–5739 页, 2022. 2, 5[38] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang 和 LingShao。多阶段渐进图像恢复。在 IEEEConf. 计算。维斯。模式识别, 第 14821–14831 页, 2021. 5[39] Richard 张、Phillip Isola、Alexei A. Efros、Eli Shecht-man 和 Oliver Wang。不合理的有效性

深层特征作为感知指标。在 IEEE 会议上计算机可视化。模式识别, 第 586–595 页, 2018. 6[40] 张玉伦, 李鲲鹏, 李凯, 王力辰, 钟必能, 傅云。使用非常深的残差通道注意网络进行图像超分辨率。欧元。会议。计算机视觉, 第 286–301 页, 2018. 5[41] 王志学, 张宇, 罗林, 王楠。Csa-cdgan: 用于遥感图像变化检测的基于通道自注意力的生成对抗网络。神经计算。应用, 34(24):21999–22013, 2022. 5[42] Yuqian Zhou, David Ren, Neil Emerton, Sehoon Lim, and Timothy Large。屏下摄像头时代的图像修复。在 IEEE 会议上计算。维斯。模式识别, 第 9179–9188 页, 2021. 1, 2[43] 周扬, 宋宇达, 杜欣。屏下摄像头的模块化退化模拟与修复。亚洲计算机视觉会议论文集, 第 265–282 页, 2022 年。1, 6