

通用骨干网络设计图像恢复网络的比较研究

Xiangyu Chen^{1,2,3*} Zheyuan Li^{2,1*} Yuandong Pu^{3,4*} Yihao Liu^{2,3}
Jiantao Zhou^{1†} Yu Qiao^{2,3} Chao Dong^{2,3,5†}

1 澳门大学 2 中国科学院深圳先进技术研究院 3 上海人工智能
实验室 4 上海交通大学 5 深圳先进技术大学 <https://github.com/Andrew0613/X-Restormer>

抽象的。尽管深度模型在各种图像恢复任务中取得了显着进展，但现有的图像恢复网络在任务通用性方面仍然面临挑战。一个直观的表现是，在某些任务中表现出色的网络往往无法在其他任务中提供令人满意的结果。为了说明这一点，我们选择了五个代表性网络，对五个经典图像恢复任务进行了比较研究。首先，我们详细解释了不同图像恢复任务和主干网络的特征。接下来，我们展示了基准测试结果并分析了不同模型在不同任务中性能差异背后的原因。根据这项比较研究，我们提出通用图像恢复主干网络需要满足不同任务的功能要求。基于这一原理，我们设计了一种新型通用图像修复骨干网络X-Restormer。大量的实验表明，X-Restormer 具有良好的任务通用性，并在各种任务中实现了最先进的性能。

1 简介

图像恢复旨在从退化图像中生成高质量图像。近年来，深度学习在该领域取得了巨大成功，提出了许多网络来解决各种图像恢复任务。最初，网络主要设计用于解决特定问题恢复任务，并且通常仅在选定的任务上进行验证。随着深度学习技术的不断发展，人们越来越关注可应用于广泛任务的通用网络的开发。这种趋势在高级视觉领域尤其明显，其中新的骨干网络被设计为支持多种任务 [17, 30]，包括分类、检测和分割。对于图像恢复，虽然越来越多的骨干网络可以处理多个恢复任务，但它们的任务通用性仍然有限，如图1所示。例如，SwinIR [25] 实现

* 同等贡献，† 通讯作者。




图 1: 不同骨干网络在五个图像恢复任务上的相对性能差异 1。现有的代表性网络在这些任务上表现出不同的性能, 而我们的方法则呈现出优越的任务通用性。

在图像超分辨率 (SR) 方面具有最先进的性能, 但在图像去模糊和去雾方面表现不佳。相反, Restormer [48] 在图像去雾和去雨方面表现得非常好, 但在图像 SR 方面效果较差。这种差异可以归因于不同图像恢复任务的图像退化特征有所不同。虽然所有图像恢复任务都涉及将退化图像映射到干净图像, 但对骨干网络能力的要求因具体任务而异。设计通用的图像恢复骨干网络提出了重大挑战。然而, 这种网络的发展具有相当大的价值, 因为它有可能大大降低与研究和应用相关的成本。为了实现这一目标, 我们首先对主流骨干网络在图像 SR、去噪、去模糊、去雨和去雾等代表性任务上进行了比较研究。选择这五个任务是因为它们的退化具有明显的特征。研究选择了五个具有代表性的骨干网络, 包括MPRNet[49]、Uformer[43]、SwinIR[25]、Restormer[48]和NAFNet[5]。这五个网络涵盖了经典架构, 例如U型架构、普通残差中残差架构和多阶段渐进架构。他们还采用了一些常见的算子, 包括卷积、空间自注意力和转置自注意力[48]。我们在选定的五项任务上对五种代表性方法进行了基准测试。实验结果清楚地反映了不同骨干网络在不同任务上的性能差异。然后我们进行详细的分析——

1 我们在表 1 中的测试集上设置了网络的最低平均性能。 2 对于任务(i)作为下界P_{lower}, 并将X-Restormer对于每个任务的平均性能设置为上限P_{upper}

上层. 图中性能 P(i) 的各点的纵坐标由 $(P(i) - P_{lower}^{(i)}) / P_{upper}^{(i)}$ 的纵坐标 of each point in $(i) / P_{upper}^{(i)}$.

分析这些任务和这些骨干网络的特征，以解释性能差异背后的原因。基于对比研究，我们提出通用的骨干网络必须在功能上高度全面，满足各种任务的多样化需求。值得注意的是，Restormer在对比研究中脱颖而出，在所有网络中排名前两名。五项任务。这种卓越的性能可以归功于几个关键设计。首先，Restormer的U形架构使其能够处理大尺寸输入，这对于处理大面积退化的任务至关重要。然后，网络采用转置自注意力机制，利用通道特征作为标记，实现通道之间的信息交互，并实现与全局感受野的映射。此外，大量深度卷积的结合激活了相当大的空间信息交互网络的能力。从功能角度来看，Restormer集成了其他比较网络的关键功能，从而在比较研究中表现出值得称赞的任务通用性。然而，Restormer的空间映射能力仍然显得有些不足，与SR 2的SwinIR相比，其在定量和定性方面的性能都低于标准。这种劣势被假设源于U所带来的细节重建的固有挑战。形状架构，再加上深度卷积的空间映射能力相对较弱，特别是与空间自注意力（即SwinIR中基于窗口的自注意力）相比。为了解决这个限制，一个可行的解决方案是引入空间自注意力关注Restormer。为了实现这一设计，我们交替用重叠的交叉注意块[8]替换一半的转置自注意块，构建一个新的网络X-Restormer，这些交叉注意块被证明具有很强的空间信息交互能力。大量实验表明，这种简单的修改可以在不增加参数数量的情况下显著增强Restormer的性能。此外，我们的X-Restormer在所有五项任务上都获得了最先进的性能，展示了最佳的任务通用性。我们的主要贡献可以总结如下：

- 我们通过构建图像恢复基准进行比较研究，强调现有图像恢复骨干网络在任务通用性方面面临的挑战。
- 基于基准结果，我们对不同图像恢复骨干网络的特征进行了详细分析退化和网络。我们强调通用图像恢复主干网络的设计必须满足多样化任务的功能要求。
- 通过进一步增强Restormer的空间映射能力，我们设计了初步的通用主干网络X-Restormer。无需额外参数，X-Restormer即可实现现有网络的显著性能提升，并展现出卓越的任务通用性。

2 一般来说，模型的SR性能与空间映射能力高度相关。




图 2: 选择了五个具有不同退化的代表性图像恢复任务。

2 相关工作

图像恢复网络。在过去的几年中，人们提出了大量的深度网络用于各种图像恢复任务，例如图像SR [8,26,59]、去噪[43,53,54]、去模糊[1,6]、去雨[4,29],45]和去雾[40,41,46]。最初，大多数深度网络是为特定任务设计的[3,14,34,55,57]。最近，随着人们对网络任务通用性的日益关注，越来越多的方法被开发出来来解决多个图像恢复任务。例如，Zamir 等人。[49]构建了一个用于去雨、去模糊和去噪的多级CNN。王等人。[43]设计了一个U形变压器，用于去雨、去模糊和去噪。梁等人。[25]实现了一个基于 Swin Transformer 的网络，该网络在 SR、去噪和压缩伪影减少方面实现了最先进的性能。扎米尔等人。[48]提出了一种新颖的转置自注意力来构建用于去雨、去模糊和去噪的 U 形网络。Chen 等人。[5]构建了一个U型CNN用于去噪和去模糊。虽然现有方法已经证明了在多个恢复任务中具有一定的泛化能力，但它们的任务通用性仍然有限。与之前的网络设计研究不同。虽然之前的工作提出了在各种图像恢复任务中表现出色的网络，但他们的主要重点是构建更强大的网络以在特定任务上实现性能突破。相比之下，本工作更注重骨干网络的任务通用性，具有与以往工作不同的愿景。更具体地说，我们的目标是探索通用图像恢复网络的设计原则和方向。我们并不是寻求创建强大的网络以在单个或某些特定任务上实现峰值性能，而是确保在各种任务中获得令人满意的性能。关于具体实现，我们打算构建复杂的网络架构或模块。相反，我们的偏好是通过使用最简单的方法来增强任务的通用性。对于特定的图像恢复任务，有一些并行的工作采用类似的想法。DAT [9] 结合了空间窗口自注意力和通道自注意力来处理图像 SR。IPT-V2 [23]设计了一个空间通道Transformerblock来构建去噪网络，并在NTIRE2023图像去噪挑战赛中获得了优胜奖[23]。然而，我们工作的动机和具体的网络实施与这些研究不同。

work implementation of our work are distinct from these studies.

3 图像恢复基准

在本节中，我们首先简要介绍几个图像恢复任务，每个任务都有其代表性的退化特征。随后，我们根据架构和核心算子两个关键方面对主流图像恢复网络进行分类。在此基础上，我们选择了五个有代表性的网络，并在五个不同的任务上进行了基准实验。我们描述了实验设置并解释了其合理性。最后，我们提出基准结果并对其进行详细分析。

3.1 图像恢复任务概述

我们选择五个代表性任务进行基准实验。这些任务（如图 2 所示）的选择基于两个主要原因。首先，它们是非常常见的图像恢复任务，具有广泛接受的评估方案。其次，这些任务的退化特征多种多样，彼此之间差异很大。因此，它们可以提供一种鲁棒的方法来评估图像恢复骨干网络的任务通用性。令 I_{GT} 表示地面实况图像， I_{LQ} 表示退化图像，其中 $I_{GT} \in \mathbb{R}^{H \times W \times 3}$ 。经典图像 SR 的退化模型可以表示为： $I_{LQ} = (I_{GT} \otimes k) \downarrow s, (1)$

$s \times 3$ 表示低分辨率图像。 k 表示双三次下采样内核， $\downarrow s$ 表示缩减因子。这种退化与局部信息高度相关，并导致高频信息的显著丢失。因此，SR 网络强调强大的空间信息交互能力，以重建尽可能多的细节。图像去噪的退化模型可以表示为：

$$I_{LQ} = I_{GT} + n, \quad (2)$$

其中 $n \in \mathbb{R}^{H \times W \times 3}$ 表示噪声图。对于高斯去噪，噪声值与内容无关。U 形架构的下采样-上采样过程本质上有助于消除噪声。此外，强大的空间信息交互能力还可以增强去噪网络的高频内容重建。图像去模糊（对于运动去模糊）的退化模型可以表示为： $I_{LQ} =$

$$(\text{ftmotion}(I_{GT})), (3)$$

t

其中 $\text{ftmotion}(\cdot)$ 表示不同连续曝光时间下的运动函数。这种退化与图像的全局运动偏移有关。因此，利用大范围信息甚至全局信息的能力对于去模糊网络非常重要。

mation is important for deblurring networks.




图 3: 图像恢复网络中的核心算子。

图像去雨的退化模型可以简单表示为:

$$I_{LQ} = I_{GT} + R, \quad (4)$$

其中 R 表示附加雨条纹, 由物理模型模拟, 例如[24, 28]。这种退化与高斯噪声的区别在于, 添加的 R 并不是均匀分布在图像上, 而是与图像内容相关。复杂的雨纹也对除雨网络的复杂性提出了很高的要求。基于大气散射模型的图像去雾退化模型可表示为:

$$I_{LQ} = I_{GT} * t(I_{GT}) + A(1 - t(I_{GT})), \quad (5)$$

其中 $t(\cdot)$ 表示传输函数, $t(I_{GT})$ 与场景点到摄像机的距离相关。这种退化与图像内的深度信息有着内在的联系。因此, 全球信息的整合对于去雾网络非常重要。

3.2 典型骨干网特点

主流图像恢复网络的架构可大致分为三类: U型编码器-解码器、普通残差中残差和多级渐进。Supp 中提供了这些架构的示意图。U型编码器-解码器架构对特征执行下采样和上采样操作, 使网络能够处理不同尺度的特征。这种架构允许网络接受大尺寸的输入, 并且网络的有效感受野随着下采样而迅速扩展。典型的U形网络包括Uformer [43]、Restormer [48]。多阶段架构将整个网络划分为多个子网络并逐步处理特征, 主要用于图像去雨和去模糊。基于该架构的常见网络包括MPRNet [49]和HINet [6]。简单的残差中的残差架构由多个残差组组成, 每个残差组由多个残差块组成。该架构在处理特征时保持原始尺寸, 有利于高频信息的重建, 但计算成本较高。典型的网络包括RCAN [57]和SwinIR [25]。

computational cost. Typical networks include RCAN [57] and SwinIR [25].

构建图像恢复网络的核心算子主要可分为三类：卷积、空间自注意力和转置自注意力。这些算子如图3所示。卷积计算固定大小内核滤波器并逐滑动窗口处理整个特征图，这是许多网络的主要组成部分，例如RDN [60]。空间自注意力通常在图像恢复任务中实现为窗口自注意力。它计算固定窗口大小内的注意力矩阵，生成功能类似于大型内核动态过滤器的内容感知权重。该算子具有很强的局部拟合能力，在SR和去噪方面表现出优越的优势[7]。转置自注意力将每个通道的整个特征视为一个令牌，以计算通道维度上的注意力矩阵。该算子直接处理全局特征，当与深度卷积结合时，它在多个恢复任务中表现出卓越的性能[48]。基准实验选择的五个代表性骨干网络包含上述架构和核心运营商，如表 1 所示。 1.

3.3 实验设置

对于图像SR，我们进行了放大倍数 $\times 4$ 的实验。我们使用 DF2K 数据集（与 SwinIR [25] 相同）来训练模型。低分辨率图像是使用 MAT-LAB 中的双三次下采样从地面实况图像生成的。对于 U 形网络，我们首先通过双线性插值对输入的低分辨率图像进行上采样。性能在 Y 通道上报告。对于去噪，我们采用 DFWB 数据集进行训练。噪声图像是通过添加噪声级别为 50 的高斯噪声来生成的。对于去模糊，我们使用运动去模糊数据集 GoPro [34] 来训练模型。对于除雨，我们使用合成降雨数据集 Rain13K 进行实验，并按照 Restormer [48] 计算 Y 通道上的性能。对于去雾，我们使用 RESIDE 数据集[21]的室内训练集（ITS），与[40]相同。为了最大化这些网络的能力，我们使用不同方法提供的官方代码和训练配置来训练模型³。请注意，为了公平比较，所有模型的训练均未使用任何预训练策略（例如 SR 的 $\times 2$ 预训练）或特殊技巧（例如 SwinIR 中的 EMA 和 NAFNet 中的 TLC）。此外，我们发现不同的方法可能不会在论文中使用完全相同的测试集和相同的指标计算来报告性能。因此，我们基于完全相同的数据重新测试所有模型，并使用流行的开源工具箱 BasicSR [42] 计算指标。

³ 我们尝试用统一的配置来训练所有网络，但发现这是不合理的。不同的训练配置和优化策略，网络的性能可能会有很大差异，因此很难确定一个公平的统一设置。

and optimization strategies, making it difficult to determine a fair unified setting.

表 2: 基准实验的 PSNR(dB) 定量结果。最好和第二好的性能结果用粗体和下划线表示。

Method	SR		Denoising		Deblurring		Deraining		Dehazing
	Set14	Urban100	CBSD68	Urban100	GoPro	HIDE	Test100	Rain100H	SOTS Indoor
MPRNet	28.90	26.88	28.48	29.71	32.66	<u>30.96</u>	30.29	30.43	<u>40.34</u>
SwinIR	29.07	27.47	<u>28.56</u>	29.88	31.66	29.41	30.05	30.45	29.14
Uformer	27.14	25.60	28.55	<u>29.98</u>	<u>33.05</u>	30.89	27.93	24.06	33.58
Restormer	<u>29.06</u>	<u>27.32</u>	28.60	30.02	32.92	31.22	32.03	<u>31.48</u>	41.87
NAFNet	29.03	27.00	28.52	29.65	33.08	31.22	<u>30.33</u>	32.83	38.97

3.4 基准测试结果

我们在表中展示了基准实验的定量结果。2. (由于篇幅限制, 补充材料中提供了完整的结果。) 从结果中可以得出几个重要的观察结果: 1) 不同的网络在不同的任务上表现出不同的性能。例如, SwinIR 在 SR 方面表现最佳, 但在去模糊和去雾方面表现最差。Uformer 在去噪和去模糊方面表现出色, 但在去雨和 SR 方面表现不佳。2) 具有U形和多级架构的网络在去模糊和去雾方面表现出明显的优势。3) 主要基于卷积算子的MPRNet和NAFNet在所有任务上都表现出中等的性能, 但没有突出的结果。4) SwinIR采用简单的架构和空间自注意力算子, 在SR上明显优于其他网络。5) Restormer的整体表现非常出色。除了在SR上始终弱于SwinIR之外, 它在几乎所有其他任务上都获得了相当可观的性能。

3.5 Analysis

在本节中, 我们通过分析不同任务和骨干网络的特征来解释上述观察结果。SR的退化在于局部信息的压缩, 导致高频细节的大量丢失。因此, SR网络往往需要很强的空间信息交互能力, 甚至生成能力。U型架构融合了多次下采样操作, 可能会破坏高频信息的重建, 直观上增加了细节重建的难度。相比之下, 保持特征尺寸的简单架构有利于SR。此外, 窗口自注意力已经表现出比卷积优越的局部拟合能力[8]。因此, 基于简单结构并采用空间自注意力算子的SwinIR在SR上表现出明显的优势。去噪需要平滑图像消除高频噪声并整合低频信息重建清晰的图像。这项任务对网络没有明确的独特要求, 而其性能直观地受益于有效的空间信息交互。据推测, Restormer 在去噪方面的高性能可归因于它能够通过通道处理更好地平滑噪声, 类似于操作

ability to better smooth noise through channel-wise processing, akin to operating




图 4: Restormer 和 SwinIR 之间的视觉和 LAM [16] 比较。LAM 结果和 DI 值表明 Restormer 比 SwinIR 利用了更多的信息。然而, SwinIR 比 Restormer 重建了更多的细节。

在频域中。相比之下, SwinIR 和 Uformer 表现良好, 因为它们具有强大的空间自注意力的空间信息交互能力。去模糊(特别是这里的运动模糊)涉及解决图像中的全局运动偏移。因此, 处理大尺寸输入的能力以及全局或多尺度信息的使用对于去模糊网络是必要的。因此, 基于U形架构的网络在此任务上都表现良好。相反, SwinIR 采用简单的架构, 更注重本地信息处理, 其性能比其他网络差得多。去雾也可以观察到类似的现象。由于雾霾模型涉及深度信息, 利用大范围甚至全局信息的能力至关重要。此外, 去雾网络需要处理低频变换, 包括颜色和对比度的改变, 这两者都构成了全局映射。因此, 更依赖局部空间信息交互的SwinIR和Uformer在这项任务上表现不佳。相反, Restormer表现出了优异的性能。除雨的比较独特之处在于, 雨水在图像中分布不均匀, 不同的雨滴和条纹之间存在显著差异。因此, 不同网络在去雨方面的性能没有明显的模式。然而, 复杂度较高的网络表现出更好的性能。基于上述结果和分析, 我们可以推断骨干网络在特定任务上的可接受性能是预测的满足该任务的功能要求。值得注意的是, Restormer 具有出色的任务通用性。这可以归因于几个因素: 1) U 形架构使网络能够容纳大尺寸输入。2) 转置的自注意力允许全局信息的直接交互。3) 深度卷积的存在使得网络能够有效地处理空间信息。综上所述, 由于Restormer功能全面, 能够满足不同任务的多样化需求。

it is capable of meeting the diverse requirements of different tasks.

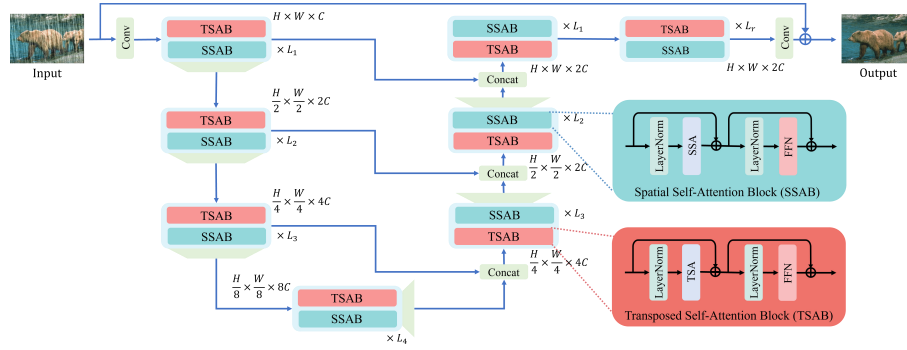


图5: X-Restormer的网络结构。为了增强Restormer的空间映射能力并创建更通用的网络，我们用空间自注意力块替换了Restormer中一半的转置自注意力块。对于TSA，我们保留Restormer中使用的初步多Dconv头转置注意（MDTA）。对于SSA，我们采用HAT [8]中的重叠交叉注意（OCA）。

4 通用骨干网设计

基于基准实验，我们认为设计通用骨干网络的原则应该是确保网络能够满足所有任务的功能要求。由于Restormer表现出相对较好的任务通用性，我们选择它作为设计更通用网络的起点。通过精确定位和解决Restormer的局限性，我们在本节中提出了通用图像恢复骨干网络的初始版本。Restormer的局限性。在基准实验中，Restormer在SR上的性能低于SwinIR，尤其是在Urban100上。图4中的定性比较也表明了这种现象。从视觉和LAM[16]结果中，我们可以观察到Restormer可以利用大范围甚至全局信息进行重建。然而，与SwinIR相比，它无法重建精细纹理，即使对于自我重复的图案也是如此。这种差异一方面可以归因于Restormer采用的U型架构，增加了高频信息重建的难度。另一方面，Restormer依靠深度卷积进行空间信息交互，其空间映射能力相对弱于SwinIR中的空间自注意力。考虑到U型架构对于某些任务是必不可少的，为了任务的通用性，我们仍然需要保留这种架构设计。为了克服Restormer的局限性并设计更强大的骨干网络，我们选择进一步增强其空间信息交互能力。一个直观可行的解决方案是将空间自注意力模块合并到Restormer.Network结构中。在图5中，我们展示了我们提出的骨干网络的结构，表示为X-Restormer。我们选择U型架构来构建网络。与Restormer相反，我们用空间自注意力块（SSAB）替换一半的转置自注意力块（TSAB）

posed self-attention blocks (TSAB) with spatial self-attention blocks (SSAB) to

增强空间信息交互能力。给定 中的输入 feature F ，两个块交替处理它：

$$F_t = F_{in} + TSA(LN(F_{in})), \quad (6)$$

$$F_{t_out} = F_t + FFN(LN(F_t)), \quad (7)$$

$$F_s = F_{t_out} + SSA(LN(F_{t_out})), \quad (8)$$

$$F_{out} = F_s + FFN(LN(F_s)), \quad (9)$$

其中， F_t 、 F_{t_out} 、 F_s 和 F_{s_out} 分别表示 TSAB 中的中间特征、TSAB 的输出、SSAB 中的中间特征和 SSAB 的输出。 F_{out} 表示两个连续块的输出，也作为以下两个块的输入。 $TSA(\cdot)$ 和 $SSA(\cdot)$ 表示转置自注意 (TSA) 和空间自注意 (SSA) 模块。 $LN(\cdot)$ 表示层归一化， $FFN(\cdot)$ 表示前馈网络。具体来说，我们采用 Multi-Dconv Transpose Attention (MDTA) 作为 TSA 模块。它首先通过应用 1×1 卷积和 3×3 深度卷积来生成查询 (Q)、键 (K) 和值 (V)。然后，通过重构 Q 和 K 的点积以及 Softmax 函数来计算大小为 $R \times C \times C$ 的通道注意力矩阵。TSA 的示意图如图3所示。最后，结果由注意力矩阵和 V 的点积生成。对于 SSA，我们采用 HAT 模型[8]中引入的重叠交叉注意 (OCA)。我们选择 OCA 是因为 SwinIR 中的移位窗口机制直观上不适合我们的 TSA-SSA 连续块，而 HAT 证明了 OCA 的有效性和优越性。对于具体计算，Q 是通过将输入划分为非重叠窗口而产生的，而 K 和 V 是通过将输入划分为具有手动设置重叠大小的重叠窗口而生成的。除了窗口划分方法不同之外，OCA 的计算本质上与标准窗口自注意力的计算相同。对于 FFN，我们采用 Restormer 中使用的门控 Dconv 前馈网络 (GDFN) 架构。GDFN 没有使用两个 1×1 卷积来构造 MLP，而是首先通过两个 3×3 深度卷积和 1×1 卷积来处理输入特征。然后，通过逐元素乘法组合所得特征，并通过另一个 1×1 卷积以产生最终输出。我们还尝试了 SSAB 和 TSAB 的多种设计选择。实验可以在补充中找到。我们强调，我们对 X-Restormer 的设计并不是为了开发新颖的架构或模块来提高某些任务的性能，而是根据通用骨干网络设计的原则，通过尽可能简单的手段来增强网络的任务通用性。

5 实验

5.1 实验设置

我们在基准实验中使用的相同数据集上对所提出的 X-Restormer 进行了实验。对于网络实现，网络采用 4 级编码器-解码器，具有三倍下采样和

work employs a 4-level encoder-decoder with three times down-sampling and

表 3: $\times 4$ 图像 SR 上的定量结果。* 表示在 $\times 2$ SR 上预训练的模型。

Model	Set5	Set14	BSD100	Urban100	Manga109
RCAN	32.63/0.9002	28.87/0.7889	27.77/0.7436	26.82/0.8087	31.22/0.9173
RCAN-it	32.69/0.9007	28.99/0.7922	27.87/0.7459	27.16/0.8168	31.78/0.9217
SwinIR*	32.92/ <u>0.9044</u>	<u>29.09/0.7950</u>	27.92/0.7489	27.45/0.8254	<u>32.03/0.9260</u>
IPT	32.64/-	29.01/-	27.82/-	27.26/-	-/-
EDT	32.82/0.9031	<u>29.09/0.7939</u>	27.91/0.7483	27.46/0.8246	32.05/0.9254
NAFNet	32.79/0.9010	29.03/0.7919	27.86/0.7463	27.00/0.8112	31.77/0.9216
SwinIR	32.88/0.9041	29.07/0.7944	<u>27.93/0.7490</u>	<u>27.47/0.8258</u>	31.96/0.9255
Restormer	<u>32.94/0.9039</u>	29.06/0.7934	27.91/0.7482	27.32/0.8199	31.96/0.9244
X-Restormer	33.16/0.9058	29.17/0.7963	28.00/0.7512	27.66/0.8291	32.38/0.9279

表 4: 噪声水平 $\sigma = 50$ 时图像去噪的定量结果。

Model	CBSD68	Kodak24	McMaster	Urban100
FFDNet	27.96/-	28.98/-	29.18/-	28.05/-
RNAN	28.27/-	29.58/-	29.72/-	29.08/-
RDN	28.31/-	29.66/-	-/-	29.38/-
IPT	28.39/-	29.64/-	29.98/-	29.71/-
DRUNet	28.51/-	29.86/-	30.08/-	29.61/-
SwinIR	28.56/0.8118	29.95/0.8221	30.20/0.8489	29.88/0.8861
Uformer	28.55/ <u>0.8130</u>	29.97/ <u>0.8244</u>	30.16/0.8485	29.98/ <u>0.8900</u>
Restormer	<u>28.60/0.8130</u>	<u>30.01/0.8237</u>	<u>30.30/0.8517</u>	<u>30.02/0.8898</u>
X-Restormer	28.63/0.8138	30.05/0.8245	30.33/0.8518	30.24/0.8928

表 5: 图像去模糊（运动模糊）的定量结果。表 6: 图像去雨的定量结果。

Model	GoPro	HIDE	RealBlur-R	RealBlur-J
SPAIR	32.06/0.953	30.29/0.931	-/-	28.81/0.875
MIMO-U-Net+	32.45/ <u>0.957</u>	29.99/0.930	35.54/0.947	27.63/0.837
IPT	32.52/-	-/-	-/-	-/-
MPRNet	<u>32.66/0.959</u>	30.96/ 0.939	35.99/0.952	28.70/0.873
Uformer	33.05/0.942	30.89/0.920	<u>36.19/0.956</u>	29.09/0.886
NAFNet	<u>33.08/0.942</u>	<u>31.22/0.924</u>	35.97/0.952	28.32/0.857
Restormer	32.92/0.940	<u>31.22/0.923</u>	<u>36.19/0.957</u>	<u>28.96/0.879</u>
X-Restormer	33.44/0.946	31.76/0.930	36.27/0.958	28.87/0.878

Model	Test100	Rain100H	Rain100L	Test1200	Test2800
PreNet	24.81/0.851	26.77/0.858	32.44/0.950	31.36/0.911	31.75/0.916
MSPFN	27.50/0.876	28.66/0.860	32.40/0.933	32.39/0.916	32.82/0.930
MPRNet	30.27/0.897	30.41/0.890	36.40/0.965	32.91/0.916	33.64/0.938
SPAIR	30.35/0.909	30.95/0.892	36.93/0.969	<u>33.04/0.922</u>	33.34/0.936
SwinIR	30.05/0.900	30.45/0.895	37.00/0.969	30.49/0.893	<u>33.63/0.940</u>
NAFNet	30.33/0.910	32.83/0.914	36.96/0.971	32.58/ <u>0.922</u>	32.15/0.933
Restormer	<u>32.03/0.924</u>	31.48/ <u>0.905</u>	<u>39.08/0.979</u>	33.22/0.927	34.21/0.945
X-Restormer	32.21/0.927	<u>32.09/0.914</u>	<u>39.10/0.978</u>	32.31/0.919	<u>33.93/0.945</u>

Table 7: Quantitative results on image dehazing.

Model	PFDN	FFA-Net	AECR-Ne	MAXIM	DehazeFormer	MPRNet	NAFNet	Restormer	X-Restormer
SOTS Indoor	32.68/0.976	36.39/0.989	37.17/0.990	39.72/-	40.05/ 0.996	40.34/0.994	38.97/0.994	<u>41.97/0.994</u>	42.90/0.995

上采样。为了保持与 Restormer 类似的参数数量，从 level-1 到 level-4（即图中的 L 1 ~ L 4），连续块（包含 TSAB 和 SSAB）的数量为 [2, 4, 4, 4]，细化块的数量（即 L r）为 4。TSA 和 SSA 中的注意力头均为 [1, 2, 4, 8]，通道数为 [48, 96, 192, 384]。对于 OCA，窗口大小和重叠率设置为 8 和 0.5，如 HAT 中一样。GDFN 中的通道扩展因子为 2.66。整体参数为 26.06M，略小于 Restormer 的 26.13M。我们在基准实验中采用与 Restormer 相同的训练设置来优化模型。我们使用 AdamW 优化器， $\beta_1 = 0.9$ 和 $\beta_2 = 0.99$ ，初始学习率为 $3e-4$ 。学习率衰减遵循余弦调度器，间隔为 92k 和 208k 迭代，总训练迭代为 300K。输入块大小为 256×256 ，批量大小为 32。对于数据增强，我们使用水平和垂直翻转。我们利用 L1 损失函数来训练模型。值得注意的是，我们没有采用任何训练技巧（例如， $\times 2$ SR 预训练或 EMA 策略）或测试技巧（例如，TLC [11]）。

5.2 实验结果

我们将我们的 X-Restormer 与基准实验中的前三个模型（基于相同的测试配置）以及每个任务的几种最先进的方法（基于他们论文中报告的性能）进行比较。PSNR(dB)/SSIM 如下表所示。最好和第二好的性能结果用粗体和下划线表示。

second-best performance results are in **bold** and underline.

图像SR。在选项卡中。在图 3 中, 我们展示了 $\times 4$ SR 在五个基准数据集上的定量结果: Set5 [2]、Set14 [50]、BSD100 [31]、Urban100 [18] 和 Manga109 [33]。本实验比较了艺术方法, 包括 RCAN [57]、RCAN-it [27]、SwinIR [35]、IPT [4] 和 EDT [22]。X-Restormer 在 Set5 上明显优于 Restormer 0.22dB, 在 Urban100 上优于 Restormer 0.34dB, 在 Manga109 上优于 Restormer 0.42dB。这证明了我们的设计在增强 Restormer 的空间测绘能力方面的有效性。此外, X-Restormer 在 Urban100 上超过 SOTA 方法 EDT 0.2dB, 在 Manga109 上超过 SOTA 方法 EDT 0.35dB, 表明 X-Restormer 在 SR 上的有效性。尽管如此, 我们指出我们的方法仍然无法击败最强大的 SR 方法, 例如 HAT。这是由于 U 型架构的 SR 性能不可避免地减弱。就 SR 而言, 残差架构中的 plain 残差仍然更有效。图像去噪。在选项卡中。如图 4 所示, 我们提供了噪声水平 $\sigma = 50$ 的高斯在四个基准数据集上的定量结果: CBSD68 [32]、Kodak24 [13]、McMaster [56] 和 Urban100 [18]。本实验比较了最先进的方法: FFDNet [55]、RNAN [58]、RDN [60]、IPT [4] 和 DRUNet [52]。X-Restormer 实现了最先进的性能, 在 Urban100 上超越 SwinIR 0.36dB, 超越 Restormer 0.22dB。这证明了 X-Restormer 在图像去噪、图像去模糊方面的优越性。在选项卡中。如图 5 所示, 我们将 X-Restormer 的结果与最先进的方法进行比较: SPAIR [36]、MIMO-UNet+ [10]、IPT [4] 和 MPR-Net [49] 在两个合成数据集上 (Gopro [34] 和 HIDE [39]) 和真实世界数据集 (RealBlur-R 和 RealBlur-J [38])。X-Restormer 在合成数据集上比其他模型取得了巨大的性能提升, 与 NAFNet 4 相比, Gopro 上的性能提高了 0.36dB, 与 Restormer 相比, HIDE 上的性能提高了 0.54dB。此外, 我们的 X-Restormer 在 RealBlur-R 上获得了最先进的性能, 在 RealBlur-J 上获得了相当可观的性能, 显示了我们的方法在现实世界运动去模糊场景中的有效性。图像去雨。在选项卡中。如图 6 所示, 我们给出了 Test100 [19]、Rain100L [47]、Rain100H [47]、Test1200 [51] 和 Test2800 [15] 的除雨定量结果。对最先进的方法: PreNet [37]、MSPFN [20]、MPRNet [49] 和 SPAIR [36] 进行了比较。X-Restormer 在 Test100、Rain100H 和 Rain100L 上的表现优于其他型号, 但在 Test1200 和 Test2800 上的表现不如 Restormer。这种差异是由于不同降雨模型产生的退化差异造成的。尽管如此, X-Restormer 仍表现出与最先进方法相当的性能, 显示了其在图像去雨方面的有效性。图像去雾。在选项卡中。7, 我们提供了 SOTS Indoor [21] 的定量结果。我们在本实验中比较了最先进的方法: PFDN [12]、FFA-Net [46]、AECR-Net [44]、MAXIM [41] 和 DehazeFormer [40]。值得注意的是, X-Restormer 模型的性能明显优于 Restormer, 相差 0.93dB。与最先进的去雾方法 Dehaze-Former 相比, 我们的方法实现了 2.85 dB 的突破性性能增益。这些结果证明了 X-Restormer 在图像去雾方面的优越性。

⁴ By using TLC, on Gopro/HIDE, NAFNet: 33.69/31.32, X-Restormer: 33.89/31.87.

表 8: 一体式修复的定量结果。

Model	SR		Denoising			Deblurring	Deraining	Dehazing
	$\times 2$	$\times 4$	$\sigma = 15$	$\sigma = 25$	$\sigma = 50$			
MPRNet	33.68/0.9300	28.17/0.8043	34.27/0.9280	31.82/0.8901	28.60/0.8119	30.00/0.8812	31.20/0.9068	35.06/0.9874
SwinIR	33.83/0.9301	28.14/0.8043	34.27/0.9283	31.83/0.8906	28.59/0.8143	29.06/0.8519	30.03/0.8983	31.48/0.9823
Uformer	29.99/0.8805	27.88/0.7949	33.86/0.9254	31.42/0.8863	27.87/0.7891	29.64/0.8725	27.53/0.8569	29.92/0.9714
Restormer	<u>34.51/0.9341</u>	<u>28.70/0.8179</u>	<u>34.43/0.9303</u>	<u>32.02/0.8942</u>	<u>28.87/0.8222</u>	<u>30.54/0.8902</u>	<u>31.91/0.9134</u>	<u>36.95/0.9897</u>
NAFNet	34.12/0.9314	28.17/0.8087	34.18/0.9281	31.76/0.8908	28.64/0.8187	30.38/0.8911	31.56/0.9149	30.84/0.9797
X-Restormer	34.72/0.9360	28.81/0.8217	34.67/0.9330	32.26/0.8983	29.12/0.8293	30.85/0.8983	32.27/0.9229	38.24/0.9914

一体式修复。我们对一体化恢复设置进行了实验，以展示不同骨干网络在同时处理各种任务时的有效性。网络接受具有不同降级级别的五项任务的训练（即，SR 的 $\times 2$ 、 $\times 4$ 和去噪的 $\sigma \in (0, 50)$ 随机级别）。每个任务的采样概率相同，并计算基准数据集上的平均性能。如表所示。如图8所示，Restormer在现有网络中具有相对较好的任务通用性，在一体式恢复方面表现出更好的性能。通过克服Restormer的限制，我们的X-Restormer在同时处理多个任务方面展示了进一步的优势，其在所有任务上的性能远远超过其他网络。相比之下，其他网络或多或少受到不同任务之间优化冲突的影响（例如，即使在SR上，SwinIR的性能也低于Restormer）。这些表明通用主干网络对于构建处理多个图像恢复任务的通用模型具有重要意义，可以有效缓解任务冲突和性能下降。凭借增强的空间映射功能，我们的X-Restormer的性能明显优于Restormer。具体而言，X-Restormer在图像SR、去噪、去模糊、去雨和分别进行去雾，显示了我们设计的有效性。尽管很简单，X-Restormer在所有这五个任务上都获得了最先进的性能，并在比较方法中呈现出最佳的任务通用性。此外，我们表明更通用的骨干网络还可以更好地同时处理多个恢复任务。我们希望它能够激发更多关于通用图像恢复主干网络设计的工作。

六, 结论

在本文中，我们对现有的图像恢复骨干网络进行比较研究，以设计通用的骨干网络。选择五个代表性网络进行选定的五个任务的基准实验。结果表明，综合功能对于设计通用恢复骨干网络至关重要。我们选择Restormer作为基线，并引入空间自注意力来增强空间信息交互能力。实验结果表明，我们的X-Restormer取得了显著的性能提升，并呈现出最好的任务通用性。

significant performance improvement and presents the best task generality.

Acknowledgements

该工作得到了国家自然科学基金（批准号：62276251、62272450）和中科院香港联合实验室的部分资助。这项工作还得到了澳门科学技术发展基金 SKLIOTSC-2021-2023 和 0022/2022/A 的部分支持。

References

1. Abuolaim, A., Brown, M.S.: 使用双像素数据进行散焦去模糊。见：欧洲计算机视觉会议。第 111–126 页。施普林格 (2020) 2.
- Bevilacqua, M., Roumy, A., Guillemot, C., Morel, M.L.A.: 基于非负邻域嵌入的低复杂度单图像超分辨率。见：英国机器视觉会议 (BMVC) (2012)3.
- Cai, B., Xu, X., Jia, K., Qing, C., Tao, D.: Dehazenet: 用于单图像去雾的端到端系统。IEEE 图像处理交易 25(11), 5187–5198 (2016)4.
- 陈红、王云、郭天、徐成、邓勇、刘志、马胜、徐成、徐成、高文：预先训练的图像处理变压器。见：IEEE/CVF 计算机视觉和模式识别会议论文集。第 12299–12310 页 (2021)5.
- 陈L., 褚X., 张X., 孙J.: 图像恢复的简单基线。见：欧洲计算机视觉会议。第 17–33 页。施普林格 (2022) 6.
- Chen, L., Lu, X., Zhang, J., Chu, X., Chen, C.: Hinet: 用于图像恢复的半实例归一化网络。见：IEEE/CVF 计算机视觉和模式识别会议论文集。第 182–192 页 (2021)7.
- Chen, X., Wang, X., Zhang, W., Kong, X., Qiao, Y., Zhou, J., Dong, C.: 帽子：用于图像恢复的混合注意力变换器。arXiv 预印本 arXiv:2309.05239(2023)8.
- 陈X., 王X., 周J., 乔Y., 董C.: 在图像超分辨率转换器中激活更多像素。见：IEEE/CVF 计算机视觉和模式识别会议论文集。第 22367–22377 页 (2023)9.
- Chen, Z., Zhang, Y., Gu, J., Kong, L., Yang, X., Yu, F.: 用于图像超分辨率的双聚合变换器。见：IEEE/CVF 国际计算机视觉会议论文集。第 12312–12321 页 (2023)10.
- Cho, S.J., Ji, S.W., Hong, J.P., Jung, S.W., Ko, S.J.: 重新思考单图像去模糊中从粗到细的方法。见：IEEE/CVF 计算机视觉国际会议论文集。第 4641–4650 页 (2021)11.
- Chu, X., Chen, L., Chen, C., Lu, X.: 通过重新审视全局信息聚合来改进图像恢复。见：欧洲计算机视觉会议。第 53–71 页。施普林格 (2022) 12.
- Dong, J., Pan, J.: 基于物理的特征去雾网络。见：欧洲计算机视觉会议。第 188–204 页。施普林格 (2020) 13.
- Franzen, R.: 柯达无损真彩色图像套件。资料来源：<http://r0k.us/graphics/kodak> 4(2) (1999)14.
- Fu, X., Huang, J., Zeng, D., Huang, Y., Ding, X., Paisley, J.: 通过深度细节网络从单张图像中去除雨水。见：IEEE 计算机视觉和模式识别会议论文集。第 3855–3863 页 (2017)15.
- Fu, X., Huang, J., Zeng, D., Huang, Y., Ding, X., Paisley, J.: 通过深度细节网络从单张图像中去除雨水。见：IEEE 计算机视觉和模式识别会议论文集。第 3855–3863 页 (2017)

on computer vision and pattern recognition. pp. 3855–3863 (2017)

16. Gu, J., Dong, C.: 用本地归因图解释超分辨率网络。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 9199–9208 页 (2021)17. 何K., 张X., 任S., 孙J.: 图像识别的深度残差学习。见: IEEE 计算机视觉和模式识别会议论文集。pp. 770–778 (2016) 18. Huang, J.B., Singh, A., Ahuja, N.: 来自变换自我范例的单图像超分辨率。见: IEEE 计算机视觉和模式识别会议论文集。第 5197–5206 页 (2015)19. Huang, J.B., Singh, A., Ahuja, N.: 来自变换自我范例的单图像超分辨率。见: IEEE 计算机视觉和模式识别会议论文集。第 5197–5206 页 (2015)20. Jiang, K., Wang, Z., Yi, P., Chen, C., Huang, B., Luo, Y., Ma, J., Jiang, J.: 单图像去雨的多尺度渐进融合网络。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 8346–8355(2020)21 页。Li, B., Ren, W., Fu, D., Tao, D., Feng, D., Zeng, W., Wang, Z.: 单图像去雾及其他基准测试。IEEE 图像处理汇刊 28(1),492–505 (2018)22. Li, W., Lu, X., Qian, S., Lu, J., Zhang, X., Jia, J.: 基于 Transformer 的高效低级视觉图像预训练。arXiv 预印本 arXiv: 2112.10175 (2021)23. 李 Y.、张 Y.、蒂莫特 R.、范古尔 L.、涂 Z.、杜 K.、王 H.、陈 H.、李 W.、王 X.等人: Ntire 2023 图像去噪挑战: 方法和结果。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 1904–1920 页 (2023)24. Li, Y., Tan, R.T., Guo, X., Lu, J., Brown, M.S.: 使用层先验去除雨条纹。见: IEEE 计算机视觉和模式识别会议论文集。第 2736–2744 页 (2016)25. Liang, J., Cao, J., Sun, G., Zhang, K., Van Gool, L., Timofte, R.: Swinir: 使用 swin 变压器进行图像恢复。见: IEEE/CVF 国际计算机视觉会议论文集。第 1833–1844 页 (2021)26. Lim, B., Son, S., Kim, H., Nah, S., Mu Lee, K.: 用于单图像超分辨率的增强型深度残差网络。见: IEEE 计算机视觉和模式识别研讨会会议记录。第 136–144 页 (2017)27. Lin, Z., Garg, P., Banerjee, A., Magid, S.A., Sun, D., Zhang, Y., Van Gool, L., Wei, D., Pfister, H.: 回顾 rcan: 改进训练用于图像超分辨率 (2022) 28. 刘 J.、杨W.、杨S.、郭Z.: 擦除还是填充? 视频中的深层联合反复雨去除和重建。见: IEEE 计算机视觉和模式识别会议论文集。第 3233–3242 页 (2018)29. 刘L., 谢L., 张X., 袁S., 陈X., 周W., 李H., 田Q.: 磁带: 用于图像恢复的任务无关的先验嵌入。见: 欧洲计算机视觉会议。第 447–464 页。施普林格 (2022) 30. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swintransformer: 使用移动窗口的分层视觉变压器。见: IEEE/CVF 国际计算机视觉会议论文集。第 10012–10022(2021)31 页。Martin, D., Fowlkes, C., Tal, D., Malik, J.: 人类分割自然图像的数据库及其在评估分割算法和测量生态统计方面的应用。见: IEEE 国际计算机视觉会议论文集。卷。2, 第 416–423 页。IEEE (2001)

32. Martin, D., Fowlkes, C., Tal, D., Malik, J.: 人类分割自然图像的数据库及其在评估分割算法和测量生态统计方面的应用。见: IEEE 国际计算机视觉会议论文集。卷。2, 第 416-423 页。IEEE (2001) 33. Matsui, Y., Ito, K., Aramaki, Y., Fujimoto, A., Okawa, T., Yamasaki, T., Aizawa, K.: 使用 manga109 数据集进行基于草图的漫画检索。多媒体工具和应用 76(20), 21811–21838 (2017) 34. Nah, S., Hyun Kim, T., Mu Lee, K.: 用于动态场景去模糊的深度多尺度卷积神经网络。见: IEEE 计算机视觉和模式识别会议论文集。第 3883–3891 页 (2017) 35. 牛B., 文W., 任W., 张X., 杨L., 王S., 张K., 曹X., 沉H.: 单图像超分辨率通过整体注意力网络。见: 欧洲计算机视觉会议。第 191-207 页。施普林格 (2020) 36. Purohit, K., Suin, M., Rajagopalan, A., Boddeti, V.N.: 使用失真引导网络的空间自适应图像恢复。见: IEEE/CVF 国际计算机视觉会议论文集。第 2309–2319 页 (2021) 37. Ren, D., Zuo, W., Hu, Q., Zhu, P., Meng, D.: 渐进式图像去雨网络: 更好、更简单的基线。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 3937–3946 页 (2019) 38. Rim, J., Lee, H., Won, J., Cho, S.: 用于学习和基准去模糊算法的真实模糊数据集。见: 欧洲计算机视觉会议。第 184–201 页。施普林格 (2020) 39. Shen, Z., Wang, W., Lu, X., Shen, J., Ling, H., Xu, T., Shao, L.: 人类感知运动去模糊。见: IEEE/CVF 国际计算机视觉会议论文集。第 5572–5581 页 (2019) 40. Song, Y., He, Z., Qian, H., Du, X.: 用于单图像去雾的视觉变换器。IEEE Transactions on Image Processing 32, 1927–1941 (2023) 41. Tu, Z., Talebi, H., Zhang, H., Yang, F., Milanfar, P., Bovik, A., Li, Y.: Maxim: 用于图像处理的多轴 mlp。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 5769–5780 页 (2022) 42. Wang, X., Xie, L., Yu, K., Chan, K.C., Loy, C.C., Dong, C.: BasicSR: 开源图像和视频修复工具箱。https://github.com/XPixelGroup/BasicSR(2022) 43. Wang, Z., Cun, X., Bao, J., Zhou, W., Liu, J., Li, H.: Uformer: 一种用于图像恢复的通用 U 形变压器。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 17683–17693 页 (2022) 44. 吴红, 曲 Y., 林S., 周J., 乔R., 张Z., 谢Y., 马L.: 紧凑单图像去雾的对比学习。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 10551–10560 页 (2021) 45. Yang, W., Tan, R.T., Feng, J., Liu, J., Guo, Z., Yan, S.: 单幅图像的深层联合降雨检测与去除。见: IEEE 计算机视觉和模式识别会议论文集。第 1357–1366 页 (2017) 46. Yang, W., Tan, R.T., Feng, J., Liu, J., Guo, Z., Yan, S.: 单幅图像的深度联合降雨检测与去除。见: IEEE 计算机视觉和模式识别会议论文集。第 1357–1366 页 (2017) 47. Yang, W., Tan, R.T., Feng, J., Liu, J., Guo, Z., Yan, S.: 单幅图像的深度联合降雨检测与去除。见: IEEE 计算机视觉和模式识别会议论文集。第 1357–1366 页 (2017) 48. Zamir, S.W., Arora, A., Khan, S., Hayat, M., Khan, F.S., Yang, M.H.: Restormer: 用于高分辨率图像恢复的高效转换器。见: 会议记录

IEEE/CVF 计算机视觉和模式识别会议。第 5728–5739 页 (2022)49。

Zamir, S.W., Arora, A., Khan, S., Hayat, M., Khan, F.S., Yang, M.H., Shao, L.: 多阶段渐进图像恢复。见: IEEE/CVF 计算机视觉和模式识别会议论文集。第 14821–14831 (2021)50 页。Zeyde, R., Elad, M., Protter, M.: 使用稀疏表示进行单图像放大。见: 曲线和曲面国际会议。第 711–730 页。Springer (2010)51。张, H., 帕特尔, V.M.: 使用多流密集网络进行密度感知的单图像去雨。见: IEEE 计算机视觉和模式识别会议论文集。页 695–704 (2018)52。张, K., 李, Y., 左, W., 张, L., 范古尔, L., 蒂莫特, R.: 使用深度降噪器先验进行即插即用图像恢复。IEEE 模式分析和机器学习汇刊 44(10), 6360–6376 (2021)53。张K., 左W., 陈Y., 孟德., 张L.: 超越高斯去噪器: 深度CNN的残差学习用于图像去噪。IEEE 图像处理交易 26(7), 3142–3155 (2017)54。张K., 左W., 顾S., 张L.: 学习深度CNN去噪器进行图像恢复。见: IEEE 计算机视觉和模式识别会议论文集。第 3929–3938 页 (2017)55。张K., 左W., 张L.: Ffdnet: 针对基于CNN的图像去噪的快速灵活的解决方案。IEEE 图像处理汇刊 27(9), 4608–4622(2018)56。张, L., 吴, X., 布阿德斯, A., 李, X.: 通过局部定向插值和非局部自适应阈值进行颜色去马赛克。电子成像杂志20(2), 023016–023016 (2011)57。张, Y., 李, K., 李, K., 王, L., 钟, B., 付, Y.: 使用非常深的残差通道注意网络的图像超分辨率。见: 欧洲计算机视觉会议。第 286–301 页。施普林格 (2018) 58。张, Y., 李, K., 李, K., 钟, B., 付, Y.: 用于图像恢复的残余非局部注意网络。arXiv 预印本 arXiv: 1903.10082 (2019)59。张Y., 田Y., 孔Y., 钟B., 付Y.: 用于图像超分辨率的残差密集网络。见: IEEE 计算机视觉和模式识别会议论文集。第 2472–2481 页 (2018)60。张Y., 田Y., 孔Y., 钟B., 付Y.: 用于图像恢复的残差密集网络。IEEE 模式分析和机器学习汇刊 43(7),2480–2495 (2020)