

# 通过直方图转换器恢复恶劣天气条件下的图像

Shangquan Sun<sup>1,2</sup> , Wenqi Ren<sup>3,4†</sup> , Xinwei Gao<sup>5</sup>, Rui Wang<sup>1,2</sup> , and Xiaochun Cao<sup>3</sup> 

1 中国科学院信息工程研究所, 北京 100085 2 中国科学院大学网络安全学院, 北京 100049 3 中山大学深圳校区网络科学与技术学院, 深圳 518107 4 广东省信息安全技术重点实验室, 广州 510006, 腾讯 China5 微信事业群, 广东省深圳市, 518057shangquansun@gmail.com, renwq3@mail.sysu.edu.cn,

抽象的。基于变压器的恶劣天气图像恢复方法取得了重大进展。它们中的大多数使用沿通道维度或空间固定范围块内的自注意力来减少计算负载。然而, 这种折衷会导致捕获远程空间特征的限制。受到天气引起的退化因素主要导致相似的遮挡和亮度的观察的启发, 在这项工作中, 我们提出了一种有效的直方图变换器 (Histoformer) 来恢复受恶劣天气影响的图像。它由一种称为直方图自注意力的机制提供动力, 该机制将空间特征分类并分割成基于强度的箱。然后, 将自注意力应用于跨箱或每个箱内, 以选择性地关注动态范围的空间特征, 并一起处理长范围的类似退化像素。为了增强直方图自注意力, 我们提出了一种动态范围卷积, 使传统卷积能够对相似像素而不是相邻像素进行操作。我们还观察到常见的像素损失忽略了输出和真实值之间的线性关联和相关性。因此, 我们建议利用皮尔逊相关系数作为损失函数, 以强制恢复的像素遵循与地面实况相同的顺序。大量的实验证明了我们提出的方法的有效性和优越性。我们已经在 Github 上发布了代码。

关键词: 图像修复·恶劣天气去除·图像除雪·图像去雨·图像去雾·雨滴去除

---

† 通讯作者。

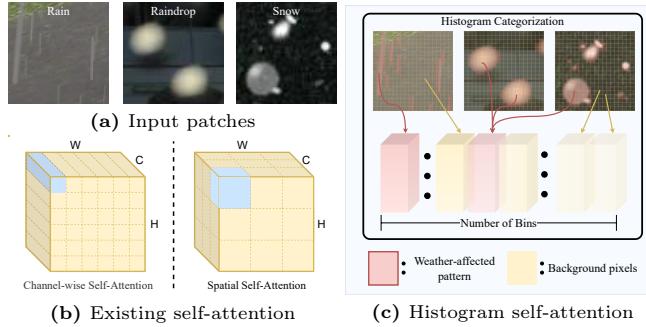


图 1：给定 (a) 中因天气原因而退化的图像，传统 Transformer 会沿着通道维度或在固定范围块内执行自注意力，如 (b) 所示。相比之下，我们观察到天气引起的退化模式往往与背景相似但又不同。因此，我们根据强度递减将受恶劣天气影响的像素和背景像素分类到不同的箱中（如 (c) 所示），然后在箱内和箱之间进行自注意力。

## 1 简介

计算机视觉领域对恢复受雨、雾、雪等恶劣天气条件影响的图像越来越感兴趣。这些天气条件显着降低了视觉质量，影响了目标检测 [3, 60] 和深度估计 [16, 18] 等下游任务的性能。因此，为了视觉美观和安全，恶劣天气下的图像恢复是一个至关重要的问题。早期的工作利用与天气相关的先验来模拟退化的统计特征并消除不利天气 [1, 2, 22, 23, 35, 76, 83, 95, 99]。随后，卷积神经网络 (CNN) 出现了作为解决除雨 [5, 17, 34, 40, 57, 73, 79, 80, 88, 89]、除雾 [27, 29, 62–64, 77, 88, 90, 92] 和除雪 [30, 44, 61, 94]。然而，每个任务需要单独训练网络以及多个模型之间切换的复杂性给实际应用带来了挑战。李等人。[33] 因此引入了恶劣天气去除的挑战，这需要使用单一统一模型恢复受各种天气条件影响的图像。最近，基于 Transformer 的方法也被研究用于恶劣天气去除任务，其效果超越了 CNN [11, 19, 70, 72]。尽管如此，这些基于 Transformer 的方法通常会在有效内存利用方面做出让步，将自注意力操作限制在固定的空间范围内或仅在通道维度内，如图 1b 所示。这种妥协阻碍了 Transformers 的内在潜力，而 Transformers 最初是为卓越的全局特征建模而设计的，因此，它导致了恢复性能的恶化。为了解决这些问题，基于对天气引起的退化通常表现出常见模式的观察，图 1a，我们开发了一个高效的直方图变压器来统一消除恶劣天气，命名为

efficient **Histogram Transformer** for unified adverse weather removal, named

组织形成者。具体来说，我们引入了动态范围直方图自注意力（DHSAs）模块，该模块赋予自注意力动态范围空间感受野。我们将强度接近但空间位置变化的像素值分类到直方图箱中。自注意力是在 bin 或频率维度上执行的，其过程如图 1c 所示。为了促进局部和全局尺度上的全面特征提取，我们设计了两种直方图自注意力重塑方法：按箱直方图重塑

(BHR) 和按频率直方图重塑 (FHR)。在 BHR 中，箱的数量被配置为包含跨越更全面的强度范围的像素，从而促进全局特征集成。在 FHR 中，分配的频率数量使得每个 bin 集中于有限数量的像素，从而增强了更精细特征的实用性。因此，直方图自注意力获得了有效建模空间动态范围的能力。为了使卷积能够提取动态定位的天气相关依赖性，我们开发了一个动态范围卷积层，其中涉及在可分离卷积的应用。为了捕获嵌入特征矩阵中的多尺度和多范围信息，我们引入了双尺度门控前馈

(DGFF) 模块，增强了其有效建模视觉特征的能力。此外，我们注意到传统的损失函数主要关注像素级的接近度，忽略了整体块级的相关性。因此，我们建议利用皮尔逊相关系数[12]来确保重建图像和干净图像之间的线性关系。我们的贡献可以概括为三个方面：

- 我们提出了一种新型变压器，旨在统一去除恶劣天气，配备新的直方图自注意力。它对天气引起的障碍物具有动态范围的空间关注，因此可以全局有效地实现退化消除。为了捕获多范围信息，我们提出了一个双尺度前馈模块。为了增强恢复图像和地面真实图像之间的全面线性关联，我们开发了相关损失。-我们的方法在各种数据集上获得了最先进的性能。此外，我们证实了所提出的方法的有效性恢复真实世界图像并支持检测的下游应用。

## 2 相关工作

广泛的研究致力于解决计算机视觉中的恶劣天气消除挑战，包括除雨等任务 [5, 17, 34, 40, 66, 73, 79, 80, 88, 89]，除雾 [27, 29, 62–64, 67, 77, 88, 90, 92]，除雪 [30, 44, 61, 94]，雨滴去除 [57, 59, 83, 93] 和多合一天气去除 [28, 33, 53, 70]。

雨纹去除。计算机视觉中的雨纹去除技术的方法的演变是值得注意的。康等人。[23]开创了单一图像  
removal techniques in computer vision. Kang et al. [23] pioneered a single image

使用双边滤波器将图像分解为低频和高频分量的去雨方法。然而，最近的进展已经见证了深度神经网络的主导地位。Fu 等人提出了早期的深度 CNN。[17]用于从高频降雨分量中提取特征，而 Yang 等人。[79]利用循环网络分解雨层并去除各种条纹类型。李等人。[32]提出了一种通过集成基于物理的降雨模型和对抗性学习来解决大雨场景中的雨条纹和遮蔽效应的方法。条件生成对抗网络也被用来解决雨条纹去除问题[89]。亚萨拉等人。[81]探索了从合成到真实世界降雨数据的迁移学习的高斯过程。全等人。[58]使用级联网络来去除雨痕和雨滴。最近，一种具有双 Transformer 架构的图像去雨 Transformer [78] 被精心设计，结合了基于窗口和基于空间的机制，从而获得了示范性的结果。还提出了稀疏去雨 Transformer 来增强特征聚合[11]。

雨滴去除。从单个图像中去除雨滴已经通过各种方法解决，其中一些方法依赖于传统的手工制作的功能。早期的工作结合了时间信息来解决基于视频的雨滴去除问题[83]。艾根等人。[15]采用了浅层 CNN，用包含雨滴降解版本和无雨滴版本的图像对进行训练，尽管结果经常表现出模糊。钱等人。[57]引入了注意力GAN和新的数据集。Quan 等人后来改进了他们的方法。[59]通过基于数学雨滴描述生成注意力图并将其与检测到的雨滴边缘相结合。

除雪。Desnow-Net [44] 是基于 CNN 的先驱除雪方法之一，其次是 Li 等人的堆叠密集网络 [31] 和 Chen 等人的 JSTASR [8]，后者引入了尺寸和透明度意识方法。最近，DDMSNet [94] 引入了一种密集的多尺度网络，利用语义和几何先验来增强除雪能力。还提出了一种涉及用于除雪的双树小波变换的层次分解范式[9]。陈等人。[7] 设计了 SnowFormer，一个使用交叉注意力来建立局部-全局上下文交互的框架。

除雾。李等人。[26]提出了一种考虑大气光度和传输图来进行去雾的 CNN。任等人。[63]提倡采用一种用于模糊图像处理的预处理方法，从而产生多种输入模式，并在此过程中引入色差作为其去雾过程的一部分。还引入了分层密度感知网络，专门研究图像去雾领域[92]。Zheng 等人。[97]制定了一种基于课程的对比正则化去雾方法，旨在促进对比空间内的一致性。

多合一天气消除。最近的一些工作试图通过单一网络来解决各种天气引起的退化问题。李等人。[33]提出了一个 weather-induced degradations by a singular network. Li *et al.* [33] proposed an

一体化网络，包含一个由多个特定于任务的编码器和一个共享解码器组成的生成器。瓦拉纳拉苏等人。[70]提出了 TransWeather，这是一种基于变压器的模型，具有单独的编码器-解码器结构，能够使受各种大气条件影响的图像恢复活力。还提出了自动选择天气退化数据的管道来增强现有模型[91]。朱等人。开发了 WGWS-Net [100]，能够在两个不同的阶段学习一般天气和特定天气。其他一些最近的工作也尝试通过采用概率去噪扩散模型[53]、知识蒸馏[10]、大规模预训练模型[68]、专家混合[49]、小样本学习[24]来解决恶劣天气去除问题。]、密码本[41,71,82]、自适应滤波器[54]、知识分配[74]和领域翻译[56]。

基于 Transformer 的图像恢复。自从用于视觉识别的视觉变换器 (ViT) [14] 诞生以来，变换器在一系列计算机视觉任务中获得了巨大的吸引力 [25,37,45,46,50,51,86]。特别是在该领域内针对低级视觉，图像处理转换器 [4] 举例说明了如何在广泛的数据集上预训练转换器可以显着提高低级应用的性能。另一方面，U-former [75] 引入了一种基于 U-Net 设计的变压器架构，用于恢复任务。Swin-IR [38] 采用 Swin Transformer [45] 进行图像恢复。一些最新的基于 Transformer 的方法被提出用于除雨 [11, 39]、除雪 [7]、除雾 [19, 43, 65] 和一体式天气去除 [70, 72]。与现有的基于 Transfomer 的方法不同，其自身-注意力应用于固定空间范围或仅通道维度，我们的方法使得动态范围空间注意力能够自适应地关注具有类似模式的天气引起的退化。

### 3 方法

#### 3.1 整体架构

我们的 Histoformer 的整体架构框架如图 2 所示。假设输入是低质量图像  $I_{lq} \in \mathbb{R}^{3 \times H \times W}$ ，我们将输入通过  $3 \times 3$  卷积来进行重叠图像块嵌入。在网络主干的编码器和解码器中，我们安排直方图变换器块 (HTB) 来提取复杂的特征并捕获动态分布的退化因素。在同一阶段内，编码器和解码器通过跳跃连接互连，从而在连续的中间特征之间建立连接，以增强训练过程的稳定性。在每个阶段之间，我们应用像素洗牌和像素洗牌操作来进行特征下采样和上采样。在每个 HTB 中，我们引入动态范围直方图自注意力 (DHSA) 来提取空间动态天气退化和增强局部和全局特征聚合。此外，双尺度门控前馈

cal and global feature aggregation. Moreover, a Dual-scale Gated Feed-Forward

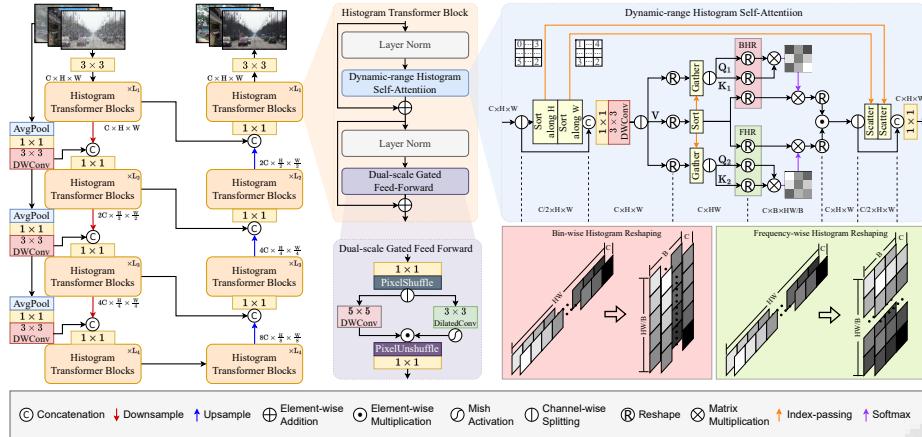


图 2：我们用于去除天气的 Histoformer 的整体架构。主要组件是直方图变换器块，它包括动态范围直方图自注意 (DHSA) 模块和双尺度门控前馈 (DGFF) 模块。在 DHSA 中，我们提出了两种类型的重塑机制，即 Bin-wise 直方图重塑和 Frequency-wise 直方图重塑。

(DGFF) 模块集成到 HTB 中，丰富了多范围特征的表示，有助于图像恢复过程。在编码阶段的每个阶段，我们的模型都配备了一个粗略的跳跃连接，用于补充输入中的原始特征，由一系列操作组成，包括平均池化、像素级卷积和深度级卷积。我们在第一阶段之后开始粗略的跳跃连接，这种设置使编码器能够更有效地专注于学习天气引起的残差。通过这种混合配方，Histoformer 能够利用与天气无关的背景的适应性内容和天气退化模式的固有特征，从而促进将不需要的退化与潜在的清晰背景分离。

### 3.2 直方图变压器块

HTB 作为我们 Histoformer 的关键组件，包含两个关键模块，即 DHSA 和 DGFF。这两个组件被安排为与层归一化相互作用，并且可以表述如下：

$$F_l = F_{l-1} + \text{DHSA}(\text{LN}(F_{l-1})), \quad (1)$$

$$F_l = F_l + \text{DGFF}(\text{LN}(F_l)), \quad (2)$$

其中 LN 表示层归一化， $F_l$  表示第 l 阶段的特征。DHSA 和 DGFF 的详细信息分别在 3.2 和 3.2 节中介绍。

动态范围直方图自我关注为了更好地捕获动态分布的天气引起的退化，我们开发了动态范围直方图  
distributed weather-induced degradation, we develop a Dynamic-range Histogram

自注意力 (DHS) 模块。该模块由涉及动态范围卷积的过程组成，该过程对分数特征的空间分布进行重新排序，以及结合全局和局部动态特征聚合的双路径直方图自注意机制。在  $1 \times 1$  逐点卷积的最终输出投影之前，重新排序的特征被重新排序回其原始位置以保持空间一致性。

动态范围卷积。传统的卷积运算采用固定的内核大小，导致感受野范围有限，因此执行局部和小范围的计算。卷积的这种受限范围主要关注局部信息，并不自然地与自注意力机制建模远程依赖性的能力相一致。为了解决这个限制，我们设计了一种动态范围卷积技术，在传统的卷积操作之前仔细地重新排序输入特征。给定一个输入特征  $F \in \mathbb{R}^{C \times H \times W}$ ，我们将其沿通道维度分为两个分支，即  $F_1$  和  $F_2$ 。对于特征的第一个分支，我们执行水平和垂直的排序操作，随后将排序后的特征与特征的第二个分支连接起来。然后将所得的重组特征传递给后续的可分离卷积。整个流程表述如下：

$$\begin{aligned} F_1, F_2 &= \text{Split}(F), \quad F_1 = \text{Sort}_v(\text{Sort}_h(F_1)), \\ F &= \text{Conv}_{3 \times 3}^d(\text{Conv}_{1 \times 1}(\text{Concat}(F_1, F_2))), \end{aligned} \quad (3)$$

其中  $\text{Conv } 1 \times 1$  表示  $1 \times 1$  逐点卷积， $\text{Conv } d3 \times 3$  表示  $3 \times 3$  深度卷积， $\text{Concat}$  表示沿通道的串联操作， $\text{Split}$  表示沿通道维度分割特征的操作， $\text{Sort}$  表示  $i \in \{h, v\}$  表示水平或垂直排序操作。这种方法将高强度和低强度的像素组织成矩阵对角处的规则图案，从而允许卷积在动态范围内执行计算。鉴于天气引起的退化通常表现出密切相关的模式，退化的像素往往集中在邻近位置，与那些干净的像素分开。因此，这种安排使卷积核能够部分专注于保留干净的信息并分别恢复退化的特征。

直方图自注意力。现有的视觉变形金刚 [11, 75, 78, 79, 86, 96] 通常利用固定范围的注意力，或者由于计算和内存效率的妥协而仅仅利用沿通道维度的注意力。然而，固定设置限制了自注意力自适应地跨越长范围以关联所需的特征。我们注意到，天气引起的退化会导致相似的模式，并且那些包含背景特征或不同强度的天气退化的像素最好被分配不同程度的关注。因此，我们提出了一种直方图自注意力机制，将空间元素分类到箱中，并在箱内和箱之间分配不同的注意力。为了并行计算，我们在实现时设置每个 bin 包含相同数量的像素。

number of pixels during implement.

给定动态范围卷积的输出，我们可以将它们分成值特征  $V \in R C \times H \times W$  和两对查询密钥  $F_{QK,1}, F_{QK,2} \in R 2C \times H \times W$ ，随后传递到两个分支。我们首先对  $V$  的序列进行排序，并根据其索引相应地排列 Query-Key 对，表示如下：

$$\begin{aligned} V, d = & \text{排序 } R C \times HWC \times H \times W (V), Q \\ 1, K_1 = & \text{分割聚集 } R C \times HWC \times H \times W \\ (F_{QK,1}), d, Q_2, K_2 = & \text{分割聚集 } R \\ C \times HWC \times H \times W (F_{QK,2}), d, & (F_{QK,2}), d, \end{aligned} \quad (4)$$

其中  $R C \times HWC \times H \times W$  表示将特征从  $R C \times H \times W$  重塑为  $R C \times HW$  的操作， $d$  是排序 Value 的索引，Gather 表示基于给定索引检索张量元素的操作。

然后给定 bin 的数量  $B$ ，我们将排序后的特征从  $C \times HW$  重塑为  $C \times B \times HW/B$ 。为了提取全局和局部信息，我们定义了两种类型的重塑，即分箱直方图重塑 (BHR) 和频率直方图重塑 (FHR)。第一个是分配 bin 的数量等于  $B$ ，每个 bin 包含  $HW/B$  元素，而第二个是将每个 bin 的频率设置为  $B$ ，并且 bin 的数量为  $HW/B$ 。通过这种方式，我们可以通过 BHR 提取大规模信息，其中每个 bin 包含大量动态定位的像素，并通过 FHR 提取细粒度信息，其中每个 bin 包含少量强度相邻的像素。这两对 Query-Key 特征分别经过两种类型的重塑和后续的自注意力过程，它们的输出按元素相乘以产生最终输出。该过程可以表述为以下表达式：

$$\begin{aligned} A_B &= \text{softmax} \left( \frac{\mathbf{R}_B(Q_1)\mathbf{R}_B(K_1)^\top}{\sqrt{k}} \right) \mathbf{R}_B(V), \\ A_F &= \text{softmax} \left( \frac{\mathbf{R}_F(Q_2)\mathbf{R}_F(K_2)^\top}{\sqrt{k}} \right) \mathbf{R}_F(V), \\ A &= A_B \odot A_F, \end{aligned} \quad (5)$$

其中  $k$  是头的数量， $R i \in \{B, F\}$  表示 BHR 或 FHR 的重塑操作， $A i \in \{B, F\}$  表示获得的注意力图。

双尺度门控前馈 先前的研究 [11, 75, 78, 86] 通常利用标准前馈网络中的单范围或单尺度卷积来支持局部上下文。尽管如此，这些方法往往忽视了动态分布的天气引起的退化之间的相关性。在实践中，不仅可以通过扩大核大小还可以利用膨胀机制来提取多尺度信息 [36, 84, 85]。因此，我们构思了一个双尺度门控前馈 (DGFF) 模块，它在传输过程中集成了两个不同的多范围和多尺度深度卷积路径。

the transmission process.

表 1：三个天气去除任务在 PSNR 和 SSIM 方面的定量比较，其中值越高表示性能越好。表格的上半部分显示特定任务方法的结果，而下半部分显示统一的多天气模型的评估。最好和第二好的结果用粗体和下划线表示。带\*的表示没有源代码的方法。

	(a) Image Desnowing				(b) Deraining & Dehazing				(c) Raindrop Removal				
	Snow100K-S [44]		Snow100K-L [44]		Outdoor-Rain [32]		RainDrop [57]		RainDrop [57]		RainDrop [57]		
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	
SPANet [73]	29.92	0.8260	23.70	0.7930	CycleGAN [98]	17.62	0.6560	pix2pix [20]	28.02	0.8547	DuRN [42]	31.24	0.9259
JSTASR [8]	31.40	0.9012	25.32	0.8076	pix2pix [20]	19.09	0.7100	RaindropAttn [59]	31.44	0.9263	AttentiveGAN [57]	31.59	0.9170
RESCAN [34]	31.51	0.9032	26.08	0.8108	HRGAN [32]	21.56	0.8550	IDT [78]	31.87	0.9313	MAXIM [69]	31.87	0.9352
DesnowNet [44]	32.33	0.9500	27.17	0.8983	PCNet [21]	26.19	0.9015	Restormer [86]	32.18	0.9408	Restormer [86]	32.18	0.9408
DDMSNet [94]	34.34	0.9445	28.85	0.8772	MPRNet [87]	28.03	0.9192						
NAPNet [6]	34.79	0.9497	30.06	0.9017	NAFNet [6]	29.59	0.9027						
Restormer [86]	36.01	0.9579	30.36	0.9068	Restormer [86]	30.03	0.9215						
All-in-One [33]*	-	-	28.33	0.8820	All-in-One [33]*	24.71	0.8980	All-in-One [33]*	31.12	0.9268	TransWeather [70]	30.17	0.9157
TransWeather [70]	32.51	0.9341	29.31	0.8879	TransWeather [70]	28.83	0.9000	Chen <i>et al.</i> [10]	31.81	0.9309	WGWSNet [100]	32.38	0.9378
Chen <i>et al.</i> [10]	34.42	0.9469	30.22	0.9071	Chen <i>et al.</i> [10]	29.27	0.9147	WeatherDiff64 [53]	30.71	0.9312	WeatherDiff4 [53]	30.71	0.9312
WGWSNet [100]	34.31	0.9460	30.16	0.9007	WGWSNet [100]	29.32	0.9207	WeatherDiff128 [53]	29.66	0.9225	WeatherDiff128 [53]	29.66	0.9225
WeatherDiff64 [53]	35.83	0.9566	30.09	0.9041	WeatherDiff64 [53]	29.64	0.9312	AWRCP [82]	31.39	0.9329	AWRCP [82]	31.93	0.9314
WeatherDiff128 [53]	35.02	0.9516	29.58	0.8941	WeatherDiff128 [53]	29.72	0.9216	Histoformer (Ours)	<b>32.08</b>	<b>0.9389</b>	Histoformer (Ours)	<b>33.06</b>	<b>0.9441</b>
AWRCP [82]*	36.92	0.9652	31.92	<b>0.9341</b>	AWRCP [82]	31.39	0.9329						
Histoformer (Ours)	<b>37.41</b>	<b>0.9656</b>	<b>32.16</b>	<b>0.9261</b>	Histoformer (Ours)	<b>32.08</b>	<b>0.9389</b>						

给定输入张量  $F_l \in \mathbb{R}^{C \times H \times W}$ ，我们最初采用逐点卷积运算将通道维度增加  $r$  倍。在这种增强之后，扩展的张量被引导到两个并行的分支中。在整个特征转换过程中，采用  $5 \times 5$  和扩展的  $3 \times 3$  深度卷积来增强多范围和多尺度信息的提取。遵循门控机制[13]，第二个分支的输出在经过激活后充当另一个分支的门控映射。因此，DGFF模块内完整的特征融合过程表述如下：

$$\begin{aligned} F_{l,1}, F_{l,2} &= \text{Split}(\text{Shuffle}(\text{Conv}_{1 \times 1}(F_l))), \\ F_{l,1} &= \text{Conv}_{5 \times 5}^d(F_{l,1}), \quad F_{l,2} = \text{Conv}_{3 \times 3}^{\text{dilated}}(F_{l,2}), \\ F_{l+1} &= \text{Conv}_{1 \times 1}(\text{Unshuffle}(\text{Mish}(F_{l,2}) \odot F_{l,1})), \end{aligned} \quad (6)$$

是  $3 \times 3$  膨胀的深度卷积，Shuffle 和 Unshuffle 分别表示像素洗牌和非洗牌的操作，Mish 表示 Mish 激活[52]， $F_{l+1}$  是当前阶段传递给的输出  $l+1$  级。

### 3.3 重建损失和相关损失

我们使用恢复的高质量图像  $I^{hq}$  和真实图像  $I^{gt}$  之间的像素级差异的 L1 范数作为重建损失，即

$$\mathcal{L}_{rec} = \|I^{hq} - I^{gt}\|_1. \quad (7)$$

此外，我们注意到  $L_{rec}$  只调节恢复图像和真实图像之间的像素级相似性，而忽略了块级线性相关性。图像中固有的强度关系被天气引起的退化的一致模式所破坏。经过 are disrupted by the consistent patterns of weather-induced degradation. By

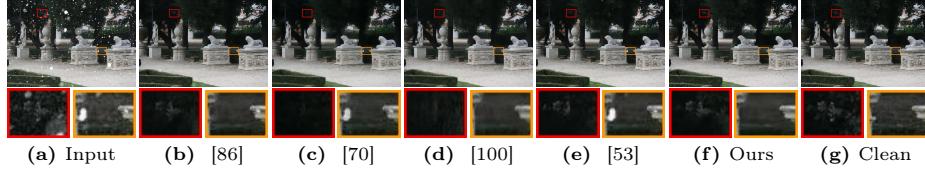


图3: Snow100K 上除雪的视觉比较[44]。 (b) 到 (e) 的样本是 Restormer [86]、TransWeather [70]、WGWSNet [100]、WeatherDiff [53]。

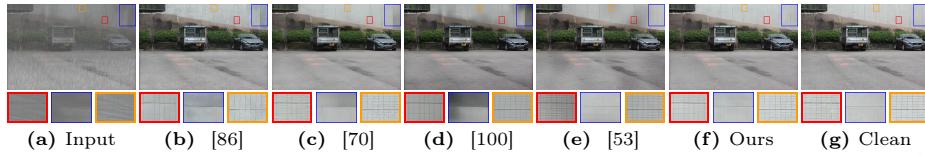


图4: Outdoor-Rain 上除雨和除雾的视觉比较 [32]。 (b)到(e)的样本是 Restormer [86]、TransWeather [70]、WGWSNet [100]、Weath-erDiff [53]。

模拟地面实况中的强度关系，我们迫使退化像素根据原始强度排名占据其原始位置。因此，我们引入图像之间的皮尔逊相关性[12]作为调节线性关系的手段，表达如下：

$$\rho(I^{hq}, I^{gt}) = \frac{\sum_{i=1}^{3HW} (I_i^{hq} - \bar{I}^{hq})(I_i^{gt} - \bar{I}^{gt})}{3HW\sigma(I^{hq})\sigma(I^{gt})}, \quad (8)$$

我在哪里  $\{ \cdot \}_i$  表示图像的第  $i$  个像素， $I^{\{ \cdot \}}$  和  $\sigma I^{\{ \cdot \}}$  分别表示图像序列的平均值和标准差。其值落在  $[-1, 1]$  范围内。当两幅图像表现出完全相关时，函数  $\rho$  的值为 1，而在负相关的情况下，其值为 -1。因此，我们将相关损失公式如下：

$$\mathcal{L}_{cor} = \frac{1}{2} (1 - \rho(I^{hq}, I^{gt})), \quad (9)$$

当恢复的图像与地面实况完美对齐时， $\mathcal{L}_{cor} = 0$ 。因此，整体损失函数定义为：

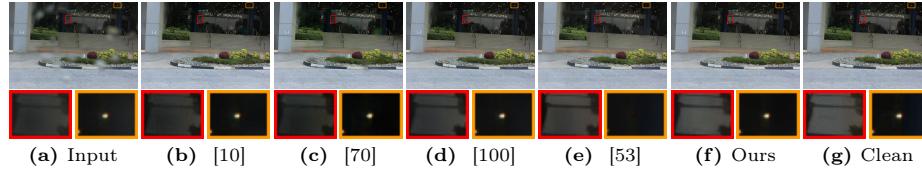
$$\mathcal{L} = \mathcal{L}_{rec} + \alpha \mathcal{L}_{cor}, \quad (10)$$

其中  $\alpha$  是相关损失的权重。

## 4 实验

### 4.1 实验设置

数据集。我们在与之前的作品[33,53,70]相同的数据集上训练我们的模型，以确保公平的比较。训练集包含 9,000 张绘制的图像[70] to ensure a fair comparison. The training set encompasses 9,000 images drawn



**Fig. 5:** Visual comparison for raindrop removal on RainDrop [57]. The samples from (b) to (e) are Chen *et al.* [10], TransWeather [70], WGWSNet [100], WeatherDiff [53].

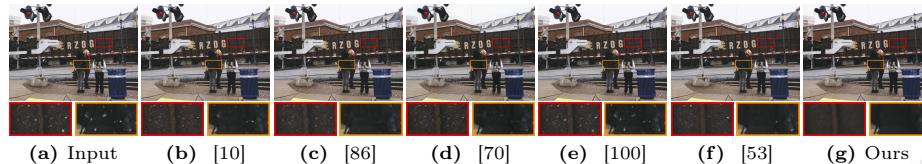


图 6: Snow100K 上现实世界恶劣天气去除的定性比较 [44]。(b) 至 (e) 的样本来自 Chen 等人。[10]、Restormer [86]、TransWeather [70]、WGWSNet [100]、WeatherDiff [53]。

来自 Snow100K [44], 1,069 张图像来自 Raindrop [57], 9,000 张图像来自 Outdoor-Rain [32]。Snow100K 包含因雪而恶化的合成图像，而 Raindrop 包含受雨滴影响的真实图像。户外雨具有受雾和雨条纹影响的合成图像。为了进行评估，我们使用 Test1 数据集 [32, 33]、RainDrop 测试数据集 [57] 以及 Snow100K-L 和 -S 测试集 [44]。Snow100K 还提供了真实世界的测试集，其中包括 1,329 张受恶劣天气影响的图像。

比较基线。我们根据专门针对不同天气去除任务设计的最先进方法来评估我们的方法的性能：去除雨滴、去除雪和去除雨雾。具体来说，对于除雪，我们以 SPANet [73]、JSTASR [8]、RESCAN [34]、Desnow-Net [44] 和 DDMSNet [94] 为基准。在去除雨雾的情况下，我们与 CycleGAN [98]、pix2pix [20]、HRGAN [32]、MPRNet [87] 和 Restormer [86] 进行比较。对于雨滴去除，我们针对 pix2pix [20] 等方法进行评估，DuRN [42]、RaindropAttn [59]、AttentiveGAN [57]。此外，我们在比较分析中还包括一些最近的变压器或多退化恢复网络，IDT [78]、NAFNet [6]、MAXIM [69] 和 Restormer [86]。值得注意的是，所有这些方法都是针对特定数据集进行微调的单任务网络。此外，我们与 Chen 等人的 All-in-Onenetwork [33] 进行了性能比较。[10]、TransWeather [70]、WGWSNet [100]、Weath-erDiff [53] 和 AWRCP [82]，它们经过训练可以使用统一模型处理所有上述任务。请注意，我们的方法还经过训练，可以使用单个模型来处理所有这些任务。

培训细节。我们的实现是通过 PyTorch [55] 和 NVIDIA Tesla V100 GPU 实现的。该网络总共训练了 300,000 次迭代，其中 Tesla V100 GPU. The network is trained for a total of 300,000 iterations, with

初始批量大小为 8，初始补丁大小为 128，类似于渐进式学习管道 [86]。我们使用 AdamW 优化器 [48]，在前 92,000 次迭代中初始学习率为  $3e-4$ ，在剩余的 208,000 次迭代中使用余弦退火计划 [47] 逐渐减少到  $1e-6$ 。每个阶段的块数  $L_i \in \{1, 2, 3, 4\}$  设置为  $\{4, 4, 6, 8\}$ ，通道大小  $C$  为 36。DGFF 中的通道扩展因子  $r$  设置为 2.667。不同阶段的 self-attention 中的 head 数量分别设置为  $\{1, 2, 4, 8\}$ 。我们随机应用水平和垂直翻转作为数据增强技术。

#### 4.2 与现有技术的比较

定量评价。在我们的研究中，我们对应用于合成数据集和真实数据集的指标进行了全面的比较分析，如表 1 所示。为了进行公平且有根据的比较，我们利用了最近的多种退化去除方法，例如 MPRNet [87]、MAXIM [69] 和 Restormer [86]，将它们视为每个基准的特定天气方法。此外，我们重新训练了包括 Chen 等人在内的一体化恶劣天气去除方法。[10] 和 WGWS-Net [100] 使用全天候训练数据集 [33, 53, 70]。这种详尽的比较表明，我们提出的方法在三种不同类型的退化中比现有方法表现出显着的性能优势。

定性评估。此外，我们对三个任务进行了视觉比较，结果分别如图 3、4 和 5 所示。图 6 显示了现实世界天气去除的案例。这些结果表明，我们的方法在全面消除雪退化（包括细雪点和大雪点）方面表现出色。相比之下，最近的 WeatherDiff [53] 方法仍然表现出一些残留的雪退化，并且其恢复细节的能力不是最佳的。当谈到恢复具有挑战性的天气条件时，我们的方法在消除复杂的雾霾和雨痕方面表现出色，与之前的方法相比，产生了视觉上吸引人的结果。

#### 4.3 消融研究

为了证实 Histoformer 中每个组件的有效性，我们对 Outdoor-Rain 进行了一系列消融研究 [32]。我们特别检查了动态范围卷积、DHSA 模块、DHSA 中的 bin 数量、DGFF 模块和相关损失的影响。

动态范围卷积。我们对动态范围卷积的两种设置进行了实验，即在卷积之前先水平排序，然后垂直排序，以及相反的顺序。此外，我们将它们与普通卷积进行了比较，结果如表 2 所示。正则排序操作使性能提高了 0.14 dB，并且排序操作的顺序对结果没有显着影响。

operations does not significantly affect the outcome.

表 2: 动态范围卷积的消融研究。

	Vanilla Conv	Verti.+Horiz.	Horiz.+Verti.
PSNR	31.94	32.03	<b>32.08</b>
SSIM	0.9377	0.9385	<b>0.9389</b>

表 3: 自注意力设计的消融研究

SA type	PSNR	SSIM
MDTA [86]	30.94	0.9278
TKSA [11]	31.12	0.9295
w/o BHR	31.05	0.9301
w/o FHR	31.79	0.9364
DHSA	<b>32.08</b>	<b>0.9389</b>

表 5: 前馈模块选择的消融研究

Feed-Forward	PSNR	SSIM
FFN [38]	31.32	0.9313
GDFN [86]	31.42	0.9347
DANB [96]	31.56	0.9351
MSFN [11]	31.78	0.9367
DGFF	<b>32.08</b>	<b>0.9389</b>

表 4: DHSA 中 Bin 数量的消融研究

#Bins in DHSA	PSNR	SSIM
12	30.43	0.9283
20	31.56	0.9312
28	31.94	0.9379
36	<b>32.08</b>	<b>0.9389</b>
44	Out of memory	

表6: 相关损失设置的消融研究

$\alpha$	PSNR	SSIM
w/o $\mathcal{L}_{cor}$	0	31.77
	0.1	32.01
w/ $\mathcal{L}_{cor}$	1	<b>32.08</b>
	5	32.03
	10	31.96
		0.9375

DHSA。为了评估所提出的 DHSA 模块的有效性，我们与两个基线进行比较，即多 Dconv 头转置注意力 (MDTA) [86] 和 top-k 稀疏注意力 (TKSA) [11]。此外，我们通过排除 BHR 分支或 FHR 分支来探索 DHSA 的两个附加设置。定量分析结果如表3所示。MDTA 和 TKSA 都整合了跨渠道的丰富信息，这可能会导致跨空间维度的远程信息的利用损失。虽然我们的直方图自注意力可以捕获空间长程信息，但使用单个 BHR 或单个 FHR 分支会忽略 bin 间或 bin 内关系，从而导致较差的结果。通过结合动态范围卷积和双分支直方图自注意力，能够提取远程空间特征，我们的 DHSA 增强了性能，与 TKSA 相比，PSNR 提高了 0.96 dB。

垃圾箱数量。为了评估 DHSA 中 bin 数量的影响，我们使用 5 个不同的值进行实验：12、20、28、36 和 44。结果如表 4 所示。据观察，增加 bin 数量会持续改善表现。然而，当 bin 的数量超过 44 时，就会导致内存不足错误。

DGFF。为了评估所提出的 DGFF 模块的有效性，我们与四个基线进行了比较：(i) 普通前馈网络 (FN) [38]，(ii) 门控 Dconv 前馈网络 (GDFN) [86]，(iii) 双自适应神经块 (DANB) [96]，以及 (iv) 混合尺度前馈网络 (MSFN) [11]。

ral block (DANB) [96]，and (iv) a mixed-scale feed-forward network (MSFN) [11].

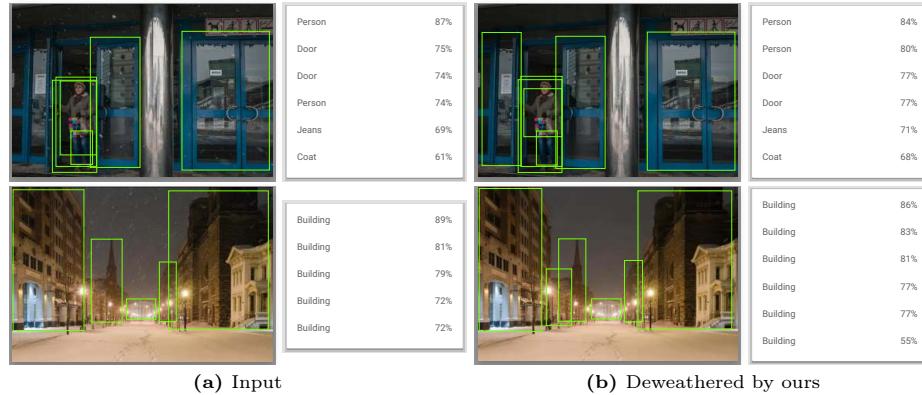


图 7: 两个雪图像 [44] 的真实世界去风化及其在 Google API 上的下游检测结果。

除非另有说明，本部分内容已获得 Creative Commons Attribution 4.0 许可证的认可 (<https://creativecommons.org/licenses/by/4.0/>)，代码示例已根据 Apache 2.0 许可证 (<https://www.apache.org/licenses/LICENSE-2.0>) 获得许可。有关详细信息，请参阅 Google 开发者网站政策 (<https://developers.google.com/site-policies>)。Java 是 Oracle 和其关联公司的注册商标。

定量分析结果如表5所示。虽然MSFN整合了混合尺度信息，但它仍然可能错过过多范围空间知识的开发。通过包含不同范围内的像素混洗和特征聚合，我们的 DGFF 进一步增强了性能，导致 PSNR 比 MSFN 提高了 0.3 dB。

相关损失。表6显示了相关损失Lcor的有效性及其权重的影响。很明显，L cor 持续提高了性能，而特定的损失重量对最终结果没有实质性影响。因此，我们默认将损失权重保留为 1。

#### 4.4 Real-world Application

为了进一步证明我们的方法在现实世界恶劣天气去除中的实际适用性及其改进下游检测任务的潜力，我们提供了图 7 中的两个示例。如图所示，我们的 Histoformer 有效地消除了场景中的雪花并协助检测器识别遗漏的门和建筑物。

#### 5 结论

在这项研究中，我们引入了一种称为直方图自注意力的新颖机制，并设计了一种名为 Histoformer 的新直方图转换器来解决一体化天气去除的挑战。我们的直方图自注意力涉及将空间特征分割成多个箱，并沿着箱或频率维度分配不同的注意力，使其能够选择性地关注具有动态范围的与天气相关的特征。为了便于学习多范围和多尺度信息，我们提出了 DGFF 模块和相关损失。通过广泛的实验，我们证明了我们方法的有效性和优越性。

riority of our approach.

## Acknowledgement

该工作得到国家自然科学基金 (No. 62322216、62172409、62025604、62306308、62311530686) 和深圳市科技计划 (批准号: JCYJ20220818102012025、KQTD2022110109355) 的资助9018), 部分由广东省重点信息安全技术实验室 (编号: 2023B1212060026)。

## References

1. Ancuti, C.O., Ancuti, C.: 通过多尺度融合进行单图像去雾。 IEEE TIP (2013)
2. Berman, D., Avidan, S. 等人: 非局部图像去雾。见: CVPR (2016)3。 Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S.: 使用 Transformer 进行端到端对象检测。见: ECCV (2020)4。陈红、王云、郭天、徐成、邓勇、刘志、马胜、徐成、徐成、高文: 预先训练的图像处理变压器。见: CVPR (2021)5。 Chen, J., Tan, C.H., Hou, J., Chau, L.P., Li, H.: CNN 框架中稳健的视频内容对齐和除雨补偿。见: CVPR (2018)6。陈L., 褚X., 张X., 孙J.: 图像恢复的简单基线。见: ECCV (2022)7。 Chen, S., Ye, T., Liu, Y., Chen, E., Shi, J., Zhou, J.: Snowformer: 通过上下文交互实现单图像除雪的尺度感知变压器。 arXiv 预印本arXiv: 2208.09703 (2022)8。 Chen, W.T., Fang, H.Y., Ding, J.J., Tsai, C.C., Kuo, S.Y.: Jstasr: 基于改进部分卷积和遮蔽效应去除的联合尺寸和透明度感知除雪算法。见: Vedaldi, A., Bischof, H., Brox, T., Frahm, J.M. (编辑) ECCV (2020)9。 Chen, W.T., Fang, H.Y., Hsieh, C.L., Tsai, C.C., Chen, I., Ding, J.J., Kuo, S.Y., et al.: 全部除雪: 使用分层双树复小波表示和矛盾的单图像除雪算法通道损耗。见: ICCV(2021)10。陈文涛、黄正坤、蔡长春、杨红辉、丁俊杰、郭诗云: 通过两阶段知识学习和多对比正则化学习多重恶劣天气去除: 走向统一模型。见: CVPR (2022)11。 Chen, X., Li, H., Li, M., Pan, J.: 学习稀疏变换网络以实现有效的图像去雨。见: CVPR (2023)12。 Cohen, I., Huang, Y., Chen, J., Benesty, J., Benesty, J., Chen, J., Huang, Y., Cohen, I.: 皮尔逊相关系数。语音处理中的降噪 (2009) 13. Dauphin, Y.N., Fan, A., Auli, M., Grangier, D.: 使用门控卷积网络进行语言建模。见: ICML (2017)14。 Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al: 一张图像相当于 16x16 个单词: 用于大规模图像识别的 Transformers。 arXiv preprint arXiv:2010.11929 (2020)15。 Eigen, D., Krishnan, D., Fergus, R.: 恢复通过被灰尘或雨水覆盖的窗户拍摄的图像。见: ICCV (2013)

covered with dirt or rain. In: ICCV (2013)

16. Fu, H., Gong, M., Wang, C., Batmanghelich, K., Tao, D.: 用于单目深度估计的深度序数回归网络。见: CVPR (2018)17。 Fu, X., Huang, J., Zeng, D., Huang, Y., Ding, X., Paisley, J.: 通过深度细节网络从单张图像中去除雨水。见: CVPR (2017)18。 Godard, C., Mac Aodha, O., Brostow, G.J.: 具有左右一致性的无监督单目深度估计。见: CVPR (2017)19。 Guo, C., Yan, Q., Anwar, S., Cong, R., Ren, W., Li, C.: 具有传输感知 3d 位置嵌入的图像去雾变换器。见: CVPR (2022)20。 Isola, P., Zhu, J.Y., Zhou, T., Efros, A.A.: 使用条件对抗网络进行图像到图像的翻译。见: CVPR (2017)21。 江凯、王中、易平、陈成、王中、王X、江建、林志伟: 无雨残渣手拉手: 用于实时图像去雨的渐进耦合网络。IEEE TIP (2021)22。 Jiang, T.X., Huang, T.Z., Zhao, X.L., Deng, L.J., Wang, Y.: 一种利用判别性内在先验的新型基于张量的视频雨条纹去除方法。见: CVPR (2017)23。 Kang, L.W., Lin, C.W., Fu, Y.H.: 通过图像分解自动去除基于单图像的雨纹。IEEE TIP (2011)24。 Kim, Y., Cho, Y., Nguyen, T.T., Lee, D.: Metaweather: 通过退化模式匹配恢复少镜头天气退化图像。arXiv preprint arXiv: 2308.14334 (2023)25。 Lai, Z., Wu, J., Chen, S., Zhou, Y., Hovakimyan, N.: 基于残差的语言模型是生物医学成像任务的免费助推器。见: CVPRW (2024)26。
- Li, B., Peng, X., Wang, Z., Xu, J., Feng, D.: Aod-net: 一体化去雾网络。见: ICCV (2017)27。 Li, B., Ren, W., Fu, D., Tao, D., Feng, D., Zeng, W., Wang, Z.: 单图像去雾及其他基准测试。IEEE TIP (2018)28。 Li, B., Liu, X., Hu, P., Wu, Z., Lv, J., Peng, X.: 未知腐败的一体化图像恢复。见: CVPR (2022)29。 Li, L., Dong, Y., Ren, W., Pan, J., Gau, C., Sang, N., Yang, M.H.: 半监督图像去雾。IEEE TIP (2019)30。李明, 曹X, 赵Q, 张L, 孟D: 监控视频在线除雨/除雪。IEEE TIP (2021)31。 Li, P., Yun, M., Tian, J., Tang, Y., Wang, G., Wu, C.: 用于单图像除雪的堆叠密集网络。神经计算 (2019) 32。 Li, R., Cheong, L.F., Tan, R.T.: 大雨图像恢复: 整合物理模型和条件对抗性学习。见: CVPR (2019)33。 Li, R., Tan, R.T., Cheong, L.F.: 使用建筑搜索一次性消除恶劣天气。见: CVPR (2020)34。 Li, X., Wu, J., Lin, Z., Liu, H., Zha, H.: 用于单图像去雨的循环挤压和激励上下文聚合网络。见: ECCV (2018)35。 Li, Y., Tan, R.T., Guo, X., Lu, J., Brown, M.S.: 使用层先验去除雨条纹。见: CVPR (2016)36。 Li, Y., Lu, J., Chen, H., Wu, X., Chen, X.: 用于高质量图像去雨的扩张卷积变换器。见: CVPRW (2023 年 6 月) 37。 Li, Z., Guan, B., Wei, Y., Zhou, Y., Zhang, J., Xu, J.: 映射新现实: 使用 pix2pix 图像到图像转换创建地面实况图像。arXiv 预印本 arXiv: 2404.19265 (2024)38。
- Liang, J., Cao, J., Sun, G., Zhang, K., Van Gool, L., Timofte, R.: Swinir: 使用 swin 变压器进行图像恢复。见: ICCV (2021)

restoration using swin transformer. In: ICCV (2021)

39.Liang, Y., Anwar, S., Liu, Y.: Drt: 一种轻量级单图像去雨递归变压器。见: CVPR (2022)40。刘J.、杨W.、杨S.、郭Z.: 擦除还是填充? 视频中的深层联合反复雨去除和重建。见: CVPR (2018)41。Liu, K., Jiang, Y., Choi, I., Gu, J.: 学习图像自适应码本以实现与类别无关的图像恢复。arXiv 预印本 arXiv: 2306.06513 (2023)42。Liu, X., Suganuma, M., Sun, Z., Okatani, T.: 利用配对操作潜力进行图像恢复的双残差网络。见: CVPR (2019)43。Liu, Y., Liu, H., Li, L., Wu, Z., Chen, J.: 通过视觉转换器实现非均匀去雾的以数据为中心的解决方案。见: CVPR (2023)44。Liu, Y.F., Jaw, D.W., Huang, S.C., Hwang, J.N.: Desnownet: 用于除雪的上下文感知深度网络。IEEE TIP (2018)45。Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin 变换器: 使用移位的分层视觉变换器视窗。见: ICCV (2021)46。刘Z., 宁J., 曹Y., 魏Y., 张Z., 林S., 胡H.: 视频swin变压器。见: CVPR (2022)47。Loshchilov, I., Hutter, F.: Sgdr: 随机梯度下降与热重启。arXiv 预印本 arXiv: 1608.03983 (2016)48。Loshchilov, I., Hutter, F.: 修复 Adam 中的权重衰减正则化。arXiv 预印本 arXiv: 1711.05101 (2017)49。罗Y.、赵R.、魏X.、陈J.、卢Y.、谢S.、王T.、熊R.、卢M.、张S.: Mowe: 天气专家的组合, 可消除多种恶劣天气。arXiv 预印本 arXiv: 2303.13739 (2023)50。Lyu, W., Zheng, S., Ling, H., Chen, C.: 针对具有注意力增强的变形金刚的后门攻击。见: ICLR 研讨会 (2023)51。Ma, H., Zeng, D., Liu, Y.: 通过多种治疗学习个体化治疗规则: 使用自适应融合的监督聚类方法。NeurIPS (2022) 52。Misra, D.: Mish: 自正则化非单调激活函数。arXiv 预印本 arXiv: 1908.08681 (2019)53。Özdenizci, O., Legenstein, R.: 使用基于补丁的去噪扩散模型在恶劣天气条件下恢复视力。IEEE TPAMI (2023)54。Park, D., Lee, B.H., Chun, S.Y.: 使用针对特定退化的自适应判别滤波器对未知退化进行一体化图像恢复。见: CVPR(2023)55。Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., 等人: Pytorch: 命令式高性能深度学习库。NeurIPS (2019)56。Patil, P.W., Gupta, S., Rana, S., Venkatesh, S., Murala, S.: 通过域转换进行多天气图像恢复。见: ICCV (2023)57。Qian, R., Tan, R.T., Yang, W., Su, J., Liu, J.: 用于从单个图像中去除雨滴的注意力生成对抗网络。见: CVPR (2018)58。全R.、于X.、梁Y.、杨Y.: 一次去除雨滴和雨痕。见: CVPR (2021)59。Quan, Y., Deng, S., Chen, Y., Ji, H.: 深度学习透过窗户看雨滴。见: ICCV (2019)60。Ren, S., He, K., Girshick, R., Sun, J.: 更快的 r-cnn: 使用区域提议网络进行实时对象检测。NeurIPS (2015)61。任文, 田静, 韩志, 陈爱, 唐阳: 基于矩阵分解的视频除雪除雨。见: CVPR (2017)

based on matrix decomposition. In: CVPR (2017)

62. Ren, W., Liu, S., Zhang, H., Pan, J., Cao, X., Yang, M.H.: 通过多尺度卷积神经网络的单图像去雾。见: ECCV (2016)63。
- Ren, W., Ma, L., Zhang, J., Pan, J., Cao, X., Liu, W., Yang, M.H.: 单图像去雾的门控融合网络。见: CVPR (2018)64。邵Y., 李L., 任W., 高C., 桑N.: 图像去雾的域适应。见: CVPR (2020)65。Song, Y., He, Z., Qian, H., Du, X.: 用于单图像去雾的视觉变换器。IEEE TIP (2023)66。Sun, S., Ren, W., Li, J., Zhang, K., Liang, M., Cao, X.: 通过多补丁渐进学习进行事件感知视频除雨。IEEE TIP (2023)67。Sun, S., Ren, W., Wang, T., Cao, X.: 重新思考目标检测的图像恢复。NeurIPS (2022)68。Tan, Z., Wu, Y., Liu, Q., Chu, Q., Lu, L., Ye, J., Yu, N.: 探索大规模预训练模型在逆境中的应用天气去除。arXiv preprint arXiv:2306.09008 (2023)69。Tu, Z., Talebi, H., Zhang, H., Yang, F., Milanfar, P., Bovik, A., Li, Y.: Maxim: 用于图像处理的多轴 mlp。见: CVPR (2022)70。
- Valanarasu, J.M.J., Yasarla, R., Patel, V.M.: Transweather: 基于Transformer 的恶劣天气条件退化图像恢复。见: CVPR (2022)71。万永昌、邵明文、程永生、刘永新、包志远、孟德云: 一次性恢复任意混合恶劣天气条件下拍摄的图像。arXiv 预印本 arXiv: 2305.09996 (2023)72。
- Wang, T., Zhang, K., Shao, Z., Luo, W., Stenger, B., Lu, T., Kim, T.K., Liu, W., Li, H.: Gridformer: 剩余密集变压器用于恶劣天气条件下图像恢复的网格结构。arXiv 预印本 arXiv: 2305.17863 (2023)73。Wang, T., Yang, X., Xu, K., Chen, S., Zhang, Q., Lau, R.W.: 使用高质量真实降雨数据集进行空间注意力单图像除雨。见: CVPR (2019)74。王勇、马成、刘杰: 智能分配: 学习除雨除雪的智能知识分配策略。见: CVPR (2023)75。Wang, Z., Cun, X., Bao, J., Zhou, W., Liu, J., Li, H.: Uformer: 一种用于图像恢复的通用 U 形变压器。见: CVPR (2022)76。Wei, W., Yi, L., Xie, Q., Zhao, Q., Meng, D., Xu, Z.: 我们应该将视频中的雨纹编码为确定性还是随机性? 见: ICCV (2017)77。吴红, 曲Y., 林S., 周J., 乔R., 张Z., 谢Y., 马L.: 紧凑单图像去雾的对比学习。见: CVPR (2021)78。肖建, 付新, 刘安, 吴芳, 查ZJ: 图像去雨变压器。IEEETPAMI (2022)79。Yang, W., Tan, R.T., Feng, J., Liu, J., Guo, Z., Yan, S.: 单幅图像的深度联合降雨检测和去除。见: CVPR (2017)80。Yasarla, R., Patel, V.M.: 不确定性引导的多尺度残差学习 - 使用循环旋转CNN进行单图像去雨。见: CVPR (2019)81。Yasarla, R., Sindagi, V.A., Patel, V.M.: 使用高斯过程进行图像去雨的 Syn2real 迁移学习。见: CVPR (2020)82。叶T., 陈S., 白J., 石J., 薛成., 江J., 尹J., 陈E., 刘Y.: 利用密码本去除恶劣天气先验。见: ICCV (2023)83。You, S., Tan, R.T., Kawakami, R., Mukaikawa, Y., Ikeuchi, K.: 视频中的粘附雨滴建模、检测和去除。IEEE TPAMI (2015)84。Yu, F., Koltun, V.: 通过扩张卷积进行多尺度上下文聚合。arXiv 预印本 arXiv: 1511.07122 (2016)85。Yu, F., Koltun, V., Funkhouser, T.: 扩张残差网络。见: CVPR (2017)
85. Yu, F., Koltun, V., Funkhouser, T.: Dilated residual networks. In: CVPR (2017)

86. Zamir, S.W., Arora, A., Khan, S., Hayat, M., Khan, F.S., Yang, M.H.: Restormer: 用于高分辨率图像恢复的高效变压器。见: CVPR (2022)87。Zamir, S.W., Arora, A., Khan, S., Hayat, M., Khan, F.S., Yang, M.H., Shao, L.: 多阶段渐进图像恢复。见: CVPR (2021)88。张, H., 帕特尔, V.M.: 使用多流密集网络进行密度感知的单图像去雨。见: CVPR (2018)89。张, H., 辛达吉, V., 帕特尔, V.M.: 使用条件生成对抗网络进行图像去雨。IEEE TCSVT (2019)90。张, H., 辛达吉, V., 帕特尔, V.M.: 使用深度网络的联合传输图估计和去雾。IEEE TCSVT (2019)91。张 H., 巴 Y., 杨 E., 梅赫拉 V., 盖拉 B., 铃木 A., 普法恩尔 A., 钱德拉帕 C.C., 黄 A., 卡达比 A.: Weatherstream: 单图像去风化的光传输自动化。见: CVPR (2023)92。张建, 任文, 张S., 张红, 聂Y., 薛Z., 曹X.: 分层密度感知去雾网络。IEEE 控制论学报 (2021)93。张凯, 李德, 罗文, 任文: 联合条纹和雨滴去除的双重注意力模型。见: IEEE TIP (2021)94。张, K., 李, R., 于, Y., 罗, W., 李, C.: 使用语义和深度先验的深度密集多尺度网络除雪。IEEE TIP (2021)95。张, X., 李, H., 齐, Y., Leow, W.K., 吴, T.K.: 通过结合时间和色彩特性去除视频中的雨水。见: ICME (2006)96。赵华、苟玉、李波、彭丹、吕杰、彭霞: 全面而细腻: 高效的图像修复转换器。见: CVPR (2023)97。郑 Y., 詹 J., 何 S., 董 J., 杜 Y.: 物理感知单图像去雾的课程对比正则化。见: CVPR (2023)98。Zhu, J.Y., Park, T., Isola, P., Efros, A.A.: 使用循环一致的对抗网络进行不配对的图像到图像的转换。见: ICCV (2017)99。Zhu, L., Fu, C.W., Lischinski, D., Heng, P.A.: 单图像雨条纹去除的联合双层优化。见: ICCV (2017)100。Zhu, Y., Wang, T., Fu, X., Yang, X., Guo, X., Dai, J., Qiao, Y., Hu, X.: 学习图像的天气一般特征和天气特定特征多种恶劣天气条件下的恢复。见: CVPR (2023) adverse weather conditions. In: CVPR (2023)