

电力线在不利天气下的空中图像恢复：数据集和基线

Sai Yang, Bin Hu, Bojun Zhou, Fan Liu, Member, IEEE, Xiaoxin Wu, Xinsong Zhang Member, IEEE, Juping Gu, Senior Member, IEEE, Jun Zhou, Senior Member, IEEE

摘要 电力线自主检查 (PLAI) 在智能电网的构建中起着至关重要的作用，因为其低成本，高效率和安全操作的优势很高。PLAI是通过准确检测到无人机（无人机）捕获的航空图像中的电气组件和缺陷来完成的。但是，雾气，雨或雪等不利的天气不可避免地会降低航空图像的可见质量，这些天气会大大降低我们的研究中的检测准确性。为了解决这个问题，我们在不利天气 (Plair-aw) 下提出了一项新的电源线航空图像修复任务，该任务旨在从恶劣天气的情况下从降级的图像中恢复清洁和高质量的图像，从而改善了PLAI的检测性能。在这种情况下，我们是第一个发布众多相应数据集的人，即HazeCplid, Hazettppla, Hazeintpla, Hazeinsplad用于电力线空中图像飞机飞行，RainCplid, Rainttplid, Rainttpla, 用于电力线的彩线图像驱逐，雪地，Snowcplid, Snowinsplad, Snowinsplad，用于电力线，电力线，航空图像播放的航空图像，达到了航空图像。根据数学模型，在CPLID, TTPLA, plaplaid的公共电源线航空图像数据集上合成。平均值，而我们从图像恢复社区中选择了许多最先进的方法作为Plair-aw的基线方法。最后，我们进行了大规模的经验实验，以评估拟议数据集上基线方法的性能。拟议的数据集和训练有素的模型可在<https://github.com/ntuhubin/plair-aw>上找到。

索引术语 “电力线自主检查，电源线空图像恢复，电源线空图像飞行，电源线空图像deraining，电源线的航空图像被淘汰。”

一、简介

毫无疑问，智能电网已成为普遍

世界各地未来电力系统的发展趋势[1], [2]。高架电源传输线是电力系统的关键基础设施，它们的工作

这项工作得到了中国国家自然科学的部分支持 (62372155, 62273188, U2066203, 61973178, 52377117)，Nantong Science和技术计划项目 (MS2023060)

通讯作者：Fan Liu和Juping Gu Sai Yang, Xiaoxin Wu, Xinsong Zhang曾在在中国Nantong University, Nantong University, Nantong University of Electrical Engineering and Automation学院，中国（电子邮件：yangsai@ntu.edu.cn, wu.xx, wu.xx, wu.xx@ntu.edu.cn, zhang_xs@ntu.edu.cn）bin hu曾在中国纳尔东大学 (Nantong University, Nantong University, Nantong University, Nantong) 的人工智能与计算机科学院 (226019) Bojun Zhou and Juping Gu是中国南东大学的信息科学技术学院，中国226019（电子邮件：zhoubj@ntu.edu.cn, gu.jp@ntu.edu.cn）。Juping Gu在苏州科技大学电子和信息工程学院，中国215009，(电子邮件：[gu.jp@ntu.edu.cn](mailto:fanliu@hhu.edu.cn))。Jun Zhou曾在澳大利亚QLD 4111的Griffith University, Griffith University的信息与通信技术学院任教（电子邮件：Jun.zhou@griffith.edu.au）。

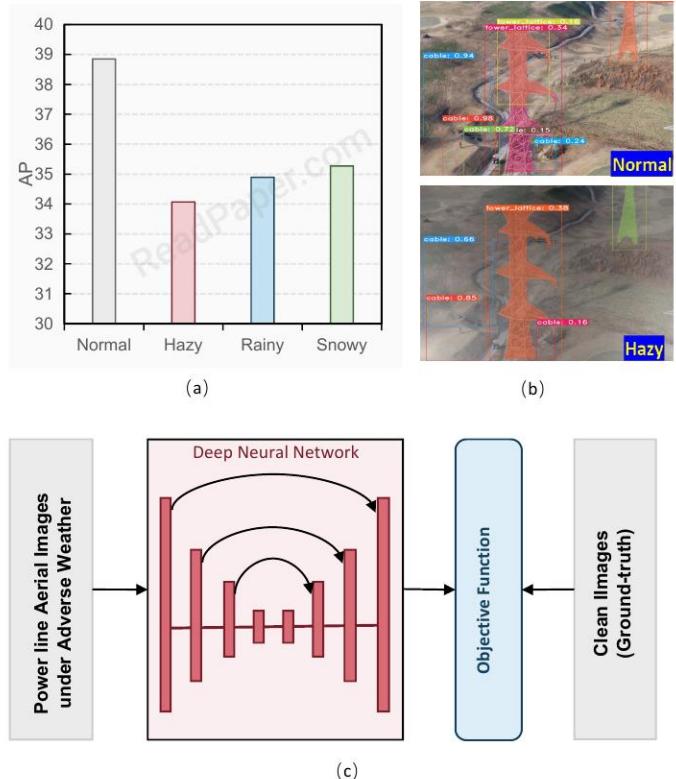


图1。 (a) 在正常，朦胧，多雨和下雪的条件下，高级实例分割模型的平均精度 (AP) 分别为TTPLA。与正常情况相比，不利天气的下降大幅下降。(b) 正常条件和朦胧状况之间的视觉比较表明，在朦胧的情况下存在错过和虚假检测。(c) 一般解决方案框架基于对电力线的深度学习，在不利天气 (Plair-aw) 下进行了空中图像恢复。在不利天气下的电源线航空图像输入了深神经网络，该网络输出了恢复的图像。然后，建立目标函数在基础和恢复的图像之间。深层神经网络通过目标函数进行了优化。训练后，将部署深度神经网络进行PLAIR-AW测试。

状态直接影响整个电力系统的稳定性和可靠性。电源线检查可以及时识别并消除潜在的危害，从而避免计划外的中断。传统的电力线检查方式是征服检查，这遭受着低效率和高风险的缺点。取而代之的是，由于低成本，高效率和安全的操作，使用无人机 (UAV) 的电力线自动检测 (PLAI) 逐渐成为主流检查方式。PLAI非常重要，可以保证安全，可靠和高效

智能电网的操作, 它受到了社区的越来越多的关注[3], [4]。

随着无人机和人工智能 (AI) 的发展, PLAI通常是通过检测到无人机捕获的空中图像中的深度学习技术[5] [9]中的深度学习技术来实现的。由于诸如阴霾, 雨水和雪之类的是不利天气是常见的现象, 因此在这种情况下捕获的空中图像不可避免地会严重降解颜色保真度, 模糊, 低对比度和遮盖物体, 从而严重降低了检测准确性。为了支持上述论点, 我们对YOLOACT的最新实例实例分割模型[11]进行了对TTPLA流行的电源线检查数据集[10]的试点研究。该实验分别通过普通图像, 朦胧的图像, 雨图像和雪图实施。我们选择平均精度 (AP) 作为性能度量标准, 并报告图1 (a) 中的结果, 其中朦胧, 多雨和下雪条件下的AP低于正常情况。在图1 (b) 中说明了正常状况与朦胧状况之间的视觉比较, 表明在朦胧的情况下出现了错过和虚假检测。为了提高PLAI的检测性能, 我们提出了在不利天气 (PLAIR-AW) 下进行电力线空中图像修复的新任务, 该任务试图从不利天气条件下由无人机捕获的降级图像中恢复清洁和高质量的图像。配对是一项高度挑战的任务, 因为它的性质不足。考虑到深神经网络的强大非线性表示功能, 我们根据图1 (c) 中的深度学习制定了一般解决方案框架。因此, 三个关键因素是数据, 模型体系结构和目标函数。其中, 数据是解决方案的先决条件, 而模型体系结构和目标函数由特定方法确定。因此, 我们为成对的深入研究提供了相应的数据集和基准。具体来说, 根据天气类型, 将对aw进一步细分为三个子任务, 即电力线航空图像飞行, 电源线空气图像排泄和电源线空中图像。我们根据CPLID [12], TTPLA [10], dipplad [13]的公共电源线空图数据集的每个单独子任务的数据集。遵循大气散射模型 (ASM) [14], [15], 我们构建了危险任务的Hazecplid, Hazettpla和Hazeinsplad的合成数据集。遵循全面的雨模型 (CRM) [16], 我们构建了用于降低任务的RainCplid, Rainttpla和Raininsplad的合成数据集。遵循Liu等人提出的数学模型。 [17], 我们构建了雪地板的合成数据集和雪地板的合成数据集, 以实现应有的任务。否则, 我们在图像恢复社区中选择了许多最先进的方法作为Plair-Aw的基线方法。最后, 我们进行了大规模的经验实验, 以评估拟议数据集上基线方法的性能。总而言之, 我们的主要贡献如下:

- 这是第一个在不利天气下提出新的电源线航空图像修复任务

(plair-aw), 它试图从不利天气条件下的无人机捕获的降级图像中恢复清洁和高质量的图像。这项研究对于满足对电力线自主检查的现实需求至关重要。

•我们是第一个在多个不良风雨下生成众多电力线航空图像数据集的人, 这可以为Plair-aw的研究提供强有力的支持。同时, 我们还为新的Plair-Aw任务提供了许多出色的基线方法。 •我们进行了大规模的经验实验, 以评估单一和多合一设置中提出的数据集上基线方法的性能。本文的其余部分如下组织。在第二节中, 我们主要制定数据集的生成过程, 以实现PLAIR-AW任务。在第三节中, 我们详细介绍了Plair-aw任务的基线方法。在第四节中, 我们描述了基线方法之间广泛的实验比较结果。最后, 我们在第五节中的一些未来研究方向提出了一个结论。

ii. 问题设置和数据集

如引言中所述, 足够的配对降级空中图像和干净的图像是基于深度学习的方法的先决条件。但是, 在正常和不利的天气条件下, 无人机捕获相同的场景。另外, 我们将朦胧, 多雨和白雪皑皑的图像综合在干净的图像上, 并在数学模型中使用模拟组件进行模拟组件, 以接近真正的不利天气环境。细节如下:

A. 电源线航空图像飞机

1) 数学模型: 在满足朦胧的天气时, 由于浮动颗粒, 朝相机的阳光将被更改为atso-themely a。同时, 现场的光被减弱为中型传输图t。朦胧的图像是由大气光A和中透射图t的联合作用形成的, 可以通过以下公式很好地描述大气散射模型 (ASM) :

$$H(x) = I(x)T(x) + A(1 - T(x)), \quad (1)$$

其中, x是像素位置, H (x) 和i (x) 分别表示朦胧的图像及其相应的清洁图像。 A是全球气氛。 t (x) 是中型跨任务图, 它主要由图像的场景深度确定, 并具有以下公式:

$$T(x) = e^{-\beta d(x)}, \quad (2)$$

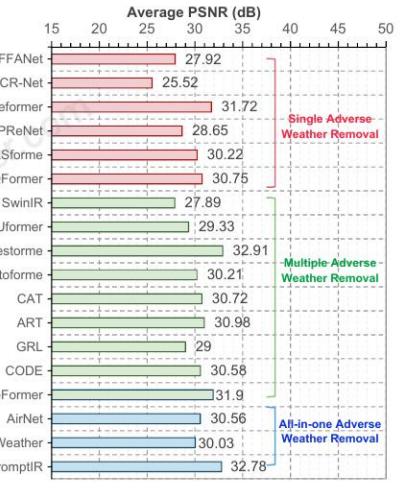
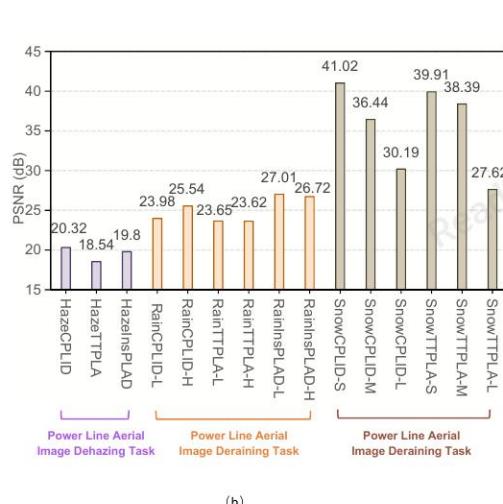
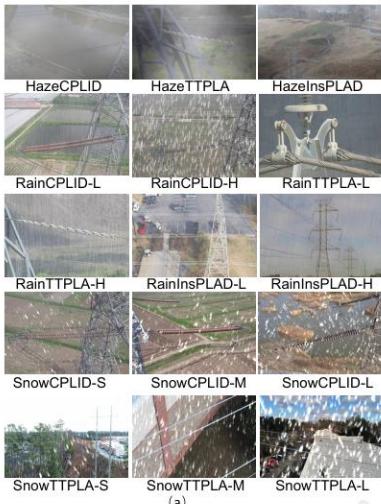
where, $\hat{\Gamma}^2$ is the atmosphere scattering parameter, and d(x) is the scene depth.

2) 电源线航空图像飞行数据集: 根据等式 (1) 和等式 (2), 我们可以看到朦胧过程由A, $\hat{\Gamma}^2$ 和D (x) 的三个参数确定。因此, 为了模拟朦胧条件的各种情况, a的值从0.4到0.6随机设置, 并且d的值是从 $5e^{-6}$ 随机设置为6。还,

表一

在不利天气 (PLAIR-AW) 任务下，提议的公共数据集的拟议公共数据集摘要。
â-â MEANS THERE IS NO SUBSET IN THIS DATASET.

Dataset	Type	Subset	Size	Numbers	train/test	Download Link
HazeCPLID	Dehazing	-	84x84	848	700/148	https://github.com/ntuhubin/PLAIR-AW/blob/main/Dehazing-DataSet.md
HazeTTPLA	Dehazing	-	512x512	1242	1000/242	https://github.com/ntuhubin/PLAIR-AW/blob/main/Dehazing-DataSet.md
HazeInsPLAD	Dehazing	-	1920x1080	10,607	7981/2626	https://github.com/ntuhubin/PLAIR-AW/blob/main/Dehazing-DataSet.md
RainCPLID	Deraining	RainCPLID-L/H	84x84	848	700/148	https://github.com/ntuhubin/PLAIR-AW/blob/main/Deraining-Datasets.md
RainTTPLA	Deraining	RainTTPLA-L/H	512x512	1242	1000/242	https://github.com/ntuhubin/PLAIR-AW/blob/main/Deraining-Datasets.md
RainInsPLAD	Deraining	RainInsPLAD-L/H	1920x1080	10,607	7981/2626	https://github.com/ntuhubin/PLAIR-AW/blob/main/Deraining-Datasets.md
SnowCPLID	Desnowing	SnowCPLID-S/M/L	84x84	848	700/148	https://github.com/ntuhubin/PLAIR-AW/blob/main/Desnowing-Datasets.md
SnowTTPLA	Desnowing	SnowTTPLA-S/M/L	512x512	1242	1000/242	https://github.com/ntuhubin/PLAIR-AW/blob/main/Desnowing-Datasets.md



选取 $d(x)$ 为无人机离地面的平均距离。上述操作在公共CPLID[12]、TTPLA[10]、InsPLAD[13]数据集上实现，产生如下去雾数据集：

* HazeCplid: 此数据集是基于CPLID [12]创建的，该数据集由848对朦胧和干净的图像组成。图像的大小为84 - 84。总图像分为700和148用于训练

和测试。 * Hazettpla: 此数据集是基于TTPLA [10] 创建的，该数据集由1242对的朦胧和干净的图像组成，大小为512×512像素。总图像分为1000和242进行培训

和测试。 * Hazeinsplad: 此数据集是基于Inplad [13]创建的，该数据集由1920×1080分辨率的10,607个配对的雪和干净的图像组成。总图像分为7981和2626张图像，用于培训和

测试。

B. 电源线航行图像

1) 数学模型: 由于多雨条件的并发症, 各种数学模型, 例如广告复合模型 (ACM) [36], [37], 屏幕混合

已经提出了模型(SBM) [38], 闭塞感杂交雨模型(OHRM) [39], 综合降雨模型(CRM) [16]。由于ACM, SBM, OHRM可以看作是CRM的简化案例, 因此我们使用CRM作为数学模型来描述多雨图像的物理过程:

$$R(x) = (1 - \alpha(x))[\beta I(x) + (1 - \beta)A + \sum_{l=1}^L S_l(x)] + \alpha(x)M(x), \quad (3)$$

其中 $r(x)$ 和 $i(x)$ 分别表示多雨的图像及其共同的清洁图像。 $S_l(X)$ 是第 l -th Rain Streak层。歧程 m 分别表示大气传播和全球大气光。 $m(x)$ 是雨依赖图， $\pm(x)$ 是一个alpha matting图，是：

$$\alpha(x) = \begin{cases} 1, & \text{if } x \in \Omega_s, \\ 0, & \text{if } x \notin \Omega_s, \end{cases} . \quad (4)$$

其中定义为雨水区域。

2) 电源线航行数据集: 从等式(3)中, 它指出CRM彻底构成了雨的复杂大气过程的关键因素, 即雨条, 雨滴, 雨滴和类似雾气的现象。因此, 我们合成尖锐的线条和透明圆

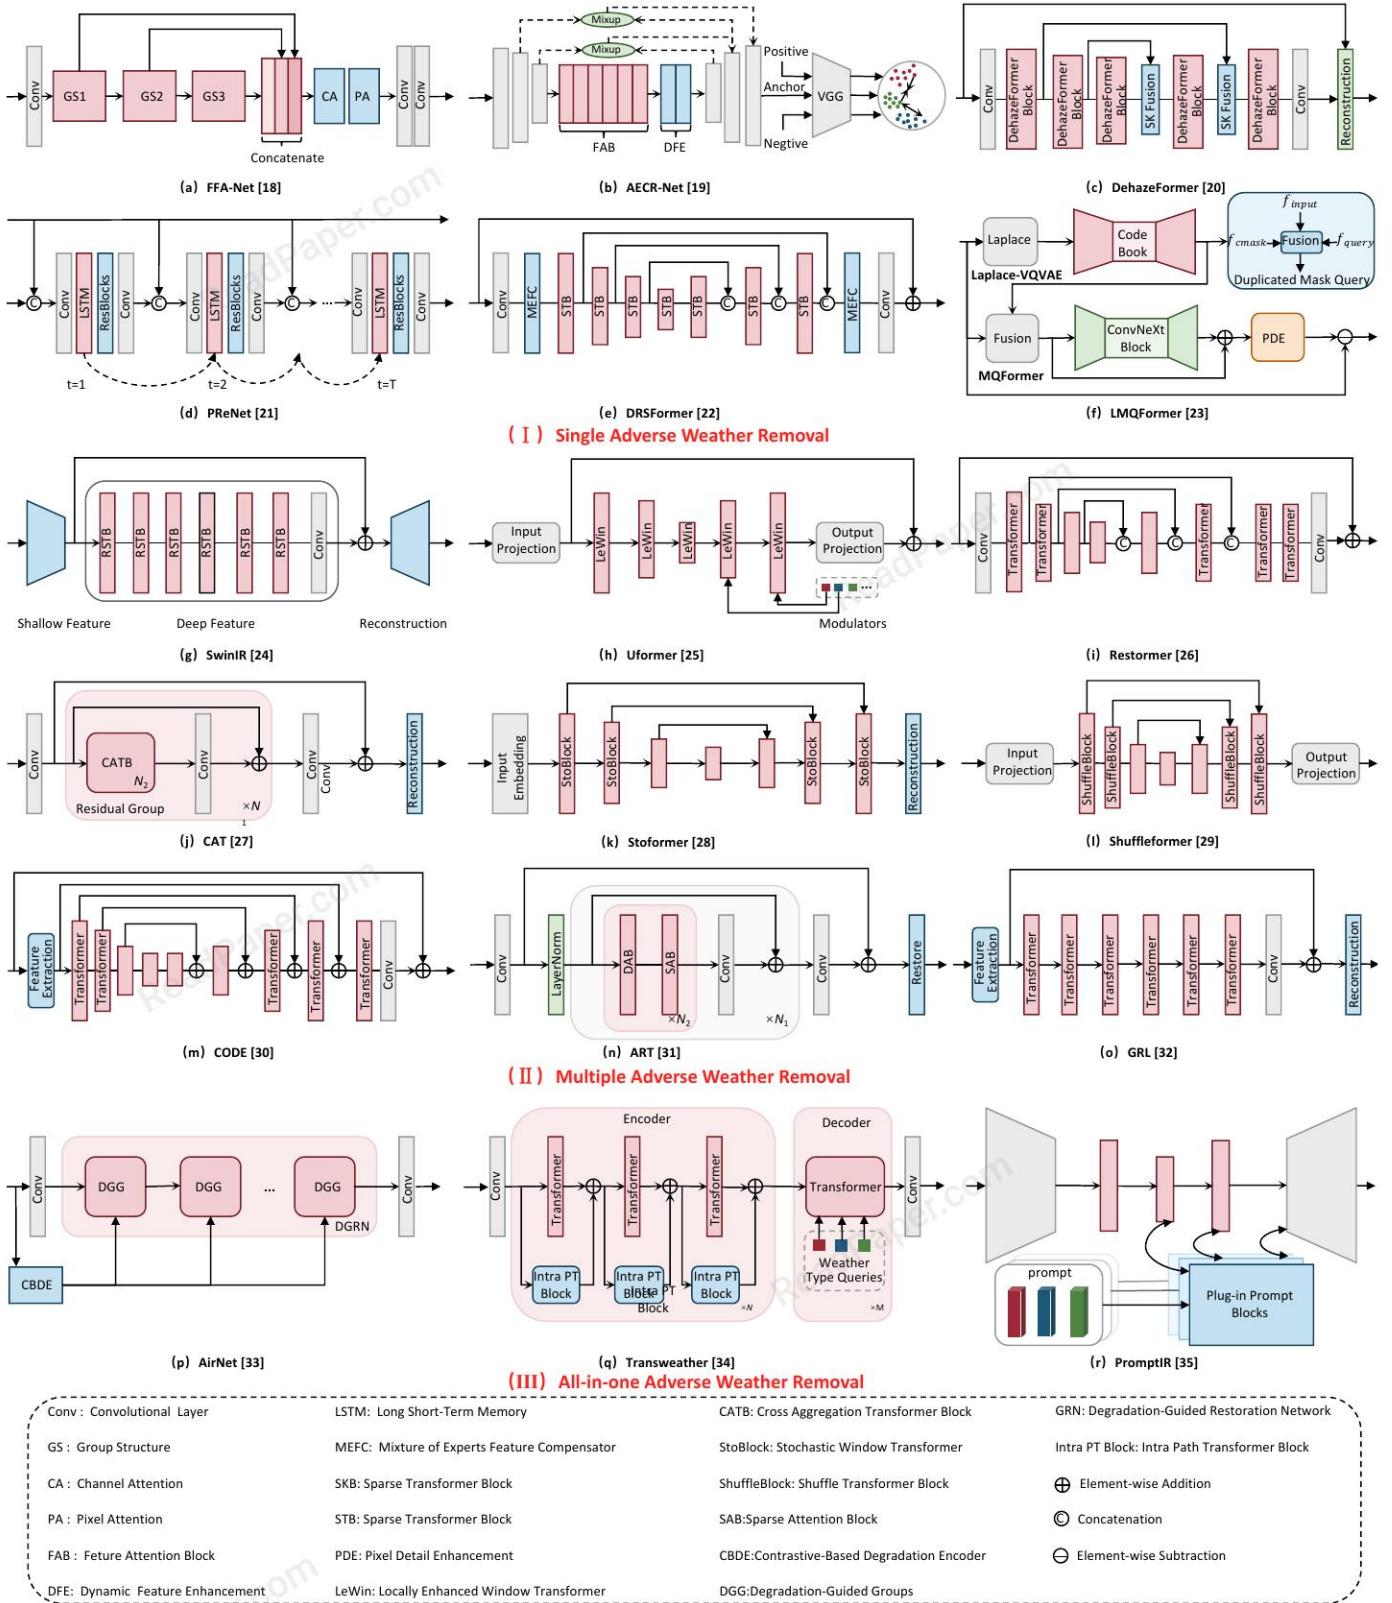


图3。在不利天气 (Plair-aw) 任务下, 新电力线的基线方法的插图。这些基线方法大致分为 (i) 单次不良天气, (ii) 多次不良天气删除和 (iii) 多合一不良天气去除。在第一个家庭中, 我们说明了每种特定不良天气去除的代表性方法, 即 (a) ffanet [18], (b) aeacr-net [19], (c) Dehazeformer [20] 电源线空中图像Dehazing, (d) Prenet [21], (e) Drsformer [22]用于电源线的播出图像, (f) lmqformer [23]用于电源线空中图像。第二个家庭的代表性方法包括 (g) Swinir [24], (h) uformer [25], (i) Restormer [26] (j) CAT [27], (k) Stoformer [28], (l) Shuffleformer [29], (M) 代码[30], (N) ART [31], (O) GRL [32]。第三家族中的代表性方法包括 (p) 气网[33], (q) Transweather [34], (R) 启发人[35]。

表II基线方法的摘要。 con, ssim', “

SIMILARITY LOSS, CHARBONNIER LOSS, PERCEPTUAL LOSS, EDGE LOSS, AND SUPERVISED CONTRASTIVE LOSS, RESPECTIVELY.

Type	Method	Main Blocks	Structure	Loss Function	Download Link	Venu	Year
SAWR	FFANet [18]	Attention	Asymmetric	\mathcal{L}_1	https://github.com/zhilin007/FFA-Net	AAAI	2020
	AECR-Net [19]	Attention	U-Net	$\mathcal{L}_1 + \mathcal{L}_{Con}$	https://github.com/GlassyWu/AECR-Net	CVPR	2021
	DehazeFormer [20]	Transformer	U-Net	$\mathcal{L}_1 + \mathcal{L}_{SSIM} + \mathcal{L}_{Per} + \mathcal{L}_{Adv}$	https://github.com/IDKiro/DehazeFormer	TIP	2023
	PRENet [21]	Convolutional	Multi-stage	$\mathcal{L}_2 + \mathcal{L}_{SSIM}$	https://github.com/csdwren/PReNet	CVPR	2019
	DRSformer [22]	Transformer	U-Net	\mathcal{L}_1	https://github.com/cschenxiang/DRSformer	CVPR	2023
MAWR	LMQFormer [23]	Transformer	Psychic-aware	$\mathcal{L}_{Char} + \mathcal{L}_{Per} + \mathcal{L}_{Edge}$	https://github.com/StephenLinn/LMQFormer	TIP	2023
	SwinIR [24]	Transformer	Asymmetric	\mathcal{L}_{Char}	https://github.com/JingyunLiang/SwinIR	ICCVW	2021
	Uformer [25]	Transformer	U-Net	\mathcal{L}_{Char}	https://github.com/ZhendongWang6/Uformer	CVPR	2022
	Restormer [26]	Transformer	U-Net	\mathcal{L}_1	https://github.com/swz30/Restormer	CVPR	2022
	CAT [27]	Transformer	U-Net	\mathcal{L}_{Char}	https://github.com/zhengchen1999/CAT	NIPS	2022
	Stoformer [28]	Transformer	U-Net	\mathcal{L}_{Char}	https://github.com/jiexiaou/Stoformer	NIPS	2022
	ShuffleFormer [29]	Transformer	U-Net	\mathcal{L}_{Char}	https://github.com/jiexiaou/ShuffleFormer	ICML	2023
	CODE [30]	Transformer	U-Net	\mathcal{L}_2	https://github.com/XLearning-SCU/2023-CVPR-CODE	CVPR	2023
AAWR	ART [31]	Transformer	Asymmetric	$\mathcal{L}_1 + \mathcal{L}_{Char}$	https://github.com/gladzhang/ART	ICLR	2023
	GRL [32]	Transformer	U-Net	\mathcal{L}_1	https://github.com/ofsoundof/GRL-Imag Restoration.git	CVPR	2023
	AirNet [33]	Convolutional	Asymmetric	$\mathcal{L}_1 + \mathcal{L}_{SC}$	https://github.com/XLearning-SCU/2022-CVPR-AirNet	CVPR	2022
TransWeather [34]	TransWeather [34]	Transformer	Asymmetric	$\mathcal{L}_1 + \mathcal{L}_{Per}$	https://github.com/jeya-maria-jose/TransWeather	CVPR	2022
	PromptIR [35]	Transformer	U-Net	\mathcal{L}_1	https://github.com/va1shn9v/PromptIR	NIPS	2023

使用Photoshop模拟雨条和雨滴。雨条和雨滴的结合称为雨面具。此外，我们在Dhazing数据集中采用合成的程序来创建类似雾的现象。合成的雨面膜和雾度在公共CPLID [12], TTPLA [10], In-splad [13]数据集的清洁图像上超级化，我们得到以下数据集： * RainCplid: 此数据集是在CPLID, CPLID, CPLID, CPLID, 其中包含两个雨水和雨水的子集。前者以轻雨的条纹生产，而后者则以大雨条纹产生。这两个子集都包括848对多雨和干净的图像，大小为84 × 84。图像分为700

培训，148用于测试。 * rainntpla: 该数据集是在TTPLA上生成的，其中有两个Rainntpla-L 和Rainntpla-H子集。前者以轻雨的条纹产生，而后者则以大雨条纹产生。这两个子集都包含1242对多雨和干净的图像，分辨率为512×512。总图像分为1000，为242进行训练和测试。 * Raininsplad: 该数据集是在Inplad上生成的，该数据集具有两个子集Raininsplad-L 和Raininsplad-H。前者以轻雨的条纹产生，而后者则以大雨条纹产生。这两个子集都在1920×1080分辨率中包含10,607对多雨和干净的图像。总图像分为7981和2626张图像，用于培训和

分别进行测试。

2) 电源线的航空图像吸引数据集：跟随方程式(5)，我们模拟了雪地面具和像差图以生成雪图像。具体来说，我们使用Photoshop在不同位置生成具有不同透明胶片和大小的雪花和条纹，然后采用高斯在雪颗粒上模糊的高斯来产生像差图。根据雪颗粒的密度，雪面被进一步分为三种小型，中等和大型。使用Snow Mask，在公共CPLID [12]和TTPLA [10]上的书面数据集的产生如下： * SnowCplid: 此数据集是基于CPLID构建的，该数据集基于CPLID，该数据集提供了三种具有不同大小的雪地颗粒的雪图像，也就是说，Snowcplid-S, Snowcplid-M 和Snowcplid-L。每个子集的总数为848对雪和干净的图像，分别为700，分别为148，分别用于训练和测试。训练中图像的大小

测试集为84。 * Snowttpla: 该数据集是基于TTPLA构建的，该数据集提供了三种具有不同尺寸的雪颗粒的雪地，即Snowtpla-s, Snowtpla-S, Snowtpla-M 和Snowtpla-l。每个子集完全由1,242个配对的雪和干净的图像组成，分别分别为1,000和242进行训练和测试。训练和测试集中的图像大小为512×512。摘要和挑战：有关任务类型，子集，图像大小，图像编号，拆分协议以及所有提出数据集的下载链接的详细信息在表I中汇总。
2(a)。此外，我们在以下方面介绍了提议的数据集的特征：(1) 在HazeCplid, RainCplid和Snowcplid数据集中，图像中的主要前景对象是绝缘子，这些物体是绝缘剂，将其进一步分为两种类型的正常和缺失盖帽。过错。图像的背景涵盖了城市，河流，田野和山脉的场景。在Hazetpla, Rainntpla和Snowttpla数据集中，图像的内容主要是关于传输塔和电源线

C. 电源线航行图像

1) 数学模型：在白雪皑皑的条件下，Liu等。 [17]建立了以下数学模型：

$$S(x) = J(x)(1 - Z(x)) + C(x)Z(x), \quad (5)$$

其中，s(x) 和j(x) 表示雪图像及其相应的干净图像。C(x) 代表雪片，Z(x) 是二进制面具，指示雪的位置。

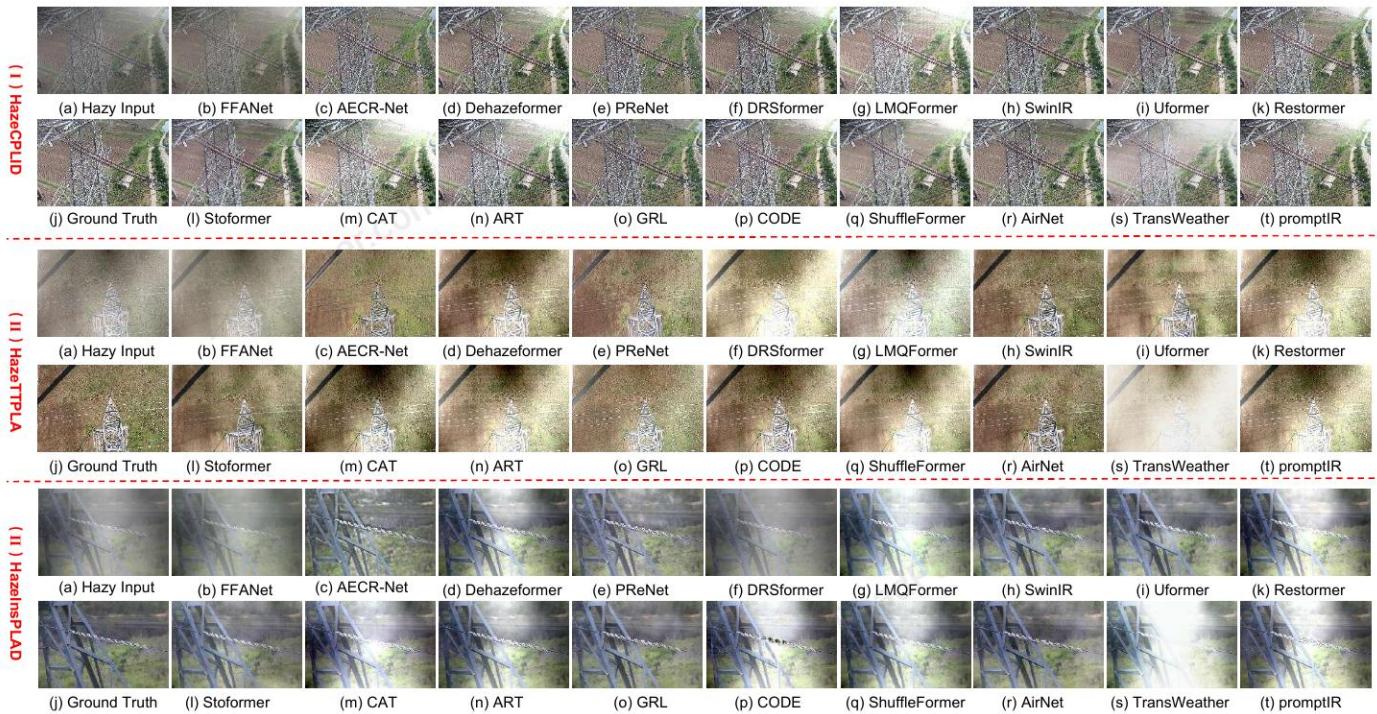


图4。电源线空气图像除雾任务的视觉比较结果。请放大图，以获得更好的视野。

具有嘈杂背景的不同景色，例如建筑物，植物，道路和车道线。在Hazeinsplad和Raininsplad数据集中，这些图像包含了17个独特的电源线组件，这些组件是从多个现实世界环境条件中捕获的。总之，拟议的数据集涵盖了电源线自动检查的主要方案，这可以为未来的有关新成对任务的研究提供强有力的支持。（2）我们使用平均峰值信噪比（PSNR）来测量每个提出的数据集的信息丢失与其干净的数据集相比。如图2（b）所示，某些数据集的PSNR，例如HazeTTPLA，Hazeinsplad，低于20 dB。此外，所有提出的数据集中的图像都是航空图像，具有特殊角度，可变目标方向，小型对象和复杂的背景。以上几点表明，新的配对任务非常具有挑战性，而要恢复的糟糕而复杂的图像。

iii. 基线方法

在不利天气下的图像恢复是一项经典的低级计算机视觉任务，众所周知，它是图像脱掩的任务[40] [44]，图像deraining [36]，[45]和图像否认[17]。已经提出了许多精彩的作品[46] [51]来解决这些任务。根据拆除天气的类型，现有方法可以大致分为三组单一的不利天气，多次不良天气降低以及多合一的不利天气去除。我们选择每个组中的代表性方法作为新任务的基线方法，将描述如下：

A. 一次不良天气去除

单一不利的天气去除被称为设计特定天气清除任务的特定方法。在这种情况下，我们选择FFANET [18]，AECR-NET [19]，DEHAZEFORMER [20]的代表性方法用于De-Hazing，Prenet [21]，Drsformer [22]用于DERANEN，LMQ-前[23]否则，如下：

ffanet [18]: Ffanet的框架如图3（a）所示。朦胧的图像被传递到卷积层以提取浅特征，然后将其馈入N组架构。将输出功能列出，以通过所提出的特征拟合模块融合在一起。之后，通过全局残留学习连接重建功能为清洁输出。

AECR-NET [19]: 如图3（b）所示，它主要拥有类似自动编码器的（AE）体系结构和建设性的学习策略。具体而言，AE由一个下采样模块，六个特征注意块，动态功能增强块，一个UPPEMLING模块和两个自适应混合操作组成。同时，它将干净的图像和朦胧的图像设置为降级输出的正和负样品，从而产生对比度正则化损失。

DeHazeformer [20]: 如图3（c）所示，它被构成带有基本去除侧块的U形结构，这些结构在流行的Swin Transformer [52]上得到了改进。核心改进主要包括SK融合和软重建层，这些层取代了串联融合层和全局残留学习。

表III在单一设置中, 电源线航空图像飞行图像的定量结果。前两个结果以红色和
BLUE, RESPECTIVELY.

Method	HazeCPLID		HazeTTPLA		HazeInsPLAD		Average		#Param	#Flops
	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	(M)↓	(G)↓
FFANet [18]	20.75	0.8112	19.69	0.7994	19.54	0.8729	19.99	0.8278	4.45	72.08
AECR-Net [19]	23.35	0.8655	19.87	0.7555	21.75	0.8227	21.65	0.8145	2.59	8.90
Dehazeformer [20]	28.34	0.9616	26.43	0.9524	28.25	0.9816	27.67	0.9652	25.45	69.24
PRNet [21]	24.01	0.9197	19.71	0.8324	22.56	0.8886	22.09	0.8802	0.17	16.56
DRSformer [22]	27.84	0.9675	25.72	0.9608	19.48	0.8718	24.34	0.9333	33.65	55.43
LMQFormer [23]	27.40	0.9623	26.53	0.9493	26.20	0.9709	26.71	0.9608	2.18	5.61
SwinIR [24]	26.24	0.9592	24.54	0.9305	26.57	0.9711	25.78	0.9536	7.78	126.51
Uformer [25]	27.38	0.9621	25.33	0.9433	26.84	0.9740	26.51	0.9598	50.88	89.46
Restormer [26]	27.85	0.9657	28.06	0.9653	28.03	0.9763	27.98	0.9691	28.63	39.71
CAT [27]	26.85	0.9547	26.93	0.9463	27.90	0.9705	27.22	0.9571	25.77	33.95
Stoformer [28]	27.44	0.9653	25.05	0.9499	22.55	0.9308	25.01	0.9486	50.47	123.97
ShuffleFormer [29]	26.69	0.9613	26.85	0.9576	27.81	0.9758	27.11	0.9649	30.75	13.28
CODE [30]	27.18	0.9606	26.59	0.9594	25.47	0.9496	26.41	0.9565	12.23	11.3
ART [31]	27.62	0.9442	25.59	0.8987	27.88	0.9532	27.03	0.9320	25.7	33.71
GRL [32]	24.68	0.9406	21.54	0.9089	25.59	0.9632	23.93	0.9375	3.29	51.86
AirNet [33]	26.40	0.9570	25.43	0.9390	27.28	0.9290	26.37	0.9416	7.6	302.3
TransWeather [34]	25.57	0.8934	22.94	0.8284	24.76	0.9436	24.42	0.8884	38.05	1.56
promptIR [35]	28.06	0.9668	27.47	0.9698	27.60	0.9800	27.71	0.9722	34.12	35.25



图5。电源线的视觉比较结果在单一设置中的空中图像驱动任务上。请放大图中的更好的视图。

PRENET [21]: 如图3 (d) 所示, 它始于一个基本的浅剩余网络, 该网络具有五个残差块, 然后将其发展为多个阶段, 并进行了反复展开的操作。此外, 引入了复发层, 以利用递归阶段的深度特征的依赖性。

drsformer [22]: 如图3 (e) 所示, 它具有基本稀疏变压器块 (STB) 的U形结构。STB的核心元素是TOP-K稀疏注意 (TKSA) 和混合尺度的进发纸网络 (MSFN)。前者探索可学习的TOP-K选择

运算符为了保持最有用的自我发项值以进行更好的特征聚合, 而后者则利用多尺度的深度卷积路径来获得丰富的多尺度表示。

LMQFormer [23]: 如图3 (f) 所示, 它具有Laplace-VQVAE和MQFormer的两个路径。第一个路径使用拉普拉斯操作员过滤输入图像, 然后使用多尺度编码器与代码簿以两个低尺度的形式获得粗蒙版。在第二个路径中, 首先将粗掩模和输入图像融合, 然后由两个并行编码器编码

电源线空中图像降低任务的表IV定量结果。前两个结果以红色和
BLUE, RESPECTIVELY.

Method	RainCPLID-L				RainCPLID-H				RainTTPLA-L				RainTTPLA-H				RainInsPLAD-L				RainInsPLAD-H				Average	#Param	#Flops
	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	(M)↓	(G)↓																			
FFANet [18]	29.55	0.9281	26.80	0.8779	30.87	0.9604	28.80	0.9318	29.05	0.9314	27.48	0.9075	28.75	0.9228	4.45	72.08											
AECR-Net [19]	29.22	0.8850	26.92	0.8442	27.42	0.8338	26.32	0.8020	31.87	0.9467	30.39	0.9295	28.69	0.8735	2.59	8.90											
Dehazeforner [20]	32.61	0.9456	30.73	0.9357	33.70	0.9675	31.24	0.9571	38.01	0.9820	36.07	0.9789	33.72	0.9611	25.45	69.24											
PReNet [21]	30.97	0.9263	27.95	0.8892	31.10	0.9515	28.99	0.9300	33.77	0.9538	31.84	0.9380	30.77	0.9314	0.17	16.56											
DRSformer [22]	34.75	0.9619	33.03	0.9594	34.57	0.9728	32.61	0.9698	26.69	0.9227	25.89	0.8985	31.25	0.9475	33.65	55.43											
LMQFormer [23]	32.31	0.9337	29.84	0.9199	32.26	0.9545	29.55	0.9323	35.95	0.9672	33.64	0.9549	32.25	0.9437	2.18	5.61											
SwinIR [24]	30.74	0.9362	28.64	0.9107	31.55	0.9607	28.93	0.9321	35.86	0.9738	33.41	0.9621	31.52	0.9459	7.78	126.51											
Uformer [25]	33.45	0.9532	31.93	0.9497	33.13	0.9654	30.91	0.9568	37.57	0.9793	35.24	0.9746	33.70	0.9630	50.88	89.46											
Restormer [26]	34.80	0.9616	32.34	0.9574	34.94	0.9755	32.83	0.9721	38.38	0.9825	36.44	0.9800	34.95	0.9715	26.13	35.25											
CAT [27]	32.91	0.9428	31.83	0.9433	31.86	0.9584	29.64	0.9440	38.05	0.9802	35.51	0.9728	33.30	0.9569	15.01	22.03											
Stoformer [28]	33.39	0.9486	31.00	0.9477	34.42	0.9718	31.74	0.9638	37.77	0.9805	35.38	0.9756	33.28	0.9646	50.47	123.97											
ShuffleFormer [29]	34.15	0.9516	32.33	0.9539	33.03	0.9648	30.24	0.9517	38.03	0.9817	36.23	0.9783	34.00	0.9636	30.75	13.28											
CODE [30]	32.30	0.9365	31.30	0.9421	31.05	0.9503	29.02	0.9340	37.99	0.9809	36.22	0.9781	32.98	0.9536	12.23	11.3											
ART [31]	32.54	0.9450	31.43	0.9446	32.46	0.9608	30.84	0.9466	37.60	0.9796	35.86	0.9755	33.45	0.9586	25.7	33.71											
GRL [32]	30.84	0.9219	27.85	0.8858	31.21	0.9556	28.94	0.9300	35.80	0.9761	33.82	0.9676	31.41	0.9395	3.29	51.86											
AirNet [33]	31.02	0.9343	28.24	0.8962	31.61	0.9628	28.99	0.9434	37.46	0.9787	35.50	0.9739	32.13	0.9482	7.6	302.3											
TransWeather [34]	32.58	0.9298	30.11	0.9205	26.17	0.7621	25.07	0.7243	32.86	0.9357	31.18	0.9242	29.66	0.8661	38.05	1.56											
promptIR [35]	34.89	0.9605	33.19	0.9638	35.24	0.9781	33.18	0.9705	37.45	0.9793	35.06	0.9733	34.83	0.9709	34.12	35.25											

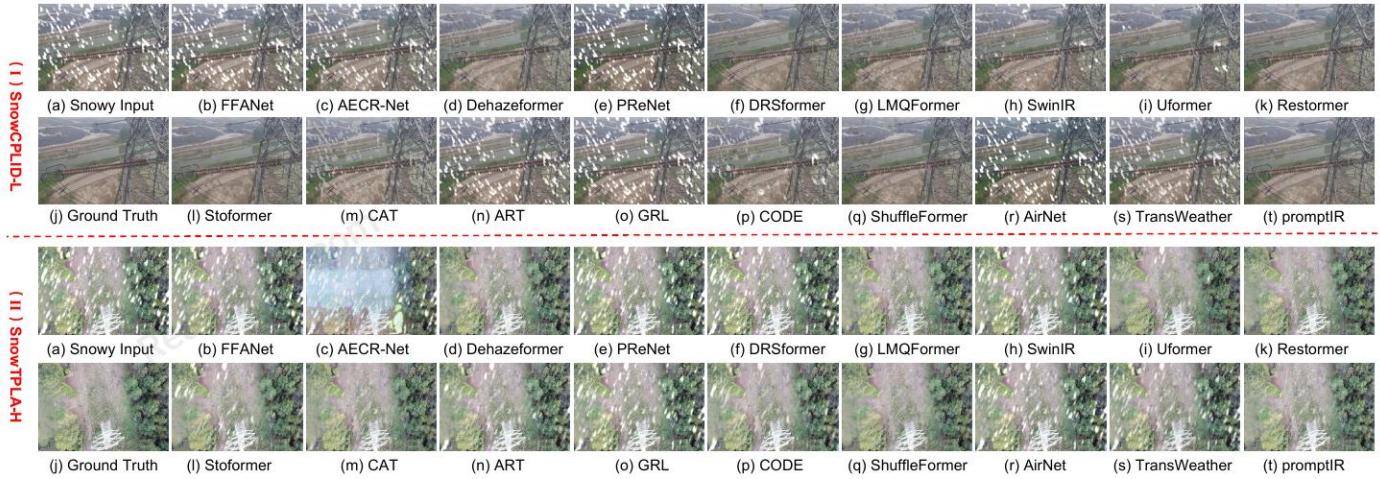


图6。电源线空气图像中的视觉比较结果在单一设置中否定任务。请放大图中的更好的视图。

解码器和修改后的ConvnextBlock。最后, Pixel细节增强 (PDE) 了解原始量表的更多详细信息。

B. 多次不利天气去除

多次不良天气拆除被称为开发一般模型, 定制了用于多种天气去除任务的定制[53], [54], 它已成为图像恢复社区中的热点, 有以下代表: Swinir [24]]: 如图3 (g) 所示, 它由 (1) 浅特征提取, (2) 深度特征提取和 (3) 高质量图像重建的三个模块组成。

具体而言, 第一个模块是3 3卷积层。第二个模块由残留的SWIN变压器块组成, 其中Swin Transformer层与残差连接组合在一起。第三个模块汇总了浅和深特征 -

Gether, 可以帮助第二个模块专注于高频信息。

UFormer [25]: 如图3 (h) 所示, 它主要是在U形结构中以局部增强的窗口 (Lewin) 跨块。 Lewin执行非重叠的基于窗口的自我注意力, 而不是全局自我注意力。 同时, 添加了可学习的多尺度恢复调制器, 以恢复更多详细信息。 Restormer [26]: 如图3 (i) 所示, 它是在多尺度层次结构中进行的。 基本块的核心组件是多DConv头transphated注意 (MDTA) 和GAID-DConv进料向前网络 (GDFN) 。 MDTA通过执行通道明智的注意而不是基于空间的注意力来对全局上下文进行建模, GDFN引入了门控机制, 即仅允许有用的信息进一步通过网络层次结构。 CAT [27]: 如图3 (j) 所示, 它由三个组成

电源线航空图像在单一设置中遇到的任务的表V定量结果。前两个结果以红色标记

AND BLUE, RESPECTIVELY.

Method	SnowCPLID-S SnowCPLID-M SnowCPLID-L SnowTTPLA-S SnowTTPLA-M SnowTTPLA-L												Average		#Param (M)↓	#Flops (G)↓
	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑		
FFANet [18]	41.30	0.9695	35.98	0.9235	29.86	0.9187	41.12	0.9754	37.86	0.9687	27.48	0.9114	35.6	0.9412	4.45	72.08
AECR-Net [19]	36.07	0.9558	33.19	0.9230	28.96	0.9033	25.72	0.7046	25.23	0.6860	22.63	0.6439	28.63	0.8027	2.59	8.90
Dehazeformer [20]	41.55	0.9753	36.92	0.9442	33.26	0.9450	39.64	0.9800	37.62	0.9778	31.63	0.9527	36.77	0.9625	25.45	69.24
PRNet [21]	38.49	0.9604	34.17	0.9153	31.66	0.9315	39.86	0.9762	37.02	0.9698	27.40	0.9168	34.76	0.9450	0.17	16.56
DRSformer [22]	42.70	0.9816	38.68	0.9558	36.67	0.9675	41.05	0.9771	37.99	0.9696	27.67	0.9184	37.46	0.9616	33.65	55.43
LMQFormer [23]	42.04	0.9749	36.25	0.9286	31.52	0.9294	39.90	0.9773	37.64	0.9736	30.43	0.9412	36.29	0.9541	2.18	5.61
SwinIR [24]	40.94	0.9722	35.40	0.9279	32.53	0.9383	39.66	0.9791	37.54	0.9738	29.53	0.9335	35.93	0.9541	7.78	126.51
Uformer [25]	41.84	0.9765	36.86	0.9405	33.21	0.9484	39.79	0.9805	38.37	0.9785	32.35	0.9549	37.07	0.9632	13.02	21.89
Restormer [26]	42.99	0.9834	38.68	0.9641	36.85	0.9703	41.26	0.9831	39.38	0.9826	33.82	0.9681	38.82	0.9752	28.63	39.71
CAT [27]	41.28	0.9725	35.98	0.9326	30.09	0.9140	39.49	0.9798	37.45	0.9776	30.82	0.9468	35.85	0.9538	25.77	33.95
Stoformer [28]	42.56	0.9816	37.93	0.9584	36.08	0.9644	41.12	0.9768	37.93	0.9698	27.38	0.9087	37.16	0.9599	50.47	123.97
ShuffleFormer [29]	41.67	0.9764	37.08	0.9490	35.09	0.9582	40.60	0.9828	38.78	0.9813	33.14	0.9643	37.72	0.9686	30.75	13.28
CODE [30]	40.30	0.9702	35.06	0.9234	30.45	0.9163	38.68	0.9766	36.69	0.9685	29.63	0.9329	35.13	0.9479	12.23	11.3
ART [31]	40.33	0.9705	35.12	0.9205	29.65	0.9180	40.21	0.9786	37.18	0.9732	30.58	0.9392	35.51	0.9500	25.7	33.71
GRL [32]	40.48	0.9696	35.24	0.9237	29.07	0.9080	39.90	0.9797	37.58	0.9747	28.84	0.9299	35.18	0.9476	3.29	51.86
AirNet [33]	40.20	0.9732	35.25	0.9326	30.42	0.9229	37.55	0.9738	36.35	0.9716	29.28	0.9362	34.50	0.9517	7.6	302.3
TransWeather [34]	33.52	0.9145	31.37	0.8736	27.80	0.8546	25.95	0.7213	25.80	0.7094	23.25	0.6741	27.94	0.7912	38.05	1.56
promptIR [35]	43.39	0.9830	39.48	0.9691	37.50	0.9724	41.59	0.9838	39.32	0.9828	33.29	0.9673	39.09	0.9764	34.12	35.25

电源线航空图像脱掩的任务, 驱逐任务以及在多合一设置中取消任务的表VI定量结果。这

前两个结果分别标记为红色和蓝色。

Method	Dehazing				Deraining				Desnowing				Average			
	HazeCPLID	HazeTTPLA	RainCPLID-L	RainCPLID-H	SnowTTPLA-S	SnowTTPLA-M	SnowTTPLA-L									
FFANet [18]	20.49	0.8274	18.83	0.7941	25.39	0.9276	25.46	0.9007	37.61	0.9706	36.33	0.9670	27.43	0.9160	27.36	0.9004
AECR-Net [19]	21.69	0.8179	19.68	0.7837	26.28	0.8553	25.92	0.8367	24.62	0.7479	24.36	0.7384	22.30	0.6989	23.55	0.7971
Dehazeformer [20]	26.00	0.9611	23.35	0.9133	31.61	0.9541	30.23	0.9393	34.67	0.9632	33.99	0.9648	28.75	0.9248	29.8	0.9458
PRNet [21]	20.86	0.8567	19.05	0.8122	26.05	0.9018	26.10	0.8770	34.83	0.9576	34.47	0.9636	26.99	0.9181	26.90	0.8981
DRSformer [22]	20.89	0.8218	19.01	0.7919	23.74	0.9231	23.60	0.8965	35.36	0.9607	34.87	0.9518	27.86	0.9221	26.47	0.8954
LMQFormer [23]	25.67	0.9519	21.74	0.8813	29.81	0.9316	28.01	0.9178	34.52	0.9487	33.84	0.9550	27.78	0.9265	28.76	0.9304
SwinIR [24]	26.11	0.9527	20.21	0.8520	28.38	0.9307	27.19	0.9031	29.59	0.9275	29.42	0.9308	24.36	0.8895	26.45	0.8649
Uformer [25]	26.04	0.9514	20.23	0.8575	27.64	0.9295	26.46	0.9088	35.26	0.9637	34.91	0.9653	27.21	0.9214	28.25	0.9282
Restormer [26]	27.25	0.9641	21.64	0.8460	31.36	0.9584	30.41	0.9499	33.55	0.9648	34.86	0.9720	29.90	0.9433	29.85	0.9426
CAT [27]	26.33	0.9537	22.19	0.8807	31.30	0.9418	29.45	0.9312	33.23	0.9659	33.21	0.9628	27.97	0.9236	29.09	0.9371
Stoformer [28]	25.44	0.9555	20.92	0.9010	29.67	0.9268	26.99	0.8844	31.33	0.9538	31.34	0.9546	25.39	0.8996	27.29	0.9251
ShuffleFormer [29]	26.11	0.9633	21.92	0.9032	30.25	0.9391	29.38	0.9180	33.49	0.9434	33.41	0.9498	26.86	0.9101	28.77	0.9324
CODE [30]	25.27	0.9529	19.84	0.8012	29.38	0.9356	28.90	0.9323	32.34	0.9557	32.03	0.9540	27.81	0.9272	27.93	0.9227
ART [31]	26.32	0.9302	22.33	0.8557	31.22	0.9360	29.61	0.9222	33.63	0.9625	33.33	0.9591	27.95	0.9249	29.19	0.9272
GRL [32]	24.15	0.9252	19.24	0.8024	27.69	0.9137	27.39	0.8990	31.43	0.9493	31.02	0.9463	25.48	0.9009	26.62	0.9052
AirNet [33]	26.09	0.9510	20.20	0.8830	30.26	0.9445	28.90	0.9270	33.98	0.9647	33.42	0.9624	28.30	0.9300	28.73	0.9375
TransWeather [34]	23.13	0.8755	20.93	0.8334	27.56	0.8700	26.53	0.8572	24.00	0.7524	23.80	0.7503	22.15	0.7050	24.01	0.8062
promptIR [35]	26.56	0.9637	21.71	0.8681	33.44	0.9709	31.97	0.9654	33.92	0.9686	33.40	0.9704	29.91	0.9428	30.13	0.9499

(1) 浅的模块提取, (2) 深度提取和 (3) 重建。核心组件是第二个模块, 它与几个残差组和一个卷积层的元素应用残差连接。每个残差组都由几个交叉聚集变压器块和一个卷积层组成。

Stoporner [28]: 如图3 (k) 所示, 它利用了一个UNET式的网络体系结构, 在编码器和解码器阶段中带有Stoblock。Stoblock中的基本变压器层是具有随机窗口策略的基于窗口的自我注意的变体。

``Shuffformer [29]: 如图3 (l) 所示, 它使用基本块进行了U形架构来揭示

Shuffleblock。Shuffleblock中的基本变压器层通过随机调整输入, 从而增强了本地窗口变压器的非本地相互作用。代码[30]: 如图3 (m) 所示, 它在U形结构中排列基本变压器块, 每个基本块由凝聚的注意(CA) 块和双自适应组成(DA)) 堵塞。CA依次执行特征聚合, 注意力计算和功能恢复以有效捕获超像素的全局特征, 而DA以动态加权方式采用双向结构, 以将超像素的全球性分配到每个像素中。

ART [31]: 如图3 (n) 所示, 它采用了不对称的自动编码器体系结构, 该体系结构首先提取浅

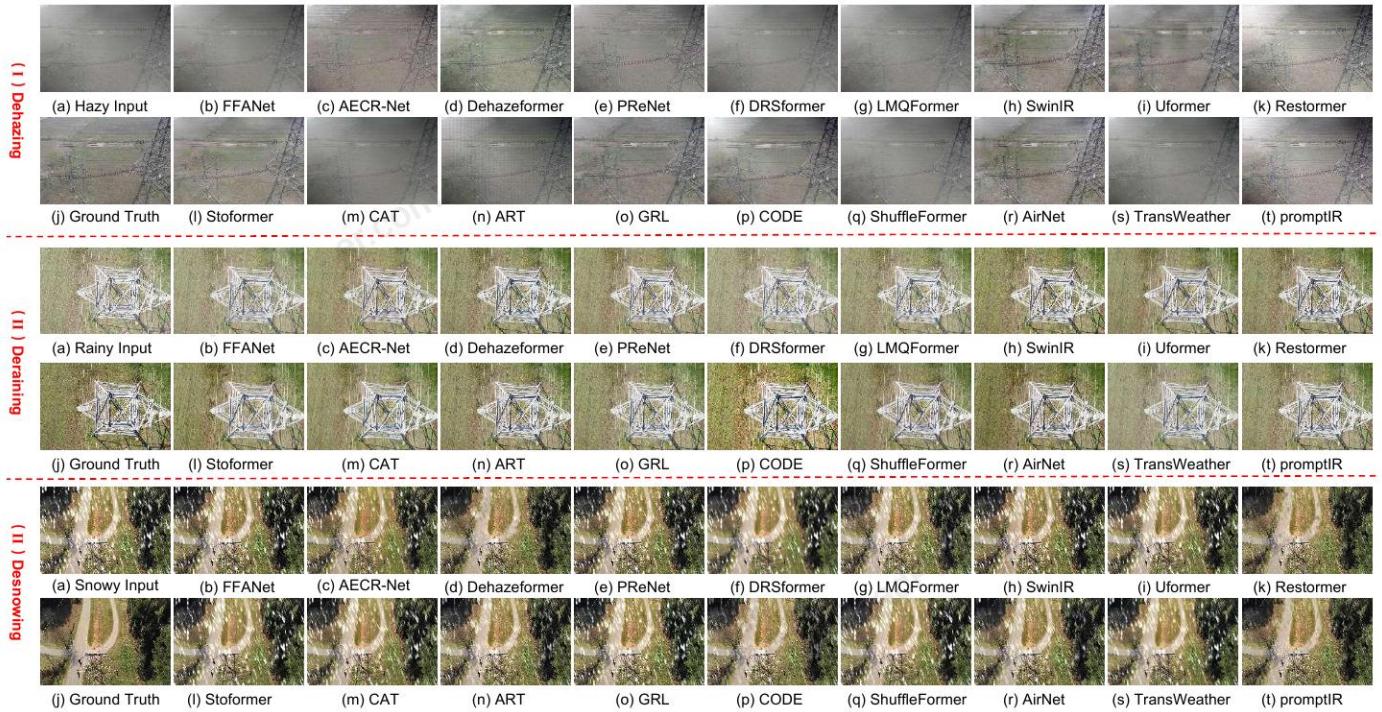


图7。电源线的视觉比较结果在多合一设置中除去，排水和否定任务。请放大图中的更好的视图。

具有3卷积层的特征，然后用几个残差组提取深度特征，最后以3 3卷积层完善恢复结果。每个残差组的核心元素是两个连续的注意力块（DAB）和稀疏注意块（SAB）。

GRL [32]：如图3 (0) 所示，它主要包含 (1) 特征提取，(2) 表示学习和 (3) 图像重建。第二部分是骨干网络，该网络与六个跨前期和一个卷积层进行残留连接。变压器层实现了锚固条纹自我注意，窗户自我注意和引起注意增强卷积的平行计算。

C. 多合一的不利天气去除

多合一的不利天气去除被称为开发统一的架构，能够同时处理模拟的不利天气去除任务[55], [56]，这已经发展为一种新的研究趋势图像恢复社区与以下代表。 Airnet [33]：如图3 (p) 所示，它主要包含基于对比的降级编码器（CBDE）和降解引导的恢复网络（DGRN）。 CBDE中的核心成分是受监督的对比学习以区分降解类型，可以有效地指导DGRN中的图像恢复。

Transweather [34]：如图3 (Q) 所示，Transweather的框架通常遵循自动编码器架构。编码器具有斑点内变压器块，可从创建的较小子点中提取功能

主补丁。变压器解码器具有可学习的天气型查询以获取任务功能。然后，将层次功能和任务功能转发到卷积投影块以获得干净的图像。 $\hat{A}xpectir$ [35]：如图3 (r) 所示，它是在Restormer [26]上设计的，具有新的插件提示模块。新模块使用一组可调参数编码特定于降解的信息，该信息可以动态地指导解码器使用各种降解类型恢复图像。

备注和电势：表II中总结了基线方法。在我们的工作中，所有基线方法都在单一和多合一的设置中广泛组合。我们计算所有数据集，任务以及PSNR中设置的平均结果。从图2 (c) 中所示的结果，我们可以看到Restormer [26] 和Proccctir [35]全面地排名第一和第二名。这两种方法的胜利主要归因于变压器的强大远程依赖性建模能力。然而，由于多头的自我关注，变形金刚由于其多头的自我关注而遭受了沉重的计算和参数容量负担，这无法满足电源线自主检查的资源有限应用。未来的工作需要专注于开发针对电力线自主检查任务的新的特定恢复模型。

iv. 实验A. 恢复评估

1) 实现详细信息：所有基线方法在单一和多合一的设置中均进行了广泛的比较。单一设置与

表七

基线方法之间的分割性能比较, 正常条件以及没有配对的方法 (w/o配对)。基线方法获得的前两个结果分别用红色和蓝色标记。结果正常情况以粗体标记。带有下划线标记的带有配对的结果。

Method	HazeTTPLA					RainTTPLA-H					SnowTTPLA-L				
	AP_b^{50}	AP_m^{50}	AP_b^{75}	AP_m^{75}	AP_b^{avg}	AP_b^{50}	AP_m^{50}	AP_b^{75}	AP_m^{75}	AP^{avg}	AP_b^{50}	AP_m^{50}	AP_b^{75}	AP_m^{75}	AP^{avg}
Normal	57.63	42.26	33.78	21.74	38.85	57.63	42.26	33.78	21.74	38.85	57.63	42.26	33.78	21.74	38.85
w/o PAIR-AW	53.98	33.56	30.47	18.14	34.03	53.72	37.42	30.35	19.60	35.27	53.95	37.07	28.95	19.62	34.89
FFANet [18]	52.50	35.04	29.47	18.27	33.82	55.10	41.45	30.90	21.11	37.14	54.47	36.89	28.47	19.18	34.75
AECR-Net [19]	42.53	29.77	19.40	13.62	26.33	45.23	31.37	20.74	13.69	27.75	44.57	28.04	23.73	11.48	26.95
Dehazeformer [20]	56.14	42.73	31.34	20.31	37.63	55.91	41.75	32.31	21.26	37.80	56.41	41.45	29.23	20.06	36.78
PReNet [21]	52.76	41.60	25.65	17.83	34.46	55.35	41.49	30.90	20.66	37.10	54.12	37.26	28.04	18.58	34.50
DRSformer [22]	50.25	35.50	25.35	14.70	31.45	55.29	41.09	31.27	20.52	37.04	54.03	37.40	28.54	18.99	34.74
LMQFormer [23]	50.71	35.53	26.78	17.53	32.63	54.16	41.09	31.34	20.72	36.82	54.72	39.13	28.90	19.72	35.61
SwinIR [24]	57.25	40.87	33.33	20.79	38.06	54.98	41.39	31.44	20.36	37.04	55.68	37.54	29.54	19.05	35.45
Uformer [25]	56.24	42.05	34.09	20.56	38.23	54.44	41.36	31.02	20.64	36.86	55.65	40.66	31.50	19.84	36.91
Restormer [26]	55.90	40.55	30.85	18.75	36.51	55.27	41.65	31.44	20.78	37.28	55.70	40.93	30.99	18.88	36.62
CAT [27]	55.69	40.20	32.96	20.41	37.31	54.52	41.73	31.98	20.92	37.28	55.30	35.47	28.10	19.30	34.54
Stoformer [28]	56.49	42.00	32.55	20.73	37.94	55.78	42.27	31.43	20.88	37.59	56.08	40.24	29.07	20.81	36.55
ShuffleFormer [29]	53.25	39.05	28.97	18.04	34.82	55.09	41.46	31.35	21.23	37.25	55.92	41.26	30.28	19.50	36.74
CODE [30]	57.03	41.09	31.10	21.91	37.78	55.04	41.53	31.83	20.84	37.31	55.54	38.11	29.55	19.87	35.76
ART [31]	53.86	40.10	32.96	20.41	36.83	55.01	41.44	31.97	21.14	37.39	55.11	39.42	29.66	19.91	36.02
GRL [32]	55.96	37.48	30.69	20.96	36.27	54.39	41.03	31.24	20.35	36.87	55.60	37.12	30.64	19.35	35.67
AirNet [33]	54.70	36.03	29.08	19.71	34.88	54.29	41.36	30.87	20.62	36.78	54.57	38.27	28.16	19.47	35.09
TransWeather [34]	29.28	20.13	11.76	7.79	17.24	31.38	21.92	13.53	9.11	18.98	44.71	30.53	20.74	14.37	27.58
promptIR [35]	54.80	38.64	30.40	19.53	35.84	55.51	41.51	30.95	20.46	37.10	56.94	41.85	30.93	19.75	37.36

在电力线航空图像中提出的培训数据集除狂物的任务, 排水和丧失的任务。多合一设置通过在每个恢复任务中结合部分培训数据集(即电力线空中图像除狂物任务, RainCplid-L, RainCplid-H, Power Linial Timail demial图像驱逐任务, 和Snowtpla-s, Snowtpla-M和Snowtpla-L在电源线上图像中涉及的任务。对于所有数据集, 势头为 $\alpha = 0.9$, 时期 $T = 0.999$ 和 $5E-4$ 的重量衰减的Adam用作优化器。最大时期数设置为200个, 批处理大小为8。[57] [62], 我们选择了峰信号比率(PSNR)的流行指标(PSNR)和结构相似性(SSIM)作为定量措施。这些指标的较高值表明方法的性能更好。部分训练的模型已上传到云驱动器。1

2) 结果: 在单一设置中, 分别在表III, 表IV和表V中报告了电源线空中图像, 驱逐和终止任务的定量比较结果。从结果来看, 我们可以看到: (1) 总体上, 基于变压器的方法[26], CAT [27], ART [31], Prockingir [35]的表现优于基于CNNS的方法, 例如Ffanet [18], 电源线空中图像上的AECR-NET [19], 在单一设置中进行除去和否定任务。(2) 从表III, 表IV和表V中的平均结果中, 我们可以看到Restormer [26]和Proctctir [35]在PSNR和SSIM中全面实现了前两名。我们进一步显示了电源线空气图像除ZE的可视化比较结果, 分别在图4中, 图5, 图6中分别进行了任务。可视化结果似乎与上述定量结果一致, 其中

RESTORMER [26]和PRESTIR [35]可以通过更好的结构和细节产生令人愉悦的结果。相比之下, 一些基于CNN的方法(例如FFANET [18], AECR-NET [19]在恢复的图像中仍然有微弱的雾, 如图4所示。如图5所示。FFANET [18], AECR-NET [19]的恢复图像。如图6所示, FFANET [18], AECR-NET [19]无法使用一些雪花残留物恢复良好。

在多合一环境中, 表VI报告了定量比较结果。从结果可以观察到: (1) 与表III, 表IV和表V所示的单一设置的结果相比, 所有方法的性能都大大降低, 说明了全面的一个实验环境比单歌设置更具挑战性。(2) 全面地说, Restormer [26]和Procectir [35]在PSNR和SSIM中排名最好和第二名。它们的成功主要归因于高级变压器块, 这些块实施了空间的自我发项操作。我们进一步显示了电源线空气图像除闪, 下雨和在图7中多合一设置中的任务的可视化比较结果。可视化结果似乎与上述定量结果一致, 其中还原[其中的Restormer [26]和Pictextir [35]可以通过更好的结构和细节产生令人愉悦的结果。相比之下, 某些方法(例如FFANET [18], AECR-NET [19]无法通过扭曲的结果恢复。

B. 基于自主检查的评估

要调查在不利天气(plair-aw)下的电力线航行图像恢复是否有益于电力线自主检查, 我们应用了yolact的最新实例实例分段模型[11]来评估图像之后的图像配对任务。这种经验是在Hazettpla, Rainttpla-H和

¹<https://pan.ntu.edu.cn/l/s1RL7R>

Snowtpla-1。在[63]之后, 我们在不同的阈值下计算标准盒平均精度 (AP) 作为评估度量。对于两个边界框和实例掩码计算的平均精度分别为 AP_B 和 AP_M。用两种情况评估精度分数, 即重叠值为 50% 和 75% 的 AP, 导致 AP_50%

, AP_50% m, AP_75% m。我们还计算了 AP_50% 的平均结果

全面比较该方法, 该方法表示为 AP_AVG。每个基线方法的分割结果如表VII所示。

从结果来看, 我们有以下观察结果: (1) 与 W/O Pair-Aw, FFANet [18], AECR-NET [19], DRSFORMER [22] 相比, 对电源线空中图像飞行任务进行了飞行模拟任务。, LMQFormer [23], Transweather [34] 没有获得改进。与 w/o 配对的方法相比, 在电源线空中图像驱动任务上, aecr-net [19], transweather [34] 没有得到改进。与 W/O PAIR-AW, FFANET [18], AECR-NET [19], PRENET [21], DRSFORMER [22], CAT

[27], Transweather, Transweather [34] 请勿获得改进。上述分析表明, 这些方法在基于自主检查的评估中失败。

(2) uformer [25], De-Hazeformer [20], Procctir [35] 分别在 DEHAZING 任务, Deraning Task 和 Dessworging 任务上实现了最佳性能。这些方法明显胜过, 凭借大幅增长, 这表明拟议的新任务可以使电源线自主检查在不利天气下受益。(3) 最佳性能的基线方法仍然不如正常情况下的结果, 表明在未来的工作中需要设计更高级的图像恢复模型。

五、结论和未来工作

在不利的天气条件下, 高架电源线更容易受到故障的影响, 从而加强检查对于确保电力系统的稳定运行至关重要。在这种情况下, 在安全性和效率方面, 自主检查非常优于手动检查。但是, 我们在本文中进行的调查验证了在不利天气中捕获的空中图像对基于深度学习的现代自主检查方法有害。为了解决这个问题, 我们在不利天气 (PLAIR-AW) 下提出了一项新的电源线航空图像修复任务, 以提高航空图像的可见质量。同时, 我们根据这项新任务的深度学习制定了一般解决方案管道。此外, 为了实现解决方案, 我们按照合理的数学模型构建了许多合成数据集。这些数据集包括 Hazecplid, Hazettpla, 用于电源线的 Hazeinsplad, 用于航空图像飞行任务, RainCplid, Rainttpla, Rainttpla, 用于电源线空中图像驱逐任务的 Raininsplad 和 SnowCplid, Snowcplid, Snowtpla, Snowtpla, 用于电力线空中图像的否定任务。此外, 我们还为新任务提供了许多出色的基线方法。这些基线方法已在单一和多合一设置中的所提出的数据集上进行了广泛的评估。

由于 Plair-Aw 是一项新任务, 因此将来需要进行很多工作。例如, (1) 所提出的数据集是人为合成的, 在不利天气下具有现实世界中降级的空中图像的偏见, 从而在现实评估中产生了域移位问题。因此, 未来的工作将收集足够的现实世界中的空中图像, 这可以帮助现有的拟议合成数据集制定半监督的学习策略。(2) 尽管 Baselines 在 Plair-Aw 任务中表现出色, 但它们仍然存在以下两个问题。一方面, 它们不是为具有特殊角度, 可变目标方向, 小型对象和复杂背景的特征的航空图像定制的。未来的工作将集中于增强基线方法的表示, 以处理硬天线恢复。另一方面, 它们不够轻巧, 无法满足无人机的资源有限要求。因此, 未来的工作将集中在模型压缩技术上, 以降低恢复模型的参数能力。

REFERENCES

- [1] J. Zhu, W. Meng, M. Sun, J. Yang, and Z. Song, “Fllf: A fast-lightweight location detection framework for false data injection attacks in smart grids,” *IEEE Transactions on Smart Grid*, vol. 15, no. 1, pp. 911–920, 2023.
- [2] C. Hu, J. Yan, and X. Liu, “Reinforcement learning-based adaptive feature boosting for smart grid intrusion detection,” *IEEE Trans. on Smart Grid*, vol. 14, no. 4, pp. 3150–3163, 2022.
- [3] M. M. Hosseini, A. Umunnakwe, M. Parvania, and T. Tasdizen, “Intelligent damage classification and estimation in power distribution poles using unmanned aerial vehicles and convolutional neural networks,” *IEEE Trans. on Smart Grid*, vol. 11, no. 4, pp. 3325–3333, 2020.
- [4] N. Wei, X. Li, J. Jin, P. Chen, and S. Sun, “Detecting insulator strings as linked chain structure in smart grid inspection,” *IEEE Trans. Ind. Inf.*, vol. 19, no. 8, pp. 9019–9027, 2023.
- [5] Q. Cao, Y. Chen, C. Ma, and X. Yang, “Few-shot rotation-invariant aerial image semantic segmentation,” *IEEE Trans. Geosci. Remote Sens.*, vol. 62, no. 12, pp. 1–13, 2023.
- [6] L. Li, X. Yao, X. Wang, D. Hong, G. Cheng, and J. Han, “Robust few-shot aerial image object detection via unbiased proposals filtration,” *IEEE Trans. Geosci. Remote Sens.*, vol. 62, no. 12, pp. 1–13, 2023.
- [7] Y. Yu, X. Yang, J. Li, and X. Gao, “Object detection for aerial images with feature enhancement and soft label assignment,” *IEEE Trans. Geosci. Remote Sens.*, vol. 60, no. 5, pp. 1–16, 2022.
- [8] K. Yang, G.-S. Xia, Z. Liu, M. Pelillo, and L. Zhang, “Asymmetric siamese networks for semantic change detection in aerial images,” *IEEE Trans. Geosci. Remote Sens.*, vol. 60, no. 10, pp. 1–18, 2022.
- [9] Y. Liu, Z. Xiong, Y. Yuan, and Q. Wang, “Transcending pixels: boosting saliency detection via scene understanding from aerial imagery,” *IEEE Trans. Geosci. Remote Sens.*, vol. 61, no. 7, pp. 1–16, 2023.
- [10] R. Abdelfattah, X. Wang, and S. Wang, “TTPLA: an aerial-image dataset for detection and segmentation of transmission towers and power lines,” in *Proc. Asian Conf. Comput. Vis.*, 2020, pp. 1–17.
- [11] D. Bolya, C. Zhou, F. Xiao, and Y. J. Lee, “YOLACT: Real-time instance segmentation,” in *Proc. IEEE Int. Conf. Comput. Vis.*, 2019.
- [12] X. Tao, D. Zhang, Z. Wang, X. Liu, H. Zhang, and D. Xu, “Detection of power line insulator defects using aerial images analyzed with convolutional neural network,” *IEEE Trans. Syst., man, cyber. : Syst.*, vol. 50, no. 4, pp. 1486–1498, 2020.
- [13] V. Silva, H. Felix, F. Simoes, V. Teichrieb, and M. Santos, “InsPLAD: a dataset and benchmark for power line asset inspection in uav images,” *Inter. J. Remote Sensing*, vol. 44, no. 23, pp. 7294–7320, 2023.
- [14] S. G. Narasimhan and S. K. Nayar, “Contrast restoration of weather degraded images,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 25, no. 6, pp. 713–724, 2003.
- [15] S. K. Nayar and S. G. Narasimhan, “Vision in bad weather,” in *Proc. IEEE Int. Conf. Comput. Vis.*, IEEE, 1999, pp. 820–827.
- [16] W. Yang, J. Liu, and J. Feng, “Frame-consistent recurrent video deraining with dual-level flow,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 1661–1670.

- [17] Y. Liu, D. Jaw, S. Huang, and J. Hwang, "DesnowNet: don't context-aware deep network for snow removal," *IEEE Trans. Image Process.*, vol. 27, no. 6, pp. 3064–3073, 2018.
- [18] X. Qin, Z. Wang, Y. Bai, X. Xie, and H. Jia, "FFA-Net: feature fusion attention network for single image dehazing," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 07, 2020, pp. 11 908–11 915.
- [19] H. Wu, Y. Qu, S. Lin, J. Zhou, R. Qiao, Z. Zhang, Y. Xie, and L. Ma, "Contrastive learning for compact single image dehazing," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 10 551–10 560.
- [20] Y. Song, Z. He, H. Qian, and X. Du, "Vision transformers for single image dehazing," *IEEE Trans. Image Process.*, vol. 32, pp. 1927–1941, 2023.
- [21] D. Ren, W. Zuo, Q. Hu, P. Zhu, and D. Meng, "Progressive image deraining networks: A better and simpler baseline," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 3937–3946.
- [22] X. Chen, H. Li, M. Li, and J. Pan, "Learning a sparse transformer network for effective image deraining," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 5896–5905.
- [23] J. Lin, N. Jiang, Z. Zhang, W. Chen, and T. Zhao, "LMQFormer: a laplace-prior-guided mask query transformer for lightweight snow removal," *IEEE Trans. Circuits Syst. Video Technol.*, 2023.
- [24] J. Liang, J. Cao, G. Sun, K. Zhang, L. Van Gool, and R. Timofte, "SwinIR: image restoration using swin transformer," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2021, pp. 1833–1844.
- [25] Z. Wang, X. Cun, J. Bao, W. Zhou, J. Liu, and H. Li, "Uformer: a general u-shaped transformer for image restoration," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 17 683–17 693.
- [26] S. W. Zamir, A. Arora, S. Khan, M. Hayat, F. S. Khan, and M. Yang, "Restormer: efficient transformer for high-resolution image restoration," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 5728–5739.
- [27] Z. Chen, Y. Zhang, J. Gu, L. Kong, X. Yuan *et al.*, "Cross aggregation transformer for image restoration," *Proc. Adv. Neural Inf. Process. Syst.*, pp. 25 478–25 490, 2022.
- [28] J. Xiao, X. Fu, F. Wu, and Z. Zha, "Stochastic window transformer for image restoration," *Proc. Adv. Neural Inf. Process. Syst.*, vol. 35, pp. 9315–9329, 2022.
- [29] J. Xiao, X. Fu, M. Zhou, H. Liu, and Z. Zha, "Random shuffle transformer for image restoration," in *Proc. Int. Conf. Mach. Learn. PMLR*, 2023, pp. 38 039–38 058.
- [30] H. Zhao, Y. Gou, B. Li, D. Peng, J. Lv, and X. Peng, "Comprehensive and delicate: an efficient transformer for image restoration," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 14 122–14 132.
- [31] J. Zhang, Y. Zhang, J. Gu, Y. Zhang, L. Kong, and Y. Xin, "Accurate image restoration with attention retractable transformer," in *Proc. Int. Conf. Learn. Represent.*, 2023.
- [32] Y. Li, Y. Fan, X. Xiang, D. Demandolx, R. Ranjan, R. Timofte, and L. Van Gool, "Efficient and explicit modelling of image hierarchies for image restoration," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 18 278–18 289.
- [33] B. Li, X. Liu, P. Hu, Z. Wu, J. Lv, and X. Peng, "All-in-one image restoration for unknown corruption," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 17 452–17 462.
- [34] J. M. J. Valanarasu, R. Yasarla, and V. M. Patel, "TransWeather: transformer-based restoration of images degraded by adverse weather conditions," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 2353–2363.
- [35] V. Potlapalli, S. W. Zamir, S. Khan, and F. S. Khan, "PromptIR: prompting for all-in-one blind image restoration," *arXiv:2306.13090*, 2023.
- [36] W. Yang, R. T. Tan, S. Wang, Y. Fang, and J. Liu, "Single image deraining: from model-based to data-driven and beyond," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 11, pp. 4059–4077, 2020.
- [37] Y. Li, R. T. Tan, X. Guo, J. Lu, and M. S. Brown, "Rain streak removal using layer priors," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 2736–2744.
- [38] Y. Luo, Y. Xu, and H. Ji, "Removing rain from a single image via discriminative sparse coding," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2015, pp. 3397–3405.
- [39] J. Liu, W. Yang, S. Yang, and Z. Guo, "Erase or fill? deep joint recurrent rain removal and reconstruction in videos," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 3233–3242.
- [40] K. He, J. Sun, and X. Tang, "Single image haze removal using dark channel prior," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.* IEEE, 2009, pp. 1956–1963.
- [41] J. Gui, X. Cong, Y. Cao, W. Ren, J. Zhang, J. Zhang, J. Cao, and D. Tao, "A comprehensive survey and taxonomy on single image dehazing based on deep learning," *ACM Computing Surveys*, vol. 55, no. 13s, pp. 1–37, 2023.
- [42] X. Guo, Y. Yang, C. Wang, and J. Ma, "Image dehazing via enhancement, restoration, and fusion: a survey," *Information Fusion*, vol. 86, pp. 146–170, 2022.
- [43] M. Singh, V. Laxmi, and P. Faruki, "Visibility enhancement and dehazing: Research contribution challenges and direction," *Comput. Science Review*, vol. 44, p. 100473, 2022.
- [44] B. Cai, X. Xu, K. Jia, C. Qing, and D. Tao, "DehazeNet: an end-to-end system for single image haze removal," *IEEE Trans. Image Process.*, vol. 25, no. 11, pp. 5187–5198, 2016.
- [45] Z. Zhang, Y. Wei, H. Zhang, Y. Yang, S. Yan, and M. Wang, "Data-driven single image deraining: a comprehensive review and new perspectives," *Pattern Recognit.*, 2023.
- [46] B. Li, X. Peng, Z. Wang, J. Xu, and D. Feng, "AOD-Net: all-in-one dehazing network," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2017, pp. 4770–4778.
- [47] X. Fu, B. Liang, Y. Huang, X. Ding, and J. Paisley, "Lightweight pyramid networks for image deraining," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 31, no. 6, pp. 1794–1807, 2019.
- [48] Y. Qiu, K. Zhang, C. Wang, W. Luo, H. Li, and Z. Jin, "MB-TaylorFormer: multi-branch efficient transformer expanded by taylor formula for image dehazing," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 12 802–12 813.
- [49] H. Dong, J. Pan, L. Xiang, Z. Hu, X. Zhang, F. Wang, and M. Yang, "Multi-scale boosted dehazing network with dense feature fusion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 2157–2167.
- [50] J. Xiao, X. Fu, A. Liu, F. Wu, and Z. Zha, "Image de-raining transformer," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2022.
- [51] K. Zhang, R. Li, Y. Yu, W. Luo, and C. Li, "Deep dense multi-scale network for snow removal using semantic and depth priors," *IEEE Trans. Image Process.*, vol. 30, pp. 7419–7431, 2021.
- [52] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, "Swin Transformer: hierarchical vision transformer using shifted windows," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 10 012–10 022.
- [53] Z. Tu, H. Talebi, H. Zhang, F. Yang, P. Milanfar, A. Bovik, and Y. Li, "MAXIM: Multi-axis mlp for image processing," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 5769–5780.
- [54] M. Zhou, J. Huang, C. Guo, and C. Li, "Fourmer: an efficient global modeling paradigm for image restoration," in *Proc. Int. Conf. Mach. Learn. PMLR*, 2023, pp. 42 589–42 601.
- [55] H. Chen, Y. Wang, T. Guo, C. Xu, Y. Deng, Z. Liu, S. Ma, C. Xu, C. Xu, and W. Gao, "Pre-trained image processing transformer," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 12 299–12 310.
- [56] W. Chen, Z. Huang, C. Tsai, H. Yang, J. Ding, and S. Kuo, "Learning multiple adverse weather removal via two-stage knowledge learning and multi-contrastive regularization: Toward a unified model," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 17 653–17 662.
- [57] Y. Zheng, J. Zhan, S. He, J. Dong, and Y. Du, "Curricular contrastive regularization for physics-aware single image dehazing," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 5785–5794.
- [58] X. Liu, Z. Shi, Z. Wu, J. Chen, and G. Zhai, "GridDehazeNet+: an enhanced multi-scale network with intra-task knowledge transfer for single image dehazing," *IEEE Trans. Intell. Transport. Syst.*, vol. 24, no. 1, pp. 870–884, 2022.
- [59] Y. Guo, Y. Gao, W. Liu, Y. Lu, J. Qu, S. He, and W. Ren, "SCANet: self-paced semi-curricular attention network for non-homogeneous image dehazing," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 1884–1893.
- [60] M. Cao, Z. Gao, B. Ramesh, T. Mei, and J. Cui, "A two-stage density-aware single image deraining method," *IEEE Trans. Image Process.*, vol. 30, pp. 6843–6854, 2021.
- [61] X. Zhu, S. Li, Y. Gan, Y. Zhang, and B. Sun, "Multi-stream fusion network with generalized smooth l1 loss for single image dehazing," *IEEE Trans. Image Process.*, vol. 30, pp. 7620–7635, 2021.
- [62] B. Cheng, J. Li, Y. Chen, and T. Zeng, "Snow mask guided adaptive residual network for image snow removal," *Conf. Comput. Image Underst.*, vol. 236, 2023.
- [63] J. He, P. Li, Y. Geng, and X. Xie, "FastInst: A simple query-based model for real-time instance segmentation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2023, pp. 23 663–23 672.